Universität Siegen

Wirtschaftswissenschaften
Wirtschaftsinformatik
Wirtschaftsrecht

Bachelorarbeit

Bachelor of Science Wirtschaftsinformatik

KI-Unterstützung im Angebotsprozess: Eine Design-Case-Studie zur Entwicklung und Evaluation eines Konzeptes zur Projektstrukturplanungsunterstützung in einem KMU

Betreuer	Sophie Degen, Lukas Schröder
Erstprüfer	Prof. Dr. Thomas Ludwig
Zweitprüfer	Prof. Dr. Volker Wulf
vorgelegt von	Tom Heindrichs
Matrikelnummer	[redacted]
Abgabedatum	19. Oktober 2026

Kurzzusammenfassung

In IT-Dienstleistungsunternehmen beginnt die Projektplanung häufig bereits in der Angebotsphase. Schon dort entsteht ein erster Projektstrukturplan, der als Grundlage für den Leistungsumfang und die Kalkulation des Angebots dient. Planungsverantwortliche stützen sich bei der Erstellung vor allem auf ihre eigene Erfahrung. Dieses Wissen ist kaum dokumentiert, liegt meist bei einzelnen Personen und ist für andere schwer zugänglich.

Diese Arbeit untersucht im Rahmen einer Design Case Study in einem mittelständischen IT-Dienstleistungsunternehmen, wie generative KI Planungsverantwortliche bei der Erstellung von Projektstrukturplänen unterstützen kann. Auf Grundlage von neun Interviews und einer Analyse vorhandener Projektdaten wurden Anforderungen abgeleitet und in einem Prototyp umgesetzt. Drei Personen bedienten ihn in Cognitive Walkthroughs selbst, vier bewerteten ihn anhand eines Demo-Videos. Der Prototyp erfasst Projektangaben im Dialog, nutzt mithilfe von Retrieval-Augmented Generation Wissen aus früheren Projekten und erstellt einen bearbeitbaren Entwurf.

Die Teilnehmenden sahen den Entwurf als Ausgangspunkt für die weitere Planung. In den Rückfragen des Systems erkannte eine Projektleitung die Fragen wieder, die sie selbst stellen würde. Verbesserungsbedarf zeigte sich bei der Führung durch die Fragen und bei der Darstellung. Da die passenden Inhalte von Rolle und Zeitpunkt abhängen, lässt sich ein solcher Entwurf nicht allein an einer Referenz bewerten. Die Kontrolle über den Entwurf liegt zwar formal beim Menschen, ausüben kann sie aber nur, wer ihn fachlich beurteilen kann. Daher muss im Angebotsprozess festgelegt werden, wer den Entwurf beginnt und wer ihn freigibt. Da der Prototyp mit synthetischen Daten arbeitete und nur in einzelnen Sitzungen genutzt wurde, bleibt offen, ob er im Alltag den erhofften Nutzen erbringt, Zeit spart und angenommen wird.

Abstract

In IT service companies, project planning often begins as early as the proposal phase. A first work breakdown structure is already created at this stage and serves as the basis for the scope of services and the cost estimate of the proposal. Those responsible for planning rely primarily on their own experience when creating it. This knowledge is rarely documented, usually rests with individuals and is difficult for others to access.

Based on a design case study in a medium-sized IT service company, this thesis examines how generative AI can support planners in creating work breakdown structures. Requirements were derived from nine interviews and an analysis of existing project data and implemented in a prototype. Three participants used it themselves in cognitive walkthroughs, four assessed it based on a demo video. The prototype collects project information in a dialogue, uses retrieval-augmented generation to draw on knowledge from previous projects and creates an editable draft.

The participants regarded the draft as a starting point for further planning. A project manager recognised in the system's follow-up questions the questions they would ask themselves. Room for improvement emerged in how the questions guided users and in the presentation. Since the appropriate content depends on the role and the point in time, such a draft cannot be assessed against a reference alone. Although control over the draft formally remains with humans, only those with the expertise to assess it can actually exercise it. The proposal process must therefore define who starts the draft and who approves it. Since the prototype worked with synthetic data and was only used in single sessions, it remains open whether it delivers the expected benefit, saves time and is adopted in everyday work.

Inhaltsverzeichnis

Kurzzusammenfassung **2**

Abstract **3**

1. Einleitung **7**

2. Fachlicher und technischer Hintergrund **8**
2.1. Planen als situierte Praxis . . . 8
2.1.1. Pläne als Ressource . . . 8
2.1.2. Implizites Erfahrungswissen . . . 8
2.2. Generative KI . . . 9
2.2.1. Sprachmodelle . . . 9
2.2.2. Retrieval-Augmented Generation . . . 9
2.2.3. Workflows und Agenten im Vergleich . . . 10
2.3. Mensch-KI-Interaktion . . . 10
2.3.1. Human in the Loop . . . 11
2.3.2. Geteilte Initiative . . . 11
2.3.3. Übervertrauen und Cognitive Offloading . . . 12
2.4. Verwandte Ansätze zur KI-gestützten Planungsunterstützung . . . 13
2.4.1. Schätzungs- und Planungsartefakte . . . 13
2.4.2. Angebotserstellung . . . 13
2.4.3. Erfahrungswissen und Planungspraxis in KMU . . . 14

3. Methodik **14**
3.1. Grounded Design & Design Case Study . . . 14
3.2. Untersuchungskontext . . . 15
3.2.1. Unternehmensprofil . . . 15
3.2.2. Werkzeuglandschaft . . . 16
3.2.3. Angebotsprozess . . . 16
3.3. Teilnehmende & Datenverarbeitung . . . 17
3.3.1. Auswahl der Teilnehmenden . . . 17
3.3.2. Umgang mit personenbezogenen, Kunden- und Unternehmensdaten 17
3.4. Vorstudie: Vorgehen & Auswertung . . . 18
3.4.1. Interviews . . . 18
3.4.2. Dokumentenanalyse . . . 18
3.4.3. Ableitung der Anforderungen . . . 19
3.5. Prototyping: Vorgehen . . . 20
3.5.1. Konzeption . . . 20
3.5.2. Iterative Implementierung . . . 21
3.5.3. Workshop . . . 21
3.6. Evaluation: Vorgehen & Auswertung . . . 21
3.6.1. Evaluationsdesign . . . 21
3.6.2. Materialien . . . 23
3.6.3. Auswertung . . . 23

4. Design Case Study **24**
4.1. Vorstudie . . . 24
4.1.1. Ergebnisse der thematischen Analyse . . . 24
4.1.2. Ergebnisse der Lessons-Learned-Liste . . . 28
4.1.3. Ergebnisse der Projektdatenanalyse aus DocBee . . . 28
4.1.4. Ableitung der Anforderungen . . . 30
4.2. Konzeption . . . 31
4.2.1. Entwurfsentscheidungen . . . 31
4.2.2. Phasen des Workflows . . . 32
4.2.3. Workshop . . . 33
4.3. Implementierung . . . 34
4.4. Evaluation . . . 38
4.4.1. Einstieg und Erfassung . . . 39
4.4.2. Kalkulationsgrundlage . . . 40
4.4.3. Historisches Wissen und Herkunft . . . 40
4.4.4. Bearbeitung und Export . . . 42
4.4.5. Bedienbarkeit und Zuverlässigkeit . . . 42
4.4.6. Rollen und Kontrolle . . . 42
4.4.7. Nutzen und Zeitgewinn . . . 43
4.4.8. Ergebnis je Anforderung und neue Anforderungen . . . 44

5. Diskussion & Schlussfolgerung **44**
5.1. Diskussion der Ergebnisse . . . 44
5.2. Limitationen . . . 48
5.3. Fazit . . . 50
5.4. Ausblick . . . 50

6. Reflexion & Danksagung **52**

Literaturverzeichnis **53**

Tabellenverzeichnis **59**

Abbildungsverzeichnis **60**

Listings **61**

A. Vorstudienmaterial **68**
A.1. Interviewleitfaden . . . 68
A.2. Rückfragen . . . 69
A.3. Thematische Analyse . . . 71

B. Prototyp **72**
B.1. Phasen des Workflows . . . 73
B.2. Beschreibungsinformationen . . . 74
B.3. Fragen des geführten Einstiegs . . . 74
B.4. Oberfläche . . . 75
B.5. Systemprompts . . . 76
B.6. Pydantic-Schemata . . . 79
B.7. Qdrant-Collections . . . 81

B.8. Demodaten 82
B.9. Quellcode 84

C. Evaluationsmaterial **85**
C.1. Szenario 85
C.2. Aufgaben 85
C.3. Interviewleitfaden 85

Erklärung zur Nutzung von KI-Werkzeugen **87**

Eidesstattliche Erklärung **88**

1. Einleitung

Im Dienstleistungskontext der Informationstechnik (IT) beginnt die Projektplanung häufig bereits in der Angebotsphase mit der Anfrage eines potenziellen Kunden. In dieser Arbeit bezeichnet die Angebotsphase den Zeitraum von der ersten Kundenanfrage bis zum Projektstart. Der Angebotsprozess beschreibt dagegen das Zusammenspiel der beteiligten Rollen und Abläufe in dieser Phase. Noch bevor feststeht, ob ein Auftrag zustande kommt, müssen Anforderungen erfasst, verstanden und ausgearbeitet werden. Diese frühe Arbeit bindet Zeit, Fachwissen und personelle Kapazitäten und wird häufig nicht vergütet. Kalenborn (2014) beschreibt dies für die Vorvertragsphase von Softwareprojekten. Für kleine und mittlere Unternehmen (KMU) ist dieser Aufwand vor dem Hintergrund begrenzter Ressourcen besonders relevant (Wong und Aspinwall 2004).

Ein wichtiges Artefakt in dieser frühen Planungsphase ist der Projektstrukturplan (PSP). Er stellt die Projektstruktur hierarchisch dar und zeigt, wie ein Vorhaben in Teilprojekte und Arbeitspakete gegliedert werden kann (Normung e.V. 2009, Abs. 3.82). Für seine Erstellung ordnen Projektplanungsverantwortliche Kundenanforderungen ein, übertragen Erfahrungen aus ähnlichen Vorhaben und leiten daraus eine erste Struktur ab. Dabei greifen sie auf Erfahrungswissen zurück, das häufig nicht systematisch dokumentiert ist, sondern bei einzelnen Personen liegt oder über Dokumente und historischer Projekte verteilt ist. Die Vorstudie dieser Arbeit legt nahe, dass die Erstellung eines PSP dadurch aufwendig und schwer standardisierbar ist (Abschn. 4.1.1).

Large Language Models (LLMs) eröffnen neue Möglichkeiten, wissensintensive Aufgaben wie die Planung zu unterstützen (Nguyen *et al.* 2025). Sie können in Arbeitskontexten Entscheidungsprozesse unterstützen oder teilweise automatisieren (Langer und Landers 2021). AutoScrum leitet beispielsweise aus einer Beschreibung des Ist- und Zielzustands Anforderungen, User Stories und Aufgaben ab (Schröder 2023, Kap. 4.1). Kwasafo *et al.* (2026) erstellen den Methodikteil von Angeboten auf Grundlage früherer Angebote. Bisherige Arbeiten bewerten jedoch vor allem die erzeugten Ergebnisse (Abschn. 2.4). Offen bleibt, auch nach Kwasafo *et al.* (2026), wie ein solches System Planungsverantwortliche in der Praxis unterstützt, also im konkreten Angebotsprozess und aus Sicht derer, die den Entwurf weiterbearbeiten und verantworten.

Um diese Lücke zu untersuchen, werden in einer Design Case Study (DCS) Anforderungen abgeleitet, in einem Prototyp umgesetzt und im Anwendungskontext evaluiert. Die Arbeit verfolgt damit die Forschungsfrage: Wie kann generative Künstliche Intelligenz (KI) Projektplanungsverantwortliche im Rahmen eines Assistenzsystems bei der Erstellung von Projektstrukturplänen unterstützen?

Diese Arbeit gliedert sich in folgende Kapitel: Kapitel 2 bildet die fachliche und technische Grundlage. Es behandelt Planung als situierte Praxis, führt in Sprachmodelle, Retrieval-Augmented Generation und Agentenmuster ein, ordnet die Gestaltung in die Mensch-KI-Interaktion ein und stellt verwandte Arbeiten vor. Kapitel 3 beschreibt das methodische Vorgehen, den Untersuchungskontext sowie die Erhebung und Auswertung der Daten. Kapitel 4 bildet den Schwerpunkt der Arbeit: Die Vorstudie untersucht die bestehende Praxis und leitet daraus Anforderungen ab. Diese werden in der Konzeption in Designziele übersetzt und im Prototyp umgesetzt. Die Evaluation untersucht anschließend, inwieweit der Prototyp die Anforderungen erfüllt und Planungsverantwortliche im Gebrauch unterstützt. Sie legt nahe, dass der Entwurf als Grundlage angenommen wird, die Schwierigkeiten aber in der Erfassung des Wissens der Nutzenden, der Darstellung und der fachlichen Prüfung liegen. Kapitel 5 ordnet die Ergebnisse in die Literatur ein, beantwortet die Forschungsfrage und diskutiert die Grenzen der Untersuchung. Es schließt mit einem Ausblick auf Forschung und praktische Weiterentwicklung sowie einem Fazit.

2. Fachlicher und technischer Hintergrund

2.1. Planen als situierte Praxis

Im Folgenden wird erklärt, welche Rolle ein Plan in der Arbeit spielt und auf welches Wissen die Planenden bei seiner Erstellung zurückgreifen. Ein Assistenzsystem für Projektstrukturpläne sollte dies berücksichtigen.

2.1.1. Pläne als Ressource

Nach Normung e.V. (2009, Abs. 3.82) ist ein PSP ein Artefakt, das eine „vollständige, hierarchische Darstellung aller Elemente (Teilprojekte, Arbeitspakete) der Projektstruktur als Diagramm oder Liste“ enthält. Daraus folgt nicht, dass das Projekt später genau nach diesem Plan abläuft. Nach Suchman (1987) beschreiben Pläne Ressourcen für situiertes Handeln, die den Verlauf einer Handlung nicht festlegen. Sie bilden nicht jedes Detail der späteren Situation ab. Suchman veranschaulicht dies am Beispiel einer Kanufahrt durch Stromschnellen. Der Plan bringt das Kanu nicht durch die Stromschnellen. Er hilft dabei, sich so vorzubereiten, dass man anschließend mit den eigenen Fähigkeiten auf die Situation reagieren kann (52). Häufig zeigt sich erst im Handeln, welche Möglichkeiten eine Situation bietet und welches Ziel erreicht werden kann, was ein Plan allein vorab nicht leisten kann (52).

2.1.2. Implizites Erfahrungswissen

Bei der Erstellung eines solchen Plans greifen die Planenden auf Erfahrungen aus früheren Projekten zurück. Dieses Wissen ist häufig nicht ausformuliert oder dokumentiert, sondern liegt bei den Mitarbeitenden als implizites Erfahrungswissen (*tacit knowledge*) vor (Nonaka und Takeuchi 2012; Polanyi 1966). Damit solches Wissen auch anderen zugänglich gemacht werden kann, ist es notwendig, dass es zumindest teilweise in eine von einzelnen Personen unabhängige Form überführt wird (*Externalisierung*) (Nonaka und Takeuchi 2012, Kap. 3). In der Fertigung liegt Prozesswissen nach Hoerner *et al.* (2023) oft nur als implizites Wissen erfahrener Mitarbeiter vor. Um es nutzbar zu machen, entwickeln die Autoren ein strukturiertes Vorgehen, bei dem eine analysierende Person das Wissen gemeinsam mit den Mitarbeitern erfasst (Kap. 2).

Für ein Assistenzsystems bedeutet dies, dass es nur auf den Teil des Erfahrungswissens zugreifen kann, der bereits externalisiert wurde. Der andere Teil bleibt bei den Planungsverantwortlichen. Das Ergebnis kann, wie nach Suchman (1987), nur eine Ressource sein, die durch die Planenden mit ihrem eigenen Wissen geprüft und angepasst wird.

2.2. Generative KI

Technisch stellt sich die Frage, wie ein Sprachmodell Entwürfe erzeugen kann, die auf dem historischen Wissen eines Unternehmens beruhen, und wie dieser Prozess gesteuert wird. Dazu werden Sprachmodelle, Retrieval-Augmented Generation (RAG) sowie Workflows und Agenten vorgestellt.

2.2.1. Sprachmodelle

LLMs erzeugen Text, indem sie auf Grundlage einer Eingabe schrittweise das jeweils nächste Textstück (*Token*) statistisch vorhersagen. Sie werden auf großen Textmengen vortrainiert und sagen jeweils das nächste Token anhand der vorangehenden Texte voraus (Zhang *et al.* 2025, Kap. 2.1). Mit zunehmender Größe des Modells und der Trainingsdaten zeigen sie Fähigkeiten, die kleineren Modellen fehlen. Sie können Anweisungen folgen, aus wenigen Beispielen in der Anfrage lernen und viele komplexe Aufgaben mit wenig oder ohne zusätzliches Training bearbeiten (Kap. 2.1).

2.2.2. Retrieval-Augmented Generation

Die Zuverlässigkeit von LLMs hängt unter anderem davon ab, wie häufig eine Information in den Trainingsdaten vorkam (Kandpal *et al.* 2023, Kap. 1). Bei seltenen Informationen sinkt die Verlässlichkeit (Kap. 3). Organisationswissen und interne Dokumente sind in der Regel nicht Teil dieser Trainingsdaten. Fehlt eine passende Wissensgrundlage, können die Modelle dennoch flüssige und plausibel wirkende, aber falsche oder erfundene Angaben erzeugen. Dieses Phänomen wird als *Halluzination* bezeichnet (Zhang *et al.* 2025, Kap. 1, 2.2). Erhält das Modell den passenden Text als Kontext in dessen Anfrage, steigt die Zuverlässigkeit gerade bei seltenen Fakten deutlich (Kandpal *et al.* 2023, Kap. 4.3). RAG sucht und ergänzt die Anfrage um passende Informationen aus einem eigenen Datenbestand und stellt sie dem Modell als erweiterten Kontext zur Verfügung (Gao *et al.* 2023). Im Unternehmenskontext wird RAG vor allem für textlastige Aufgaben eingesetzt, etwa zur Prüfung regulatorischer Vorgaben oder zur Erstellung von Verträgen und technischer Dokumentation (Karakurt und Akbulut 2026, Kap. 2.2, Tab. 1).

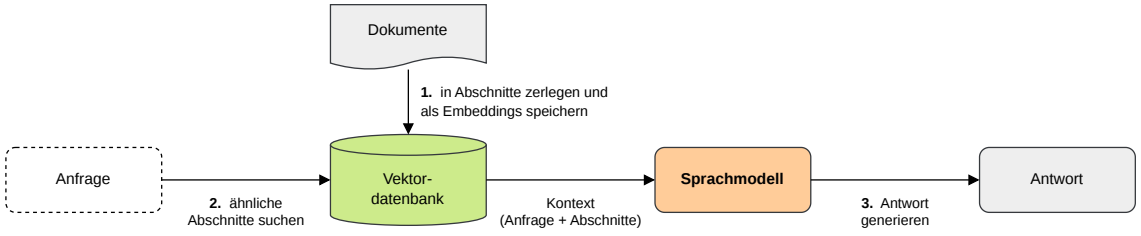


Abb. 1: Funktionsweise von RAG anhand einer Vektordatenbank. Eigene Darstellung in Anlehnung an Gao *et al.* (2023, Fig. 2).

Wie Abbildung 1 zeigt, umfasst der Ablauf drei Schritte (Gao *et al.* 2023, Kap. II.A). Zunächst werden die Dokumente in Abschnitte zerlegt und als Vektoren [1] , sogenannte *Embeddings*, in einer Vektordatenbank gespeichert. Stellt der User eine Anfrage, wird ebenfalls ein Vektor erzeugt. Das System gibt die Abschnitte zurück, deren Vektoren der Anfrage inhaltlich am ähnlichsten sind, und stellt sie dem Modell als Kontext bereit. Abschließend generiert das Modell auf Grundlage dieses Kontexts eine Antwort.

Eine Alternative ist das Nachtrainieren des Modells (*Fine-Tuning*), bei dem das Wissen in die Parameter des Modells übergeht. Gao *et al.* (2023) vergleichen RAG mit einem Lexikon, das dem Modell bereitgestellt wird, und Fine-Tuning mit einem Lernenden, der Wissen über längere Zeit verinnerlicht. Fine-Tuning eignet sich vor allem, um bestimmte Strukturen, Stile oder Formate zu übernehmen. Um das Modell zu aktualisieren, muss es jedoch erneut trainiert werden, was vorbereitete Trainingsdaten und hohen Rechenaufwand erfordert. Bei RAG kann neues oder geändertes Wissen dagegen direkt in die Datenbank aufgenommen werden, und es bleibt nachvollziehbar, welche Textabschnitte dem Modell als Kontext vorlagen. Dafür verlängert die Suche die Antwortzeit (Kap. II.D). Beide Ansätze schließen sich nicht aus und lassen sich kombinieren (Kap. II.D). Für diese Arbeit ist RAG naheliegend, da sich der Bestand historischer Daten laufend aktualisiert und die Planenden nachvollziehen sollen, auf welchen Projekten ein Entwurf beruht.

2.2.3. Workflows und Agenten im Vergleich

Wenn ein Sprachmodell mehrere Schritte nacheinander ausführen soll, stellt sich die Frage, wie der Ablauf gesteuert wird. Bei einem *Agenten* entscheidet das Modell selbst, welcher Schritt als nächstes folgt. Ein Beispiel ist ReAct. Dabei formuliert das Modell abwechselnd eine Überlegung und führt eine Aktion aus. Das Ergebnis der Aktion bezieht es in den nächsten Schritt ein (Yao *et al.* 2023). Sumers *et al.* (2024) bezeichnen die Steuerungslogik als *decision procedure*. Sie ist das übergeordnete Programm des Agenten, in dem das Modell die nächste Aktion vorschlägt und auswählt (Kap. 4.6). Bei einem *Workflow* ist die Reihenfolge der Schritte dagegen im Programmcode festgelegt. Das Modell übernimmt dabei die einzelnen Teilaufgaben. Die Gegenüberstellung von *Workflow* und *Agent* ist auch in der Praxisliteratur verbreitet (Anthropic 2024).

Davon unabhängig ist die Frage, ob eine Aufgabe in mehrere Schritte zerlegt oder mit einer einzigen Anfrage an das Modell bearbeitet wird. Wu *et al.* (2022) zeigen in einer Nutzerstudie, dass verkettete und einzeln sichtbare Teilschritte die Ergebnisse verbessern und den Planenden mehr Transparenz und Steuerungsmöglichkeiten geben können. Für ein Werkzeug, dessen Ergebnisse Menschen prüfen und anpassen sollen, ist diese Tranparenz, neben der Ergebnisqualität, relevant. Der gewählte Ansatz wird in Abschnitt 4.2.1 erläutert.

2.3. Mensch-KI-Interaktion

Wenn ein Sprachmodell einen Entwurf erzeugt, stellt sich neben der Frage nach der Qualität auch die Frage, wie Mensch und System interagieren, wer die Verantwortung trägt und wie Nutzende den Entwurf prüfen. Dafür spielen drei Konzepte eine Relevanz.

1. Ein Vektor beschreibt semantische Informationen eines Textabschnitts als Punkt in einem mehrdimensionalen Raum. Über die Ähnlichkeit zweier Vektoren, etwa die Kosinus-Ähnlichkeit, lässt sich bestimmen, wie ähnlich sich zwei Texte inhaltlich sind (Gao *et al.* 2023, Kap. II.A, III.D)

2.3.1. Human in the Loop

Wie viel ein System selbst entscheidet, lässt sich anhand einer Stufenfolge von manueller Ausführung bis zur vollständigen Automatisierung beschreiben (Parasuraman *et al.* 2000, Kap. 3). Auf Stufe 4 schlägt das System beispielsweise eine Entscheidung vor und dessen Entscheidungsbefugnis bleibt beim Menschen (Kap. 3, Abb. 1). Langer und Landers (2021) übertragen diese Stufen auf KI im Arbeitskontext und bezeichnen den Zwischenbereich als Unterstützung (*Augmentierung*). Das System bereitet Informationen auf, die Entscheidung trifft weiterhin der Mensch.

Auf welcher Stufe ein System arbeitet, ist eine Gestaltungsentscheidung. Parasuraman und Riley (1997) sprechen von Missbrauch der Automatisierung (*abuse*), wenn Funktionen automatisiert werden, ohne die Folgen für die menschliche Leistung und die Entscheidungsbefugnis der Bedienenden zu berücksichtigen. Sie empfehlen, die Rolle des Menschen aus seiner Rolle und Fähigkeiten abzuleiten und nicht als Nebenprodukt der technischen Umsetzung zu behandeln. Eine aktive Beteiligung halten sie auch dann für sinnvoll, wenn eine vollständige Automatisierung leistungsfähiger wäre, weil der Mensch so informiert und eingriffsfähig bleibt (249). Die Rolle der Planenden in einem Assistenzsystem ergibt sich nicht aus dem, was das Modell technisch leistet, sondern aus ihrer Verantwortung in dem Prozess.

Die Hochrangige Expertengruppe für künstliche Intelligenz (2019) unterscheidet drei Prinzipien, über die Menschen die Aufsicht über ein KI-System ausüben können. Bei *Human in the Loop* kann der Mensch in jeden Entscheidungszyklus des Systems eingreifen. Bei *Human on the Loop* wirkt er am Entwurf des Systems mit und überwacht dessen Betrieb. Bei *Human in Command* entscheidet er, ob und wie das System eingesetzt wird. Ein Eingreifen in jede einzelne Entscheidung halten die Autoren jedoch häufig weder für möglich noch für wünschenswert (Abs. 65).

Fries *et al.* (2025) fordern, Beschäftigte in KMU bereits an der Gestaltung von KI-Systemen zu beteiligen und nicht erst an deren Nutzung. Auch Betriebsräte prüfen in deutschen Unternehmen die Auswirkungen neuer Technik auf Beschäftigte. Sie verstehen sich dabei als Mitgestaltende und nicht als Bremse (Gerbracht *et al.* 2024, Kap. 6). In dieser Arbeit entspricht die Prüfung jedes Entwurfs durch die Planungsverantwortlichen dem Konzept von *Human in the Loop*. Die Einbindung von Nutzenden in den Gestaltungsprozess im Rahmen der DCS ist dem *Human on the Loop* zuzuordnen (Kapitel 3). Dass der Mensch die Entscheidung behält, legt allerdings noch nicht fest, wie die Zusammenarbeit mit dem System im Einzelnen abläuft.

2.3.2. Geteilte Initiative

Hier setzt das Konzept der geteilten Initiative an. Nach Horvitz (1999) sollen Mensch und System gemeinsam auf das Ziel der nutzenden Person hinarbeiten. Bei Unsicherheit soll das System nachfragen, ohne unnötig zu stören (Prinzip 5). Im Zweifel soll es weniger tun, dafür aber zuverlässig handeln (Prinzip 8). Außerdem sollen Nutzende das Ergebnis selbst weiterbearbeiten können (Prinzip 9). Ähnliche Aspekte finden sich in den 18 Richtlinien von Amershi *et al.* (2019). Fehler sollen sich leicht korrigieren lassen (G9). Bei Unsicherheit soll das System nachfragen oder weniger anbieten (G10). Auch die Gründe für einen Vorschlag sollen erkennbar sein (G11). Die Autoren lassen offen, wie die Richtlinien im Gestaltungsprozess angewendet werden (Kap. 7).

Während *Human in the Loop* festlegt, wer entscheidet, beschreiben diese Prinzipien, wie ein System den Menschen in die Lage versetzt, diese Entscheidung zu treffen: Es fragt bei Unsicherheit nach, hält sich im Zweifel zurück und liefert Ergebnisse, die sich bearbeiten lassen. Beide Konzepte setzen jedoch voraus, dass sich Nutzende mit den Vorschlägen tatsächlich auseinandersetzen.

2.3.3. Übervertrauen und Cognitive Offloading

Dass dies nicht selbstverständlich ist, beschreiben bereits Parasuraman und Riley (1997). Neben dem Missbrauch durch die Gestaltung nennen sie zwei Fehlformen auf Seiten der Nutzenden. Bei der ersten verlassen sich Nutzende zu stark auf das System (*misuse*). Bei der zweiten nutzen sie es gar nicht mehr, etwa nach wiederholten Fehlalarmen (*disuse*). Vertrauen in KI hängt nicht nur von ihrer Zuverlässigkeit ab, sondern auch von der jeweiligen Person und ihrer Situation (Kaplan *et al.* 2023, 337). Unvorhersehbares Systemverhalten kann Nutzende verunsichern und dazu führen, dass sie das System nicht mehr nutzen (Amershi *et al.* 2019, Kap. 1).

Eine ähnliche Perspektive bietet das Konzept des *Cognitive Offloading*. Risko und Gilbert (2016) beschreiben damit, dass Menschen äußere Hilfsmittel (beispielsweise ein Taschenrechner zum Rechnen) nutzen, um die geistigen Anforderungen einer Aufgabe zu verringern. Bei Automatisierung wählt die Person das Auslagern häufig nicht selbst, es ist bereits im System angelegt. Als mögliche Folgen nennen Risko und Gilbert (2016), dass sich Nutzende unkritisch auf die Ausgabe verlassen und dass Fähigkeiten bei dauerhafter Abhängigkeit verloren gehen können. Damit schließt sich der Kreis zum Missbrauch nach Parasuraman und Riley (1997): Ist das Auslagern bereits im System angelegt, bestimmt die Gestaltung, wie viel eigene Auseinandersetzung den Nutzenden bleibt. Gerlich (2025) findet in einer Befragung einen negativen Zusammenhang zwischen häufiger Nutzung von KI-Werkzeugen und kritischen Denkfähigkeiten, verursacht durch stärkeres *Cognitive Offloading*. Der Befund beruht allerdings auf Selbstauskünften und belegt keinen kausalen Zusammenhang (Kap. 6).

In einem Online-Experiment mit 220 klinischen Fachkräften verschlechterten fehlerhafte KI-Empfehlungen die Behandlungsentscheidungen (Jacobs *et al.* 2021). Erklärungen zu den Empfehlungen glichen diesen Effekt nicht aus und können nach Ansicht der Autoren Übervertrauen sogar verstärken (Jacobs *et al.* 2021). In einem Online-Experiment mit Laien erkannten Teilnehmende Fehler besser, wenn sie sich zunächst selbst mit der Aufgabe auseinandersetzten, etwa weil die KI-Empfehlung erst auf Abruf oder nach einer eigenen Entscheidung erschien (Buçinca *et al.* 2021). Die Teilnehmenden empfanden diese Varianten allerdings als komplexer, und eine bessere Fehlererkennung ging mit geringerem Vertrauen in das System einher (Kap. 4.2, 4.3). Hier zeigt sich ein Spannungsfeld zur geteilten Initiative: Während Horvitz (1999) und Amershi *et al.* (2019) Nutzende möglichst wenig stören wollen, entsteht die bessere Fehlererkennung gerade durch zusätzlichen Aufwand. Systeme werden zudem eher angenommen, wenn sie zur bestehenden Arbeitsweise passen (Van Berkel *et al.* 2023, Kap. 5.2). Werden Pläne, wie bei Suchman (1987), als Ressource statt als Vorgabe verstanden, ist die Prüfung des Entwurfs ohnehin Teil der Arbeit. Nach Buçinca *et al.* (2021) reicht eine Prüfung im Nachhinein jedoch nicht aus. Fehler werden eher erkannt, wenn sich die Planenden schon vorher selbst mit der Aufgabe auseinandersetzen. Das System muss sie dazu nicht zusätzlich zwingen. Es kann diese Auseinandersetzung in Schritte legen, die ohnehin zur Planung gehören, etwa indem die Planenden das Projekt zuerst selbst beschreiben, bevor ein Entwurf entsteht.

2.4. Verwandte Ansätze zur KI-gestützten Planungsunterstützung

Eine Arbeit, die ein Assistenzsystem vorstellt, welches im Angebotsprozess eines KMU Projektstrukturpläne auf Basis historischer Projekte und Erfahrungen entwirft, ließ sich in der Recherche nicht finden. Der Abschnitt betrachtet bisherige ausgewählte Forschungsarbeiten wie Systeme, die mit Sprachmodellen Planungs- und Schätzartefakte erzeugen, über Systeme, die frühere Angebote für neue nutzen, und über Studien dazu, wie in KMU mit Erfahrungswissen geplant wird. Neben dem, was die Systeme leisten, ist dabei jeweils von Interesse, wie sie bewertet wurden und welche Rolle die Menschen in ihnen einnehmen.

2.4.1. Schätzungs- und Planungsartefakte

Mit AutoScrum beschreibt Schröder (2023), wie LLMs aus einer Beschreibung des Ist- und Zielzustands schrittweise Anforderungen, Produktfeatures, User Stories, Akzeptanzkriterien und schließlich Aufgaben ableitet (Kap. 4.1, 5). Die einzelnen Schritte folgen dem Workflow-Muster aus Abschnitt 2.2.3 und werden nacheinander aufgerufen. Das Vorgehen wird an einem Beispiel demonstriert (Kap. 5.1). Eine Evaluation mit Nutzenden findet nicht statt. Das Team soll die Vorschläge des Modells filtern (Kap. 4.1, 6). Bui *et al.* (2025) untersuchen SEEAgent, bei dem mehrere LLM-Agenten gemeinsam mit Teams aus der Softwareentwicklung User Stories schätzen. Die Agenten begründen und diskutieren ihre Schätzungen und beziehen frühere Schätzungen zu User Stories ein (Kap. II.A, II.D). In einer Laborstudie zu einem fiktiven Projekt mit zwölf Teilnehmenden sahen alle einen Nutzen. Nur ein Drittel hielt jedoch einen vollständigen Ersatz von Fachleuten für möglich. Die Autoren leiten daraus eine Präferenz für menschliche Aufsicht bei zentralen Entscheidungen ab (Kap. III.B).

2.4.2. Angebotserstellung

Kwasafo *et al.* (2026) entwickeln ein System, das Angebote für Beratungsunternehmen im Bauwesen erstellt. Zuerst fragten sie in zwei Unternehmen die Verantwortlichen für Angebote, welche Tätigkeiten sich automatisieren lassen (4). Das System liest die Anforderungen aus einer neuen Ausschreibung aus und sucht ähnliche frühere Angebote. Daraus erstellt es einen Entwurf einer Art Vorgehensbeschreibung, den das Angebotsteam anschließend prüft und überarbeitet (10–11). Bewertet wurde das System auf zwei Wegen. Die ausgelesenen Anforderungen wurden mit einer manuellen Auswertung verglichen. Außerdem bewerteten fünf Fachleute die erzeugten Texte, ohne zu wissen, ob sie vom System oder von Menschen stammten (13–15). Die Autoren folgern, dass die Vorgehensbeschreibung fachliches Urteilsvermögen braucht und sich ohne Fachleute kaum vollständig automatisieren lässt (16). Wie solche Systeme die Arbeitsabläufe verändern, untersuchen sie nicht (18). Al-Hebshi und Lübbe (2026) erzeugen Lösungskonzepte für den Angebotsprozess einer Unternehmensberatung. Dafür nutzen sie das Transkript des Erstgesprächs mit dem Kunden. Ergänzend sucht das System frühere ähnliche Konzepte und Inhalte. Bevor ein Konzept an den Kunden geht, soll eine Person es prüfen und freigeben (Kap. 2). Untersucht wird vor allem, welches Sprachmodell sich am besten eignet. Dafür nutzen die Autoren technische Kennzahlen, eine Bewertung durch ein weiteres Sprachmodell und das Urteil einer Fachperson (Kap. 3). Die Qualität der Ergebnisse hängt

nach den Autoren auch davon ab, wie gut das Unternehmenswissen aufbereitet ist und wie ausführlich das Erstgespräch festgehalten wurde (Al-Hebshi und Lübbe 2026, Kap. 5).

2.4.3. Erfahrungswissen und Planungspraxis in KMU

Fries *et al.* (2025) untersuchen die Produktionsplanung in drei mittelständischen Unternehmen anhand von Interviews und Beobachtungen (Kap. 4). Die Verantwortlichen stützen sich auf Erfahrung und Bauchgefühl, zwischen geplanter und tatsächlicher Ausführung besteht eine deutliche Lücke (Kap. 7). Daraus leiten die Autoren Gestaltungsräume ab, in denen KI einzelne Teilaufgaben unterstützen kann, etwa die Schätzung der Bearbeitungszeit oder der Wahrscheinlichkeit von Nacharbeit (Kap. 7). Eine Gesamtlösung für die Produktionsplanung sehen sie darin nicht (Kap. 5.1.4). Hoerner *et al.* (2023) erschließen implizites Erfahrungswissen von Beschäftigten in der Fertigung und stellen es über ein Assistenzsystem bereit. Dieses entwickeln sie iterativ mit den Nutzenden weiter. Das System arbeitet ohne generative KI. Das Wissen ist als Regeln hinterlegt, die einer Störung eine Lösung zuordnen. Neue Hinweise der Beschäftigten fasst das System nach Ähnlichkeit zusammen, und eine verantwortliche Person prüft sie, bevor sie übernommen werden (Kap. 2.1.3, 3.3). Soziale und organisatorische Folgen haben die Autoren nach eigener Aussage nicht umfassend untersucht (Kap. 4.2).

Die betrachteten Arbeiten zeigen, dass LLMs Planungs- und Angebotsartefakte aus Anforderungen und früheren Projekten ableiten können. Dabei bleiben drei Aspekte offen. Erstens erzeugt keine der Arbeiten einen PSP in der Angebotsphase. Die Angebotssysteme erstellen Textbausteine, während sich die Planungssysteme auf Aufgaben und Schätzungen in der Softwareentwicklung konzentrieren. Zweitens wird meist der Output, das Ergebnis, bewertet, etwa anhand von Genauigkeitsmaßen oder Bewertungen durch Fachleute zu einzelnen Dokumenten. Dazu passt der Befund von Karakurt und Akbulut (2026).Von den 63 ausgewerteten Studien zu RAG im Unternehmenskontext bezieht nur etwa ein Fünftel Bewertungen durch Menschen ein. Nur etwa ein Achtel erprobt das System im realen Umfeld. Drittens werden Systeme und Praxisstudien getrennt betrachtet. Fries *et al.* (2025) untersuchen die erfahrungsgebundene Planungspraxis ohne ein System. Hoerner *et al.* (2023) erproben ein System, untersuchen dessen organisatorische Folgen jedoch nicht näher.

Während bisherige Arbeiten vor allem den System-Output betrachten, untersucht diese Arbeit, wie ein KI-gestütztes Assistenzsystem Planungsverantwortliche bei der Erstellung von Projektstrukturplänen im Gebrauch unterstützt. Im Mittelpunkt stehen dabei zwei Aspekte, zum einen wie das System vorhandenes Erfahrungswissen einbringt und zum anderen wie Planungsverantwortliche den Entwurf nachvollziehen und kontrollieren können.

3. Methodik

3.1. Grounded Design & Design Case Study

Als methodischer Rahmen dient Grounded Design (GD), eine praxistheoretische Forschungsperspektive aus der Human-Computer Interaction (HCI) beziehungsweise dem Computer-Supported Cooperative Work (CSCW) (Rohde *et al.* 2017). GD geht davon aus, dass IT-Artefakte und soziale Praktiken sich wechselseitig beeinflussen und dass

die Gestaltung eines Artefakts und seine Überführung in den Gebrauch in die etablierten Praktiken einer Organisation eingreifen (Rohde *et al.* 2017). Anforderungen an ein System lassen sich demnach nicht vollständig im Voraus erheben. Sie erschließen sich im Zusammenspiel aus dem Verständnis bestehender Praktiken, der gestalterischen Intervention und der Beobachtung ihrer Wirkung. Die konkrete Forschungsstrategie innerhalb dieses Rahmens ist die DCS (Wulf *et al.* 2015). Sie gliedert die Forschung in drei aufeinander aufbauende Phasen:

1. Eine empirische Vorstudie oder Kontextstudie, die die bestehende Praxis, ihre Arbeitsweisen und Werkzeuge untersucht.
2. Die Konzeption und Entwicklung eines IT-Artefakts auf Grundlage der Ergebnisse der Vorstudie.
3. Die Untersuchung und Dokumentation, wie die Praxis das Artefakt aneignet.

Das Artefakt kann iterativ entwickelt werden. Dafür ist eine enge Zusammenarbeit zwischen Forschenden und Teilnehmenden aus der Praxis wichtig (Wulf *et al.* 2015). Abweichend von dieser idealtypischen Form endet die Arbeit nicht mit einer Aneignungsstudie im produktiven Einsatz (Wulf *et al.* 2015), sondern mit einer einmaligen Evaluation des Prototyps (Abschn. 3.6). Die Folgen für die Aussagekraft werden in Abschnitt 5.2 diskutiert.

Für den Anwendungsfall ist dieser Ansatz geeignet, weil Pläne das tatsächliche Vorgehen nicht vollständig festlegen (Suchman 1987). Zwischen geplantem Soll-Prozess und tatsächlichem Ist-Ablauf treten daher regelmäßig Abweichungen auf, etwa wegen unvollständiger Daten oder Arbeitsschritten, die an die Situation angepasst werden (Fries *et al.* 2025). Ein System ist aus dieser Sicht auch daran zu beurteilen, ob es implizites Erfahrungswissen sichtbar macht (Hoerner *et al.* 2023) und an bestehende Arbeitsweisen anschließt. Eine DCS zielt nicht auf statistische Generalisierbarkeit, sondern auf ein detailliertes Verständnis eines konkreten Untersuchungskontexts. Übertragbar sind vor allem die daraus abgeleiteten Gestaltungsimplikationen, die mit weiteren Fallstudien verglichen werden können (Rohde *et al.* 2017; Wulf *et al.* 2015). Die Werkstudententätigkeit des Autors im Bereich Software Engineering erleichterte den Feldzugang und das Verständnis interner Abläufe.

3.2. Untersuchungskontext

3.2.1. Unternehmensprofil

Die Studie wurde in einem mittelständischen IT-Dienstleistungsunternehmen mit etwa 150 Mitarbeitenden durchgeführt. Das Unternehmen berät bei der strategischen Umsetzung und dem Management von IT-Lösungen.

Das Unternehmen gliedert sich in mehrere Fachabteilungen. Drei davon sind für den Angebotsprozess relevant. *Consulting & Vertrieb* ist für Kundenakquise und Account Management zuständig. Das *Projektmanagement* übernimmt die Planung, Durchführung und Überwachung betreuter Projekte. *Customer Service & Consulting* stellt die Consultants für die fachliche Umsetzung. Abteilungsübergreifend gibt es sogenannte „Skill-Teams“, Gruppen mit spezialisiertem Wissen zu einem Themenbereich der IT oder der Betriebstechnik (OT). Die Abteilung *Inside Sales* wurde trotz ihrer Beteiligung am Angebotsprozess nicht einbezogen. Sie verantwortet die kaufmännische Vor- und Nachbereitung; diese Arbeit konzentriert sich auf die operativ planenden Rollen.

3.2.2. Werkzeuglandschaft

Für die Untersuchung sind vor allem zwei Werkzeuge relevant. DocBee dient der Zeit- und Tätigkeitserfassung auf Projekt- und Ticketpositionen und enthält Struktur- und Aufwandsdaten abgeschlossener Projekte. Es ist die zentrale Datenquelle der Dokumentenanalyse (Abschn. 3.4.2). Microsoft Teams wird für Kommunikation und Dateiablage genutzt; dort liegt auch die Lessons-Learned-Liste des Projektmanagements. Außerdem kommen SAP für kaufmännische Prozesse und eine eigens entwickelte Projektmanagement-Software für die Projektsteuerung zum Einsatz.

3.2.3. Angebotsprozess

Im betrachteten Unternehmen begleiten Account Manager (Consulting & Vertrieb) und Consultants (Customer Service & Consulting) den Angebotsprozess. Projektleiter aus dem Projektmanagement kommen in der Regel erst nach der Auftragserteilung hinzu. Sie übernehmen die weitere Planung auf Grundlage der im Angebotsprozess erstellten Kalkulation. Abbildung 2 zeigt den Ablauf. Für Projekte, an denen mehrere Consultants beteiligt sind und die einen Projektleiter vorsehen, wird ein PSP erstellt. Im Unternehmen werden diese als „managed Projekte“ bezeichnet.

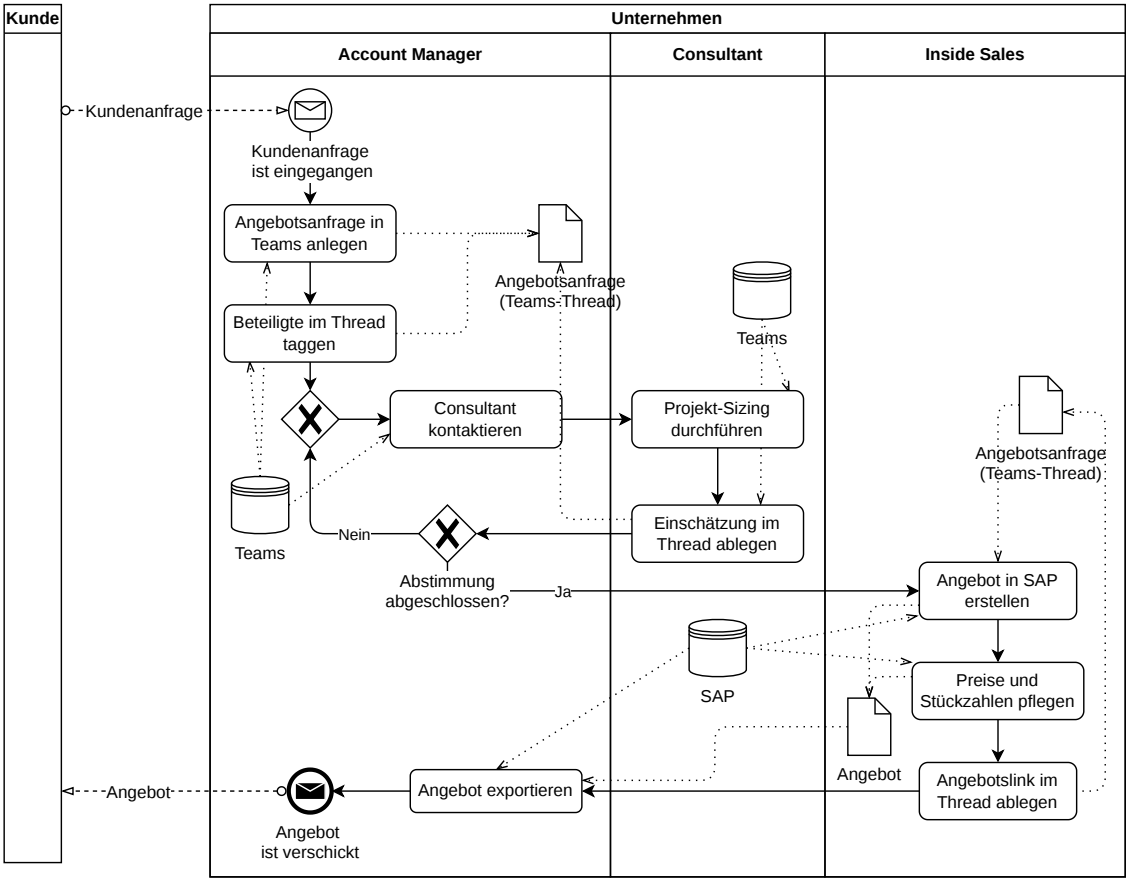


Abb. 2: Angebotsprozess im untersuchten Unternehmen (BPMN 2.0, eigene Darstellung)

3.3. Teilnehmende & Datenverarbeitung

3.3.1. Auswahl der Teilnehmenden

Die Teilnehmenden wurden nach einem zielgerichteten Sampling-Ansatz (*purposeful sampling*) ausgewählt (Patton 2014, Kap. 5). Berücksichtigt wurden Personen, die Einblicke in den aktuellen Angebotsprozess und die Nutzung von Projektstrukturplänen geben konnten. Im Verlauf der ersten Interviews zeigte sich, dass weitere Perspektiven aus Consulting und Account Management benötigt wurden. Die Auswahl folgte deshalb zusätzlich einem Schneeball-Prinzip (Goodman 1961). Am Ende jedes Interviews wurden Ansprechpersonen für die noch unterrepräsentierten Perspektiven erfragt. So wurden neun Personen mit unterschiedlichen Rollen im Angebotsprozess gewonnen. Urlaub, Arbeitsbelastung, Krankheit und Dienstreisen erschwerten in allen Phasen die Terminfindung und verzögerten Rückmeldungen. Nicht alle Personen nahmen daher an jeder Phase teil. Tabelle 1 zeigt die Teilnehmenden und ihre Beteiligung.

Tab. 1: Teilnehmende der Design Case Study.

ID	I	R	W	A	B	Rolle	Berufserfahrung
P1	×	×	×	×	–	Projektleiter	3 Jahre
P2	×	–	–	–	×	Account Manager	15 Jahre
P3	×	–	–	×	–	Projektleiter	15 Jahre
P4	×	–	–	–	×	Projektleiter	4 Jahre
P5	×	–	–	–	–	Projektleiter	5 Jahre
P6	×	–	×	×	–	Consultant	9 Jahre
P7	×	–	–	–	×	Consultant	22 Jahre
P8	×	–	–	–	–	Projektleiter	26 Jahre
P9	×	–	–	–	×	Account Manager	25 Jahre

Legende: I, Interviews; R, Rückfragen; W, Workshops; A, Evaluation Gruppe A; B, Evaluation Gruppe B. ***Belegformat:*** Belege enthalten ein Erhebungskürzel und eine Teilnehmer-ID (z. B. I-P6, A-P1, B-P9, W-P1, R-P1). Darauf folgt die Fundstelle. Bei Interviews und Evaluation ist dies der Absatz (Abs.) in MAXQDA, bei Workshops die Position (Pos.) im Protokoll und bei Rückfragen das Datum.

Die Geschäftsführung gab den Anstoß für die Arbeit, wurde aber nicht befragt.

3.3.2. Umgang mit personenbezogenen, Kunden- und Unternehmensdaten

Die Teilnahme an Interviews und Evaluation war freiwillig, und alle Daten wurden ausschließlich für diese Arbeit erhoben und verarbeitet. Die Teilnehmenden wurden über den Zweck und die Verarbeitung der Daten informiert und stimmten zu. In einem Unternehmen dieser Größe lässt sich eine Person möglicherweise bereits anhand ihrer Rolle erkennen. Deshalb sind die Rollen in Tabelle 1 zu Rollengruppen zusammengefasst. Wertende Aussagen über Personen oder Abteilungen werden nicht wörtlich wiedergegeben. Aufzeichnungen und Transkripte sind nicht Teil des Anhangs und bleiben beim Autor (siehe Anhang B.9).

Für die Dokumentenanalyse wurden Kunden- und unternehmensinterne Daten verarbeitet. Diese wurden anonymisiert und durch allgemeine Bezeichnungen ersetzt. Projektin-

halte werden so beschrieben, dass kein Rückschluss auf einzelne Kundenprojekte möglich ist. Da für den Prototyp keine im Unternehmen freigegebenen Modelle verwendet wurden, musste auch berücksichtigt werden, welche Daten das Unternehmen verlassen. Für die Demonstration kamen deshalb ausschließlich synthetische Projektdaten zum Einsatz. Produktive Kunden- oder Unternehmensdaten wurden nicht verarbeitet.

3.4. Vorstudie: Vorgehen & Auswertung

3.4.1. Interviews

Erhebung Die Datenerhebung erfolgte durch leitfadengestützte, semi-strukturierte Interviews. So ließen sich die Gespräche an die unterschiedlichen Rollen der Teilnehmenden anpassen, ohne dass relevante Anforderungsbereiche unberührt blieben. Der Leitfaden umfasste sechs Themenblöcke. Dazu gehörten Rolle und Tätigkeiten, Berührungspunkte mit Projektstrukturplänen im Ist-Prozess, persönliche Nutzung von KI-Werkzeugen, erlebte Probleme in Prozess und Tätigkeit, Erwartungen an ein KI-gestütztes Assistenzsystem sowie Vorstellungen möglicher Veränderungen und Bedingungen für die Nutzung (siehe Anhang A.1). Insgesamt wurden neun Interviews innerhalb eines Zeitraums von zwei Wochen mit einer Dauer von 56 bis 91 Minuten geführt. Die Gespräche fanden online über MS Teams statt.

Aufbereitung Die Aufzeichnungen wurden mit der Transkriptionsfunktion von MS Teams automatisiert transkribiert, anschließend manuell korrigiert und in MAXQDA importiert. Erfasst wurde der Wortlaut, nicht aber sprachliche Merkmale wie Pausen, Betonungen oder Füllwörter.

Auswertung Die Auswertung folgte einer reflexiven Thematischen Analyse nach Braun und Clarke (2006, 2019, 2022). Die Kodierung erfolgte induktiv, die Codes wurden somit aus dem Material entwickelt und nicht vorher aus dem Leitfaden oder anderen Vorannahmen abgeleitet. Nach der Familiarisierung mit dem Material wurden die Transkripte abschnittsweise kodiert. Dabei entstanden 125 Codes mit 631 Segmenten. In einem ersten Durchlauf wurden diese zu fünf vorläufigen Themen gruppiert. Anschließend wurden Codes und Themen mehrfach überprüft, zusammengeführt oder umbenannt und Segmente ohne Bezug zur Fragestellung ausgeschlossen. Die finale Struktur umfasst sechs Themen mit 35 Codes sowie einen nicht-thematischen Code für Kontextinformationen zum Angebotsprozess. Insgesamt umfasst sie 499 Segmente. Kodierung und Themenbildung wurden vom Autor allein vorgenommen. Im Sinne der reflexiven Thematische Analyse (TA) sind sie als interpretative Leistung zu verstehen und nicht als Abbildung objektiv vorhandener Kategorien (Braun und Clarke 2019).

3.4.2. Dokumentenanalyse

Die Einbindung historischen Erfahrungswissens setzt Kenntnisse über die vorhandene Datenbasis voraus, die sich aus Interviewaussagen nicht zuverlässig gewinnen lassen. Ergänzend wurde deshalb eine Dokumentenanalyse nach Bowen (2009) durchgeführt. Prozess- und Projektdokumente gelten im Requirements Engineering neben Befragungen als eigenständige Anforderungsquelle (Pohl und Rupp 2010, Kap. 4.1.3). Die Analyse diente außerdem dazu, Interviewaussagen mit der vorhandenen Datenlage abzugleichen. Abweichungen wurden festgehalten.

Erhebung Die Auswahl der Dokumente richtete sich nach der in DocBee verfügbaren Dokumentation und nicht nach einem systematischen Sampling-Verfahren. Einbezogen wurden die im Unternehmen auffindbaren und zugänglichen Dokumente. Der Projektbestand wurde nicht vollständig gesichtet. Die Analyse umfasste folgende Dokumente und Projekte:

- die vom Projektmanagement gepflegte Lessons-Learned-Liste, die als Excel-Datei im Teams-Kanal des Projektmanagements geführt wird;
- ein laufendes Projekt, dessen Daten in DocBee nach der aktuellen Struktur angelegt sind;
- ein abgeschlossenes Projekt, dessen Daten nach einer älteren Struktur angelegt sind;
- zwei weitere historische Projekte aus vergleichbarem Kontext, die ohne Projektleitung durchgeführt wurden.

Die einbezogenen Projekte bilden die im Unternehmen vorhandenen Strukturvarianten ab. Eine repräsentative Auswahl war nicht nötig, da nicht die Häufigkeit einzelner Strukturen untersucht wird, sondern die Form, in der planungsrelevante Informationen vorliegen. Die Sichtung erfolgte vom 10.08.2026 bis zum 31.08.2026.

Angebote wurden nicht einbezogen. Sie sind individuell auf den jeweiligen Kunden zugeschnitten und enthalten keine standardisierten Strukturinformationen. Ihre planungsrelevanten Inhalte gehen bis auf Hardware-, Software- und Lizenzangaben in den Projektstrukturplan über.

Vorgehen Bowen (2009) beschreibt die Dokumentenanalyse als iterativen Prozess aus Sichtung (*Skimming*), gründlicher Durcharbeitung (*Reading*) und Interpretation, ohne die Bildung von Bewertungskategorien festzulegen. Auf eine qualitative Inhaltsanalyse oder thematische Analyse wurde verzichtet, da beide auf Bedeutungsstrukturen in weitgehend unstrukturiertem Material zielen. Die untersuchten Dokumente haben dagegen feste Feldstrukturen oder vorgegebene Hierarchien. Untersucht wurde deshalb, wie vollständig, einheitlich und detailliert diese Strukturen ausgefüllt sind. Für die tabellarische Liste und die hierarchisch gegliederten Projektdaten wurde jeweils ein eigenes Analyseraster entwickelt.

Bei der *Lessons-Learned-Liste* wurden die vorhandenen Felder und ihr Füllgrad, die Form der Einträge (Schlagworte oder Freitext), Redundanzen und der abgedeckte Zeitraum erfasst. Bei den *Projektdokumentationen* aus DocBee wurde untersucht, welche Strukturebenen die Strukturgenerationen enthalten, wie diese gekennzeichnet sind und sich aufeinander abbilden lassen, wo Beschreibungen und erfasste Leistungen vorliegen und wie sich geplante und gebuchte Aufwände zueinander verhalten. Beide Raster dienten dazu, Form und Verlässlichkeit der Daten als mögliche Wissensbasis einzuschätzen, denn beide Quellen werden von den Beteiligten selbst gepflegt und enthalten, was diese für dokumentationswürdig halten. Ein Assistenzsystem, das darauf aufbaut, würde vorhandene Lücken übernehmen. Für jedes Dokument wurde deshalb festgehalten, wer es aus welchem Anlass pflegt und welche Vorgänge darin nicht erfasst werden.

3.4.3. Ableitung der Anforderungen

Die Anforderungen wurden aus den Ergebnissen der Interviews und der Dokumentenanalyse abgeleitet. Ergänzend wurden direkte Rückfragen und der Workshop berücksichtigt

(Abschn. 3.5.3). Die Ableitung erfolgte in zwei Schritten. Zunächst wurden alle Codes der thematischen Analyse und Befunde der Dokumentenanalyse einzeln gesichtet. Aussagen mit einem erkennbaren Bedarf an das System wurden als vorläufige Anforderungen festgehalten, mit ihrer Quelle verknüpft und einer der vier unten beschriebenen Kategorien zugeordnet. So entstand eine Rohliste mit Einzelaussagen. Anschließend wurden inhaltlich gleiche oder eng verwandte Aussagen, auch über Interviews und Dokumentenanalyse hinweg, zu einer Anforderung mit gemeinsamer Kennung gebündelt. Zu jeder Anforderung wurde festgehalten, worauf sie sich stützt.

Pohl und Rupp (2010) unterscheiden funktionale und nicht-funktionale Anforderungen. Funktionale Anforderungen beschreiben das Verhalten des Systems, nicht-funktionale dessen Eigenschaften und Randbedingungen. Einige der erhobenen Anforderungen betreffen jedoch weder das Verhalten noch die Eigenschaften des Systems, sondern dessen Verhältnis zu bestehenden Rollen und Abläufen. Deshalb werden zusätzlich soziotechnische Anforderungen aufgenommen, die Wechselwirkungen zwischen Mensch, Organisation und Technik betreffen (Tessmer 2023). Hinzu kommen prozessuale Anforderungen an das Unternehmen, die im Prototyp nicht umgesetzt werden können. Sie werden dokumentiert, weil die Wirkung des Systems auch von ihnen abhängt, und in Kapitel 5 aufgegriffen.

Nach den Interviews und der Dokumentenanalyse blieben einzelne Befunde offen. Die daraus entstandenen Rückfragen wurden im August 2026 schriftlich mit P1 geklärt, dem Hauptansprechpartner für Fragen zur Arbeit des Projektmanagements. Sie dienten der Klärung von Sachverhalten und nicht der Erhebung von Einschätzungen. Deshalb wurden sie nicht kodiert, sondern den betroffenen Anforderungen zugeordnet und in den Tabellen mit dem Kürzel „R“ ausgewiesen. Da nur eine Person beteiligt war, lassen sich die Auskünfte nicht verallgemeinern. Fragen und Antworten sind in Anhang A.2 dokumentiert.

Jede Anforderung erhält eine eindeutige Kennung (F, NF, ST, P) und Verweise auf ihre Quellen. Die Kennungen dienen auch als Bezugspunkt für die Architekturentscheidungen (Abschn. 3.5.1) und die Evaluation (Abschn. 3.6). Als Quellenkürzel werden Tx für das jeweilige Thema der thematischen Analyse, D für die DocBee-Analyse, LL für die Lessons-Learned-Liste, W für den Workshop und R für die Rückfragen mit P1 verwendet. Der Katalog ist kein abgeschlossenes Lastenheft. Im Sinne des GD (Abschn. 3.1) bildet er den Kenntnisstand nach der Vorstudie ab. Im weiteren Verlauf wurde er mit der Praxis abgeglichen und ergänzt. Der Katalog wird in Abschnitt 4.1.4 dargestellt; die Änderungen durch den Workshop folgen in Abschnitt 4.2.3.

3.5. Prototyping: Vorgehen

Die zweite Phase überführt die Ergebnisse der Vorstudie in einen funktionsfähigen Prototyp. Die Gestaltungsentscheidungen und der daraus entstandene Prototyp werden in Abschnitt 4.2 beschrieben.

3.5.1. Konzeption

Zunächst wurde geprüft, ob bereits lizenzierte Plattformen für KI-Assistenten die abgeleiteten Anforderungen (Abschn. 3.4.3) abdecken oder Lücken aufweisen. Anschließend wurden die Architekturkomponenten anhand der Anforderungen ausgewählt. Wichtige Architekturentscheidungen wurden jeweils auf eine oder mehrere Anforderungen zurückgeführt und durch den Vergleich mit möglichen Alternativen begründet.

3.5.2. Iterative Implementierung

Die Implementierung erfolgte iterativ und begann bereits während der Vorstudie, sodass Erkenntnisse aus späteren Interviews in den Entwurf einfließen konnten. Das entspricht Wulf *et al.* (2015), dass die Phasen einer DCS zwar eine natürliche Reihenfolge haben, aber nicht strikt aufeinanderfolgen. Die Analyse der bestehenden Praxis begleitet demnach Entwurf und Aneignung.

3.5.3. Workshop

Am 11.09.2026 wurde ein Zwischenstand des Prototyps in einem 45-minütigen Workshop mit P1 und P6 besprochen (Tab. 1, Spalte W). Der Workshop war keine Evaluation im Sinne von Abschnitt 3.6, sondern ein Zwischenschritt im Entwurf. Geprüft wurde nicht der Nutzen des Systems, sondern ob die abgeleiteten Anforderungen entsprechend dem Verständnis der Teilnehmenden ausgelegt und umgesetzt worden waren. Das ließ sich anhand des Interviewmaterials allein nicht beurteilen.

Nach einem Austausch über Veränderungen im Unternehmen seit den Interviews wurde für jede Phase des Prototyps zunächst die Erwartung der Teilnehmenden erfragt. Erst danach wurde erläutert, was der Prototyp in dieser Phase tut. So sollte vermieden werden, dass die gezeigte Lösung die Erwartungen beeinflusst. Eine vollständige Vorführung war nicht möglich, da das lokale Sprachmodell vor Ort nicht installiert werden konnte und das Kontingent der externen Modellschnittstelle aufgebraucht war. Die Demonstration erfolgte daher anhand von Erläuterungen zur Oberfläche. Die Rückmeldungen beziehen sich somit auf den gezeigten Aufbau und nicht auf ein laufendes System.

Der Workshop wurde nicht aufgezeichnet. Stattdessen wurden Notizen angefertigt und anschließend ausgearbeitet. Wörtlich festgehaltene Aussagen sind als Zitate gekennzeichnet, alle übrigen als Paraphrasen. Die Ergebnisse werden in Abschnitt 4.2.3 dargestellt.

3.6. Evaluation: Vorgehen & Auswertung

Die dritte Phase umfasst die qualitative Evaluation des Prototyps. Dabei werden die Umsetzung der Anforderungen sowie die Praktikabilität und Relevanz des Prototyps aus Sicht von Fachleuten aus der Praxis untersucht. Der Ansatz folgt der situierten Evaluation nach Twidale *et al.* (1994).

3.6.1. Evaluationsdesign

An der Evaluation nahmen sieben der neun Personen aus der Vorstudie teil (Tab. 1). Die Auswahl war im Rahmen der DCS beabsichtigt, da diese Personen mit dem Angebotsprozess vertraut sind und den Prototyp später einsetzen könnten. Untersucht wurde, ob der Prototyp zur bestehenden Praxis passt.

Wegen der eingeschränkten Verfügbarkeit (Abschn. 3.3.1) war zunächst ein Demo-Video mit schriftlicher Befragung vorgesehen, das ohne gemeinsamen Termin auskommt. Um zusätzlich die tatsächliche Nutzung beobachten zu können, wurde die Evaluation um Live-Sitzungen ergänzt. Daraus ergaben sich zwei Gruppen. In Gruppe A bedienten drei Teilnehmende den Prototyp selbst und konnten daher auch die Bedienbarkeit beurteilen. Angefragt wurden zunächst P1 und P6, die den Prototyp aus dem Workshop kannten (Abschn. 3.5.3) und P3 kam als nächste verfügbare Person hinzu. Eine Person aus dem

Account Management konnte nicht gewonnen werden. Wegen des Aufwands für Protokollierung und Auswertung wurde Gruppe A auf drei Sitzungen begrenzt. Gruppe B sah den Prototyp nur im Video. Die Aussagen ihrer vier Teilnehmenden beziehen sich daher auf Nutzen, Qualität und die erwartete Passung zur eigenen Praxis. Beide Gruppen bearbeiteten dasselbe Szenario und erhielten denselben Interviewleitfaden (Abb. 3, Anhang C). Dadurch lassen sich ihre Aussagen trotz der unterschiedlichen Formate vergleichen.

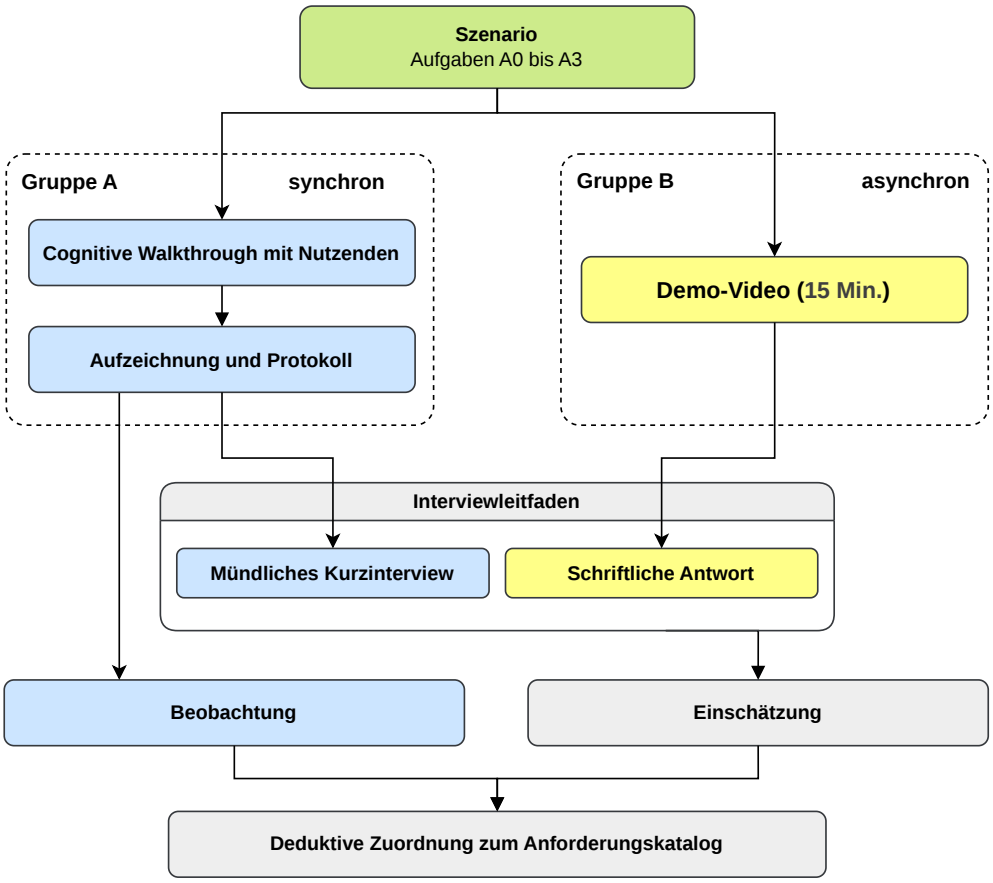


Abb. 3: Evaluationsdesign mit zwei Teilnehmendengruppen

Ablauf Gruppe A: Walkthrough Gruppe A nahm an einem Cognitive Walkthrough mit Nutzenden teil (Mahatody *et al.* 2010). Anders als beim klassischen Cognitive Walkthrough nach Lewis und Wharton (1997), der ohne Beteiligung von Nutzenden auskommt, bearbeiteten die Teilnehmenden die Aufgaben selbst mit dem Prototyp. Der Ablauf umfasste vier Aufgaben. Sie wählten den Einstieg, beschrieben die Anfrage im Dialog mit dem Prototyp, erzeugten und überarbeiteten den Strukturvorschlag und exportierten das Ergebnis. Die Aufgaben wurden zu Beginn mündlich erläutert und gaben nur den Ablauf vor. Innerhalb der Aufgaben erkundeten die Teilnehmenden den Prototyp frei. Während der Bearbeitung wurden sie gebeten, ihre Gedanken laut auszusprechen (*Lautes Denken*) (Boren und Ramey 2000; Mcdonald *et al.* 2012). Die Sitzungen fanden am 18.09.2026 über MS Teams mit Bildschirmfreigabe statt und dauerten einschließlich Kurzinterview 40 bis 50 Minuten.

Die Moderation war zurückhaltend. Anders als bei Kaufhold *et al.* (2024), die nach einem coachingorientierten Ansatz gezielt nachfragten, wurde hier nur bei Bedarf unterbrochen, um die Teilnehmenden nicht zu lenken. Dadurch äußerten sich die Teilnehmenden nicht zu jedem Schritt, etwa weil das Schema ungewohnt war oder während der Bedienung wenig Raum zum Sprechen blieb. Die Aussagen sowie auftretende Hänger und Fehler wurden je Aufgabe protokolliert. Anschließend folgte ein strukturiertes Kurzinterview.

Ablauf Gruppe B: Demo-Video Gruppe B erhielt ein 15-minütiges Demo-Video mit neutralem Voice-over. Es zeigte denselben Aufgabendurchlauf wie bei Gruppe A. Da kein gemeinsamer Termin verfügbar war, beantworteten die Teilnehmenden die Fragen des Interviewleitfadens nach dem Ansehen des Videos schriftlich im Teams-Chat. Dafür hatten sie vom 22. bis 25.09.2026 vier Tage Zeit.

Abweichungen vom geplanten Ablauf Die Durchführung wich in drei Punkten vom Plan ab. Erstens griff der Autor häufiger ein als vorgesehen. Er erklärte Felder der Oberfläche, beantwortete Fragen zur Navigation und zeigte einzelne Bedienelemente. Diese Hilfen sind im Beobachtungsprotokoll vermerkt und gehen in die Bewertung ein. Zweitens kam es in zwei Sitzungen zu einem Timeout des lokal betriebenen Embeddings. Der Grenzwert wurde daraufhin erhöht, bei P1 nach der Sitzung und bei P3 während der Sitzung. Die Sitzungen fanden daher nicht unter identischer Konfiguration statt. Drittens enthielt das Szenario die englische Abkürzung „CIA“ für die Schutzziele, die nicht allen Teilnehmenden bekannt war.

3.6.2. Materialien

Als Szenario diente ein fiktives Kundenprojekt bei einem kommunalen Versorger. Es wurde auf Grundlage der Vorstudie entwickelt und enthält keine realen Kunden- oder Unternehmensdaten (Abschn. 3.3.2). Das Szenario besteht aus einer kurzen Projektanfrage mit grundlegenden Informationen. Angaben, die sich daraus nicht entnehmen ließen, sollten die Teilnehmenden mit „weiß ich nicht“ beantworten. Das Szenario, die mündlich erläuterten Aufgaben und der Interviewleitfaden finden sich in Anhang C.

3.6.3. Auswertung

Die Aufnahmen der Sitzungen mit Gruppe A wurden, wie die Interviews der Vorstudie, transkribiert (Abschn. 3.4.1) und nach Aufgaben (A0 bis A3) segmentiert. Für jede Aufgabe wurde festgehalten, ob sie ohne Hilfe, mit Hilfe oder nicht bearbeitet werden konnte und welche Schwierigkeiten, Fehler und Äußerungen dabei auftraten.

Die Auswertung erfolgte deduktiv entlang des Anforderungskatalogs. Jede Beobachtung und Aussage beider Gruppen wurde der jeweils betroffenen Anforderung zugeordnet. Für jede geprüfte Anforderung wurde ein Ergebnis festgehalten. Eine Anforderung gilt als *erfüllt*, wenn sie in jeder Sitzung, in der sie vorkam, ohne Probleme funktionierte oder bestätigt wurde. *Eingeschränkt erfüllt* ist sie, wenn sie zwar funktionierte, aber nur mit Hilfe, nur bei einem Teil der Teilnehmenden oder mit konkreten Mängeln. *Nicht erfüllt* ist sie, wenn sie im Ablauf scheiterte oder nicht wahrgenommen wurde. Manche Anforderungen lassen sich in einer einzelnen Sitzung nicht beobachten, etwa ein Zeitgewinn im Arbeitsalltag. Sie werden als *erfragt* geführt und stützen sich auf die Einschätzungen der Teilnehmenden. Widersprechen sich Beobachtung und Aussage, gilt die Beobachtung.

4. Design Case Study

4.1. Vorstudie

Die Vorstudie umfasst neun leitfadengestützte Interviews sowie eine Dokumentenanalyse der Lessons-Learned-Liste des Projektmanagements und ausgewählter Projekte in DocBee (Abschn. 3.4). Alle sechs Themen finden sich in jedem der neun Interviews (Abb. 6). T1 bis T4 beschreiben die bestehende Praxis der Angebotsplanung. T5 und T6 fassen die Erwartungen an ein unterstützendes System zusammen.

4.1.1. Ergebnisse der thematischen Analyse

T1: Zeitdruck, verteilte Werkzeuge und steigende Qualitätsanforderungen In allen neun Interviews zeigt sich derselbe Zielkonflikt: Angebote sollen schnell beim Kunden sein, zugleich steigen die Anforderungen an ihre Gliederung. Weniger umstritten ist der Nutzen einer frühen Planung als die Frage, wer die dafür nötige Zeit aufbringt und bezahlt. Projekte ohne vorausgehende Planung seien „meistens schiefgegangen“ (I-P1, Abs. 82), und der Zeitaufwand in der Pre-Sales-Phase gelte als gut investiert (I-P7, Abs. 32). Dieser Aufwand werde jedoch häufig nicht vergütet (I-P8, Abs. 9). Zudem verursache jede weitere beteiligte Person zusätzliche Kosten (I-P2, Abs. 17; I-P3, Abs. 91). Eine zusätzliche Planungsstufe könne deshalb die Vertriebsgeschwindigkeit beeinträchtigen: Je mehr Personen beteiligt seien, desto länger dauere es bis zur Angebotsabgabe (I-P2, Abs. 101). Das Unternehmen gelte bereits als eher langsam. Kunden meldeten zurück, „der Wettbewerb hat schon geschickt“ (I-P9, Abs. 94). Ein Werkzeug dürfe den Prozess daher nicht verlangsamen (I-P9, Abs. 94). Gleichzeitig stehe die Qualität der Leistung derzeit hinter dem Vertriebserfolg zurück (I-P1, Abs. 74). Zugleich steigen die Anforderungen an die Angebotsqualität. Kunden akzeptierten Pauschalpositionen seltener und verlangten eine Gliederung und klare Abgrenzung der Leistung (I-P1, Abs. 74; I-P8, Abs. 39).

Der Strukturplan diene als Grundlage für Leistungsumfang und Kalkulation und solle spätere Nachträge vermeiden (I-P8, Abs. 7). Dafür sei intern eine detaillierte Planung nötig. Wie die Leistung im Angebot dargestellt werde, entscheide dagegen der Vertrieb in Abstimmung mit dem Kunden (I-P1, Abs. 76; I-P3, Abs. 29; I-P9, Abs. 10–12). Der Planungsbedarf wächst somit, während die verfügbare Zeit gleich bleibt. Für die Planung gibt es außerdem keinen festen Ablageort. Relevante Informationen seien auf Teams, E-Mails und DocBee sowie auf Word- und Excel-Vorlagen verteilt (I-P1, Abs. 155; I-P2, Abs. 11; I-P3, Abs. 12; I-P8, Abs. 55). Als wichtigstes Werkzeug nannte eine befragte Person „mein Gehirn“ (I-P9, Abs. 28). In acht Interviews wurde ein Werkzeug für die Projektplanung vermisst. Es gebe weder Vorlagen noch eine Wissensbasis, sodass jede Planung von Neuem beginne (I-P5, Abs. 29). Auch fehle ein gemeinsamer Ort, an dem der Plan mit den Consultants bearbeitet werden könne (I-P5, Abs. 51). Eine selbst entwickelte Projektmanagement-Software sei bereits im Aufbau (I-P4, Abs. 77; I-P5, Abs. 11).

Für den Prototyp ergeben sich daraus zwei Anforderungen. Er darf den Angebotsprozess nicht verlangsamen und muss intern eine detaillierte Gliederung liefern. Wie diese im Angebot dargestellt wird, entscheidet der Vertrieb in Abstimmung mit dem Kunden.

T2: Verteiltes Wissen und Koordination im Angebotsprozess Das Wissen für einen Strukturplan und die Verantwortung für seine Ausarbeitung liegen bei unterschiedlichen Rollen. In allen neun Interviews wurde die fachliche Einschätzung den Consultants zugeschrieben, die Produkte und den Dienstleistungsumfang auswählen (I-P2, Abs. 7).

Ohne ihren Beitrag reichten die verfügbaren Informationen für einen Strukturplan nicht aus (I-P5, Abs. 13, 15). Die Projektleitung sehe sich dagegen als koordinierende Instanz. Sie sei „nicht schlauer als die Consultants“ und behalte vor allem den Zeitplan im Blick (I-P3, Abs. 14; I-P5, Abs. 4). Häufig werde zunächst nur eine Gesamtzahl weitergegeben. Eine genauere Gliederung müsse dann angefragt werden und werde teilweise direkt als Arbeitspaket übernommen, „um überhaupt schon mal 'ne Struktur zu haben“ (I-P1, Abs. 12–13; I-P2, Abs. 92). Außerdem sei die Person, die den Aufwand schätzt, oft nicht an der Umsetzung beteiligt (I-P1, Abs. 38, 43).

Auch der Zeitpunkt der Einbindung verstärkt diese Verteilung. Zwar sei vorgesehen, die Projektleitung früh einzubeziehen (I-P3, Abs. 8), in fünf Interviews wurde jedoch berichtet, dass sie meist erst nach Auftragseingang hinzukomme (I-P1, Abs. 10, 72; I-P2, Abs. 15; I-P3, Abs. 8; I-P4, Abs. 10; I-P5, Abs. 8–9). Die Abstimmung finde dadurch erst nach der Beauftragung statt. Tatsächlich werde der Strukturplan häufig erst beim internen Kickoff mit den Consultants fertiggestellt (I-P4, Abs. 8, 46). Teilweise sei unklar, wer wofür verantwortlich ist (I-P3, Abs. 37–39). Ob ein Projekt überhaupt eine Projektleitung erhält, richte sich nach Umfang und Komplexität sowie nach den Ansprechpersonen auf Kundenseite (I-P2, Abs. 72; I-P9, Abs. 14, 22). Fehle eine Projektleitung, teilten sich Consultants und Account Management die Planungsverantwortung (I-P6, Abs. 11; I-P9, Abs. 24).

Der Strukturplan entsteht im Zusammenspiel der Rollen und meist erst nach Auftragserteilung. Das Problem liegt somit weniger im fehlenden Wissen als darin, dass es während der Angebotsplanung nicht bei allen Beteiligten verfügbar ist. Ein früher Entwurf könnte der Projektleitung den Einstieg erleichtern, ohne die fachliche Einschätzung der Consultants zu ersetzen. P5 zufolge könnten dadurch die ersten Abstimmungstermine entfallen. Eine gemeinsame abschließende Durchsicht bliebe jedoch nötig (I-P5, Abs. 61).

T3: Undokumentiertes Erfahrungswissen als Planungsgrundlage Das Erfahrungswissen für die Planung ist meist implizit und an einzelne Personen gebunden. Consultants gingen die nötigen Arbeitsschritte gedanklich durch und leiteten daraus „Pi mal Daumen“ eine Stundenzahl ab (I-P1, Abs. 15). Erfahrungswerte zu wiederkehrenden Vorhaben seien „noch nirgendwo dokumentiert“ (I-P5, Abs. 13), und ein Strukturplan werde „jedes Mal aktuell von 0“ erstellt (I-P1, Abs. 31). Was dennoch dokumentiert werde, liege meist in persönlichen Ablagen, vor allem in OneNote (I-P1, Abs. 27; I-P3, Abs. 10; I-P5, Abs. 11; I-P8, Abs. 11). Trotzdem würden in Angeboten immer wieder Komponenten wie Transceiver oder Kabel vergessen, selbst wenn Erfahrungswerte und Checklisten vorlägen (I-P2, Abs. 40, 58).

Die Bereitschaft, Wissen zu teilen, sei dagegen hoch (I-P1, Abs. 128; I-P5, Abs. 98–99). Ein Prozess zur Sicherung von Lessons Learned bestehe zwar, werde laut übereinstimmenden Aussagen in acht Interviews aber kaum umgesetzt. Die zentrale Liste werde vermutlich seit einigen Monaten nicht mehr gepflegt (I-P1, Abs. 27). Außerdem fehle ein fester Zeitpunkt im Projektablauf, um Erkenntnisse festzuhalten (I-P4, Abs. 67–68). Als Grund dafür wurde die hohe Auslastung genannt: Mit dem Projektabschluss beginne bereits das nächste Projekt (I-P4, Abs. 64–65). Das Dokumentieren habe „weniger mit Wollen zu tun“ als mit der zeitlichen Priorisierung (I-P5, Abs. 100–101). Wissen werde stattdessen vor allem mündlich, in Chats und Besprechungen geteilt (I-P2, Abs. 54; I-P9, Abs. 53–55). Auch dokumentiertes Wissen werde bei der Planung selten genutzt. Eine befragte Person fragte sich, wer später tatsächlich in eine solche Dokumentation schaue. Ein früheres Wiki zu einer nicht mehr angebotenen Software werde heute nicht mehr auf-

gerufen. Sei die Dokumentation gut nutzbar, würde man sich aber auch die Mühe machen (I-P7, Abs. 48, 56). Erfahrungswissen geht somit sowohl beim Dokumentieren als auch bei seiner späteren Nutzung für die Planung verloren. Der Prototyp sollte deshalb vorhandenes Erfahrungswissen während der Planung zugänglich machen, ohne zusätzlichen Dokumentationsaufwand zu verursachen.

T4: Umgang mit Vorgaben und Standardisierung Das vierte Thema beschreibt ein Spannungsfeld im Umgang mit festen Strukturen. Sie werden begrüßt, wenn sie Orientierung geben und Prioritäten setzen, aber abgelehnt, wenn sie den Handlungsspielraum einschränken. Teilweise kommen beide Sichtweisen im selben Interview vor. Eine Person beschrieb die eigene Arbeitsweise als „sehr viel implizit“ und verwies auf den bisherigen Projekterfolg. Kurz darauf sagte sie: „ich bin Fan von Deadlines“, weil diese bei hoher Auslastung Prioritäten setzten (I-P6, Abs. 17–18). Eine andere Person hielt Struktur und Dokumentation zwar vom „Kopf“ her für „klug“, sie erreichten „Herz und Bauch“ aber meist nicht (I-P9, Abs. 59).

Auch organisatorisch gelte die Gestaltungsfreiheit der Einzelnen als Grundlage des bisherigen Erfolgs. Entsprechend stießen Versuche, Prozesse zu vereinheitlichen, auf Widerstand. Vertrieb und Consulting wollten selbst bestimmen, mit welchen Ansprechpersonen sie arbeiteten, und die Verantwortung für das Sizing behalten (I-P1, Abs. 65–66).

Ein Befragter sprach sich für verbindlichere Standards aus. Er verwiest auf Quality Gates aus einem früheren Arbeitsumfeld (I-P5, Abs. 43), auf den fehlenden „sauberen Prozess“ zur Erstellung von Strukturplänen (I-P4, Abs. 110) und auf eine mögliche Nutzungspflicht für größere Projekte (I-P6, Abs. 82). Im selben Interview wurde allerdings auch die Erwartung geäußert, dass sich ein gutes Werkzeug ohne Pflicht „automatisch durchsetze“ (I-P6, Abs. 82). Einer einheitlichen Standardisierung steht die Vielfalt der Projekte und Arbeitsweisen entgegen: Hersteller, Vorgehen und Benennungen unterschieden sich (I-P2, Abs. 90), und ein Teil der Aufgaben sei kundenspezifisch (I-P5, Abs. 61). Der Prototyp sollte eine Struktur anbieten, ohne ihre Nutzung vorzuschreiben. Die Planenden sollen selbst entscheiden können, ob das Werkzeug für sie nützlich ist. Das gilt auch für die Darstellung im Angebot (I-P9, Abs. 11).

T5: Erwartete Funktionen des KI-gestützten Planungssystems Die Befragten erwarteten ein Werkzeug, das früh einen groben Ausgangspunkt erstellt und so die spätere Abstimmung vorbereitet. Erfahrungen mit KI waren bereits vorhanden: In acht Interviews berichteten die Befragten, allgemeine KI-Werkzeuge informell zu nutzen. Mehrere setzten sie bereits für erste Entwürfe, Vorlagen oder Grobstrukturen ein (I-P1, Abs. 51; I-P4, Abs. 25; I-P5, Abs. 21; I-P8, Abs. 11).

Als Mehrwert gegenüber diesen Werkzeugen wurde die Wiederverwendung abgeschlossener Projekte genannt (I-P3, Abs. 83–84). Viele grundlegende Tätigkeiten wiederholten sich bei unterschiedlichen Kunden. Ein gemeinsamer Wissensspeicher solle deshalb typische Tätigkeiten, Lessons Learned und Auswertungen der tatsächlichen Dauern enthalten (I-P5, Abs. 19, 59–60; I-P2, Abs. 97; I-P7, Abs. 74). Als mögliche Datenquelle wurde DocBee genannt (I-P8, Abs. 55, 57).

Der Entwurf solle schrittweise vom Groben zum Feinen aufgebaut werden. Die erste Ebene solle Themengebiete beziehungsweise Skill-Teams abbilden (I-P4, Abs. 11, 36). Für die Angebotsphase reiche ein grober Rahmen. Nach der Auftragserteilung solle die Detailplanung gemeinsam mit den Consultants folgen (I-P2, Abs. 26; I-P8, Abs. 9, 41). Technische

Abhängigkeiten, die bislang nicht geplant würden, sollten als Reihenfolge ohne feste Termine dargestellt werden (I-P7, Abs. 6; I-P9, Abs. 72; I-P2, Abs. 85–86; I-P3, Abs. 71). Das Werkzeug solle entsprechend früh zum Einsatz kommen. Vertrieb und Consultants könnten selbst einen Entwurf erstellen, ohne die Projektleitung einzubeziehen (I-P1, Abs. 147; I-P4, Abs. 92). Eine Prüfung durch die Projektleitung solle noch vor der Auftragserteilung stattfinden (I-P3, Abs. 81). Das Ergebnis sei als „Kalkulationsgrundlage“ gedacht. Es dürfe zunächst grob sein und solle ein bis zwei Seiten umfassen (I-P8, Abs. 22; I-P6, Abs. 63). Dafür genügten wenige Angaben, etwa Kunde, Projektkategorie, grober Inhalt und Zeitrahmen sowie, falls bekannt, Hardware oder wirtschaftliche Metadaten (I-P1, Abs. 100; I-P5, Abs. 23–25; I-P6, Abs. 71).

Für den Prototyp ergeben sich daraus drei Ziele. Er soll Vorlagen aus abgeschlossenen Projekten nutzen, den Plan vom Groben zum Feinen aufbauen und eine Erstplanung ohne Projektleitung ermöglichen. Das Ergebnis dient als Kalkulationsgrundlage und nicht als fertiger Plan.

T6: Voraussetzungen für die Nutzung KI-generierter Projektstrukturpläne
Das sechste Thema behandelt die Bedingungen, unter denen die Befragten einen KI-generierten Entwurf nutzen würden. Die Idee wurde überwiegend positiv aufgenommen (I-P5, Abs. 61; I-P6, Abs. 61). P7 sehe eine Stärke des Systems darin, dass es an Punkte denken könne, die sonst übersehen würden (I-P7, Abs. 80).

Alle neun Befragten nannten einen Zeitgewinn als Voraussetzung für die Nutzung. Er müsse größer sein als der Prüf- und Korrekturaufwand. Ein Werkzeug, das „mehr Zeit kostet als bringt“, sei ein Ausschlusskriterium (I-P6, Abs. 106). Prüfen und korrigieren könnten schnell mehr Aufwand verursachen als die eigene Erstellung (I-P1, Abs. 90). Für einen ersten Entwurf sei eine halbe Stunde als Obergrenze genannt worden (I-P4, Abs. 81) und fehlende Angaben seien falschen vorzuziehen, indem „lieber zu wenig als was Falsches“ erstellt wird (I-P6, Abs. 66). Gegenüber einer KI sei die Fehlertoleranz zudem deutlich geringer als gegenüber Kolleginnen und Kollegen (I-P9, Abs. 39). Bei fehlender Grundlage müsse das System sicherstellen, dass es „nichts erfinde“ (I-P1, Abs. 94). Schon ein grober Entwurf könne hilfreich sein (I-P4, Abs. 123), solange er schlüssig wirke. Was genau diese Plausibilität ausmacht, ließ sich jedoch kaum näher beschreiben (I-P3, Abs. 66–67, 71). Quellen sollten vor allem dabei helfen, Fehler nachzuvollziehen, und nicht nur Vertrauen schaffen (I-P4, Abs. 112).

Auch bei der Erfassung kommt es auf dieses Verhältnis an. Rückfragen seien willkommen, solange sie nicht selbst zu zusätzlichem Aufwand führen. Die Befragten bevorzugten ein dialogisches System, das bei Unsicherheiten nachfragt, statt die Eingabe „stumpf“ umzusetzen. Ein Formular galt dafür als zu steif (I-P6, Abs. 71; I-P7, Abs. 96; I-P8, Abs. 65). Die Zahl der Rückfragen solle jedoch begrenzt bleiben, etwa auf zwei bis drei Stufen (I-P8, Abs. 67), und sie sollten sich auf konkrete Angaben statt auf allgemeine Checklisten beziehen (I-P9, Abs. 80). Manche Fragen müssten erst mit Consultants geklärt werden, was den Ablauf verzögern könne (I-P3, Abs. 112–115). Zwei Befragte sahen dagegen ein standardisiertes Formular als geeigneten Einstieg (I-P3, Abs. 118–119; I-P5, Abs. 79). Den meisten Befragten war wichtig, dass der Einstieg leichtfällt. Das Werkzeug solle intuitiv bedienbar sein (I-P2, Abs. 84; I-P8, Abs. 71; I-P9, Abs. 72). Eine Projektmanagement-Software, für die zunächst eine Schulung nötig sei, werde in dieser frühen Phase kaum akzeptiert (I-P2, Abs. 88). Eine Eingabe per Sprache und auf mobilen Endgeräten wurde nur in einem Interview gefordert, dort jedoch ausdrücklich (I-P9, Abs. 74).

Neben den funktionalen Erwartungen äußerten die Befragten auch Vorbehalte. Nutzende könnten sich mit der Zeit „blind drauf verlassen“ und Ergebnisse nicht mehr hinterfragen (I-P7, Abs. 30). Berufseinsteigende könnten dadurch weniger Gelegenheit haben, den Umgang mit ungelösten Problemen einzuüben (I-P7, Abs. 26). Außerdem scheitere die Einführung neuer Werkzeuge häufig daran, dass die späteren Nutzenden vorher nicht einbezogen würden (I-P2, Abs. 103). Diese Bedingungen bilden den Maßstab für die Evaluation: Das System soll gegenüber der manuellen Erstellung Zeit sparen, fehlende Angaben offenlassen, statt zu erfinden, Quellen bei Bedarf anzeigen und begrenzte Rückfragen im Dialog ermöglichen, die sich überspringen lassen.

4.1.2. Ergebnisse der Lessons-Learned-Liste

Die Liste umfasste zum Zeitpunkt der Sichtung 33 Einträge aus dem Zeitraum von Dezember 2025 bis Mai 2026 (Abschn. 3.4.2).

Felder und Füllgrad Jeder Eintrag enthält Titel, Beschreibung und Maßnahme als Freitext. Projektart, Projektphase und Skill-Team sind als Kategorien erfasst. Hinzu kommen Angaben zu Projekt, Kunde, Projektleitung, eintragender Person und Eintragungsdatum. Bis auf einen Eintrag sind diese Felder vollständig ausgefüllt. Nur das Feld „Kategorie (Test-Phase)“ ist lückenhaft und mit schwer deutbaren Werten wie „Leer“ oder „Organisatorisch“ gefüllt. Es stammt nach Auskunft des Projektmanagements aus einem früher erprobten Kategorisierungskonzept und wurde nach dessen Test nicht bereinigt (R-P1, 11.08.). Die Freitexte eignen sich für eine inhaltliche Suche, die Kategorien für eine Eingrenzung.

Redundanzen Inhaltlich überschneiden sich mehrere Einträge. Das passt zur Einschätzung aus den Interviews, dass sich in der Liste „viel wiederholt“ (I-P5, Abs. 33). Ein Eintragspaar ist ein **Duplikat**, das dieselbe Situation, Ursache und Maßnahme in derselben Projektphase doppelt erfasst. Andere Einträge bilden **thematische Cluster**. Sie beschreiben dasselbe Problem in unterschiedlichen Situationen und zeigen, welche Themen Projektleitende wiederholt für dokumentationswürdig hielten.

Zeitraum und Entstehung Zwischen dem 5. Februar und dem 5. Mai 2026 wurden nur zwei Einträge ergänzt. Nach dem letzten Eintrag am 11. Mai kam bis zur Sichtung am 10. August kein weiterer hinzu. Aus den Daten allein lässt sich nicht klären, ob es keine weiteren Vorkommnisse gab oder ob die Liste nicht mehr gepflegt wurde. Auf Rückfrage hieß es, es „kommt alles zusammen“, darunter fehlende Awareness und wenige Lessons Learned (R-P1, 11.08.). Das deckt sich mit den Interviews (T3). Da die Projektleitung die Liste selbst pflegt und einträgt, was ihr dokumentationswürdig erscheint und wofür Zeit bleibt, bildet die Liste keine vollständige Problemhistorie ab.

Die Liste lässt sich als Wissensquelle durchsuchen, enthält aber doppelte und nur ausgewählte Einträge. Bei der Ausgabe sollten gleiche Treffer zu einem Hinweis zusammengefasst werden, der auf die zugrunde liegenden Einträge verweist. Cluster bleiben getrennt, da sie unterschiedliche Situationen beschreiben (F-13). Lessons Learned sind als Hinweise und nicht als vollständige Risikoliste darzustellen.

4.1.3. Ergebnisse der Projektdatenanalyse aus DocBee

Datenmodell und Zielstruktur In DocBee sind alle Ebenen eines Projektstrukturplans als Objekte derselben Klasse („Vorgang“) mit identischem Feldschema abgebildet.

Gebuchte Zeiten auf die Projekte liegen als eigene Leistungsdokumente vor. Die Ebenenzugehörigkeit ergibt sich nicht aus dem Datenmodell, sondern aus frei vergebbaren Tags und hierarchischen Verknüpfungen zwischen Vorgängen (Abb. 4). Vorgänge, Verknüpfungen und Leistungsdokumente lassen sich über eine REST-Schnittstelle auslesen, sodass sich die Struktur eines Projekts schrittweise rekonstruieren lässt. Die Zielstruktur sei im Vorjahr eingeführt worden und gehe auf Kundenanforderungen und interne Anforderungen zurück (I-P1, Abs. 6). Hauptvorgang, Leistungsbereich und Aufgabe seien verbindlich. Arbeitspakete bildeten eine optionale Zwischenebene. Zeiten sollten ausschließlich auf Aufgaben gebucht werden (R-P1, 31.08.). Ohne Arbeitspakete liegen Aufgaben direkt unter dem Leistungsbereich. Offen blieb, ob beides innerhalb eines Leistungsbereichs nebeneinander vorkommen darf. Das Beispiel aus der Rückfrage zeigt diese Anordnung (Anhang A.2), die Interviews beschreiben dagegen Aufgaben durchgängig unter Arbeitspaketen (I-P1, Abs. 88; I-P3, Abs. 23; I-P5, Abs. 6).

```
Vorgang: „Managed Projekt | Hauptvorgang"-Tag
└─ Vorgang: „Managed Projekt | Leistungsbereich"-Tag
   ├─ Vorgang: „Managed Projekt | Aufgabe"-Tag
   │  └─ Leistungsdokumente: gebuchte Zeiten und Tätigkeiten
   └─ Vorgang: „Managed Projekt | Aufgabenpaket"-Tag
      └─ Vorgang: „Managed Projekt | Aufgabe"-Tag
         └─ Leistungsdokumente: gebuchte Zeiten und Tätigkeiten
```

Abb. 4: Zielstruktur eines Projekts in DocBee über Tags und hierarchische Verknüpfungen. Das in DocBee als „Aufgabenpaket“ bezeichnete Element entspricht dem Arbeitspaket.

Strukturgenerationen Betrachtet wurden drei Strukturgenerationen von Projekten. Das **aktuelle Projekt** folgt der Zielstruktur und ist der eigens eingeführten Kategorie „Managed Projekt“ zugeordnet. Es gliedert sich in fünf Leistungsbereiche, 16 Arbeitspakete und 46 Aufgaben. Vier Leistungsbereiche entsprechen fachlichen Themengebieten des Vorhabens, der fünfte erfasst interne, nicht fakturierbare Zeiten. Wie im Beispiel aus der Rückfrage liegen Aufgaben teilweise direkt unter einem Leistungsbereich. Alle Vorgänge sind terminiert und mit einer Aufwandsschätzung versehen. Abweichend von der Vorgabe hängen Leistungsdokumente nicht nur an Aufgaben, sondern auch an Arbeitspaketen und Leistungsbereichen (etwa den internen Zeiten). Das **historische Projekt mit Projektleitung** trägt ältere strukturbezogene Tags („Projekthauptvorgang“, „Projektvorgang“) und umfasst nur zwei Ebenen. Unter dem Hauptvorgang liegen vier Leistungsbereiche, darunter unmittelbar die Leistungsdokumente. Aufwandsschätzungen sind nur für die Leistungsbereiche hinterlegt. Die beiden **historischen Projekte ohne Projektleitung** wurden laut dem erfassten Ersteller nicht manuell angelegt, sondern automatisch aus dem ERP-System erzeugt. Sie haben keine strukturbezogenen Tags, unter dem Hauptvorgang liegen unmittelbar die Leistungsdokumente.

Beschreibungen Für Beschreibungen stehen ein öffentliches und ein internes Feld zur Verfügung. Das öffentliche Feld enthält durchgehend nur den Titel. Im aktuellen Projekt enthält das interne Feld strukturierte Tätigkeitslisten und einen Verweis auf den Kundenauftrag. Der Inhalt reicht von einer ausführlichen Liste mit Hardware und Stundenkontingenten bis zu einem bloßen Verweis auf den Auftrag. Beschrieben ist dabei faktisch der Leistungsbereich. Liegen Arbeitspakete darunter, tragen sie innerhalb eines Leistungs-

bereichs dieselbe Beschreibung, obwohl sie unterschiedliche Aufgaben umfassen. Liegen darunter ausschließlich Aufgaben, enthält der Leistungsbereich selbst die Beschreibung. Aufgaben haben meist keine eigene Beschreibung, sondern nur die zugehörigen Leistungsdokumente. Diese zeigen die Ausführung, nicht die Planungsabsicht. In den historischen Projekten folgen die Beschreibungen einem einheitlichen Schema aus Auftragsdaten, benötigter Hardware und verkauften Stundenkontingenten und sind innerhalb eines Projekts identisch.

Aufwände Geschätzte und gebuchte Aufwände liegen beide vor und lassen sich abgleichen. Nach Auskunft des Projektmanagements wird in ganzen Tagen geschätzt. Die Schätzung dient dem Kunden als Planungswert, abgerechnet wird nach dem tatsächlichen Aufwand und Abweichungen werden erwartet (R-P1, 31.08.). Beim historischen Projekt mit Projektleitung lagen die gebuchten Aufwände in allen vier Leistungsbereichen unter der Schätzung, bei den automatisch erzeugten Projekten darüber, in einem Fall um mehr als ein Drittel (336 geschätzte gegenüber rund 460 gebuchten Stunden). Systematische Abweichungen lassen sich aus der kleinen Fallzahl nicht ableiten. Als verlässliche Referenz taugen die historischen Schätzungen aber nicht. Gebuchte Zeiten sind in den Leistungsdokumenten einzelnen Mitarbeitenden zugeordnet.

Folgerung Der Leistungsbereich ist die einzige Zwischenebene, die über mehrere Strukturgenerationen hinweg vorkommt. Bei den automatisch erzeugten Projekten fehlt diese Ebene ganz. Ein System muss daher sowohl flache als auch mehrstufige Vorlagen verarbeiten und die Ebenen anhand der Tags bestimmen. Beschreibungen auf Aufgabenebene, die für die Abgrenzung der Leistung nötig wären, fehlen in den Daten. Historische Aufwände können nur als Orientierung dienen. Da sie einzelnen Mitarbeitenden zugeordnet sind, dürfen sie nicht personenbezogen ausgewertet werden. Eine datenschutzrechtliche Prüfung dieser Nutzung ist nicht Gegenstand der Arbeit.

4.1.4. Ableitung der Anforderungen

Aus den Ergebnissen wurden nach dem in Abschnitt 3.4.3 beschriebenen Vorgehen 43 Anforderungen in vier Kategorien abgeleitet (Tabellen 2 bis 5). Die Anforderungen sind über ihre Quellen auf die Befunde zurückgeführt. Im Text werden nur jene erläutert, deren Ableitung nicht unmittelbar aus diesen Quellen hervorgeht oder die für die weitere Arbeit zentral sind. F-20 und NF-09 überschreiten den Rahmen dieser Arbeit. Sie werden dokumentiert, aber nicht umgesetzt, und in Abschnitt 5.4 wieder aufgegriffen.

Funktionale Anforderungen Die funktionalen Anforderungen betreffen die Erfassung der Projektinformationen, das Auffinden vergleichbarer Vorgänge, die Erzeugung der Struktur und den Umgang mit Unsicherheit (Tab. 2).

F-04 beschreibt einen Zielzustand, den die vorhandenen Daten nicht abbilden. Beschreibungen auf Aufgabenebene werden benötigt, weil die schätzende und die umsetzende Person häufig nicht identisch sind (T2) und Kunden eine Abgrenzung der Leistung fordern (T1). In DocBee sind Aufgaben dagegen in der Regel nicht beschrieben. Beschreibungen liegen nur auf Ebene der Leistungsbereiche oder identisch auf allen Arbeitspaketen eines Leistungsbereichs vor. F-07 und F-09 folgen aus T6. Auch die Befragten, die ein standardisiertes Formular befürworten, stützen eine *geführte* Erfassung. F-15 berücksichtigt zwei Befunde. In der frühen Phase bleiben die Eingaben grob (T5), und historische Vorlagen reichen teilweise nur bis zur Ebene der Leistungsbereiche (Abschn. 4.1.3). F-17 folgt

aus der übereinstimmenden Erwartung, eine erkennbare Lücke einer plausibel wirkenden, aber unbelegten Angabe vorzuziehen. Hinzu kommt die geringe Fehlertoleranz gegenüber KI-Ergebnissen (T6).

Nicht-funktionale Anforderungen Die nicht-funktionalen Anforderungen betreffen überwiegend die Bedingungen, unter denen das System im Arbeitsalltag genutzt würde (Tab. 3).

Die Zeitvorgabe in NF-01 dient als Orientierung und nicht als harte Grenze. NF-07 und NF-08 wurden in den Interviews kaum thematisiert. Beide ergeben sich daraus, dass die Datenquellen personenbezogene Informationen enthalten. Die Lessons-Learned-Liste enthält die Namen der Projektleitung und der eintragenden Person. DocBee enthält die gebuchten Zeiten einzelner Mitarbeitender. NF-08 greift außerdem die Sorge auf, dass Aufwände einzelnen Personen zugeordnet und verglichen werden könnten (I-P7, Abs. 86).

Soziotechnische Anforderungen Die soziotechnischen Anforderungen beschreiben, wie sich das System zu den bestehenden Rollen und Zuständigkeiten verhält. Sie ergeben sich überwiegend aus den Themen zur Koordination und zum Umgang mit Vorgaben und betreffen Arbeitsteilung und Entscheidungsbefugnisse (Tab. 4).

Prozessuale Anforderungen Einen Teil der beobachteten Probleme kann Software nicht lösen. Nach T3 scheitert die Dokumentation von Erfahrungswissen vor allem an der Auslastung (I-P4, Abs. 73), und diese Praxis verändert ein Werkzeug nicht von selbst. Die prozessualen Anforderungen beschreiben die dafür nötigen Rahmenbedingungen (Tab. 5). Der Prototyp setzt sie nicht um. Sie werden in Kapitel 5 aufgegriffen.

4.2. Konzeption

Die Vorstudie zeigt, dass in der Angebotsphase kein vollständiger Projektstrukturplan erwartet wird. Benötigt wird eine strukturierte Arbeitsgrundlage, die die Verantwortlichen weiterbearbeiten können (T2, T5; F-01, ST-05). Der Prototyp soll dafür das nötige Wissen gezielt erfragen und um Erfahrungswissen aus abgeschlossenen Projekten ergänzen (T3). So soll ein erster Entwurf auch ohne Beteiligung der Projektleitung entstehen (ST-01, ST-02). Das Ergebnis ist ein internes Arbeitsdokument (ST-06). Die Quellsysteme werden nicht angebunden (NF-09). Stattdessen nutzt der Prototyp synthetische Daten in der Struktur dieser Systeme (Abschn. 3.3.2).

Tabelle 6 ordnet jeder Anforderung aus Abschnitt 4.1.4 ein Designziel zu.

4.2.1. Entwurfsentscheidungen

Anwendung statt Plattform Zunächst wurde geprüft, ob die im Unternehmen vorhandenen KI-Werkzeuge die Anforderungen abdecken (Abschn. 3.5.1). Vorhanden sind ein Suchindex über Azure AI Search, der bisher ausschließlich abgeschlossene Support-Tickets erfasst, ein MCP-Server mit Zugang zu DocBee sowie Automatisierungen über Power Automate. Auch ein Low-Code-Workflow wurde verworfen, da die je Anfrage verketteten Modellaufrufe und Suchen in der Wissensbasis lange Laufzeiten erwarten ließen. Der Prototyp ist daher eine eigenständige Anwendung.

Workflow statt Agenten Der Mensch behält die Verantwortung für den Entwurf (ST-03; T4, T6), da die Fehlertoleranz gegenüber KI-Ergebnissen gering ist und eine ungeprüfte

Übernahme befürchtet wird (T6). Zudem soll der Entwurf die anschließende Abstimmung vorbereiten, nicht vorwegnehmen (ST-05; T2). Ein autonomer Agent, der Lösungswege, Werkzeugaufrufe und Zwischenschritte selbst wählt, würde die Auslagerung im Sinne des *Cognitive Offloading* bereits im System anlegen (Abschn. 2.3). Die inhaltliche Auseinandersetzung mit den Kundenanforderungen könnte so an das System übergehen. Der Workflow ist daher im Programmcode festgelegt: Das System kann keine Schritte überspringen, keine zusätzlichen Werkzeuge heranziehen und den Workflow nicht umstellen. Innerhalb des Workflows wird die Aufgabe nicht über eine einzelne Anfrage gelöst, sondern als Kette von Teilschritten (Abschn. 2.2.3). Im Prototyp sind dies die Projektbeschreibung und der Strukturplan, die Nutzende jeweils bearbeiten können, bevor sie in den nächsten Schritt eingehen. Zudem können Kontextdaten, etwa die Ergebnisse der Suche in der Wissensbasis, so zu bestimmten Zeitpunkten eingebracht und verarbeitet werden.

Der Entwurf legt außerdem fest, welche Aufgaben das Sprachmodell übernimmt. Der Programmcode steuert die Reihenfolge der Schritte und prüft Eigenschaften, die sich maschinell prüfen lassen, wie beispielsweise die Einhaltung des Datenmodells. Das Sprachmodell bearbeitet sprachliche Aufgaben. Diese Aufteilung macht den Ablauf vorhersehbar. Nutzende können dadurch nachvollziehen, wie der Entwurf entsteht, und ihn schrittweise korrigieren (ST-03, F-18).

4.2.2. Phasen des Workflows

Der Workflow gliedert sich in drei Phasen (Abb. 7 im Anhang): Die Beschreibungsphase zur Erfassung der Projektbeschreibung, die Planungsphase zur Erstellung des Projektstrukturplans und die Exportphase.

Beschreibungsphase Die erste Phase erfasst die Projektbeschreibung. F-08 legt die Mindestangaben fest, F-07 verlangt Freitext statt eines Formulars, und F-09 beschränkt Rückfragen auf fehlende Angaben und hält sie begrenzt und überspringbar. Im Dialog fasst das Sprachmodell die Angaben fortlaufend zu einer Projektbeschreibung zusammen, prüft sie gegen die Mindestangaben und fragt gezielt nach dem, was fehlt. Den vollständigen Fragenkatalog stellt es nicht auf einmal, da in der Vorstudie vor einer zu umfangreichen Abfrage gewarnt wurde (T6). Angaben, die Nutzende nicht kennen oder überspringen, werden als offen vermerkt (F-15, F-17). Da die Mindestangaben im Systemprompt und nicht als Formular hinterlegt sind, kann das Modell Angaben in beliebiger Reihenfolge aufnehmen und an bereits Gesagtes anknüpfen.

Die Beschreibung ist zugleich die Grundlage für alle Suchanfragen an die Wissensbasis und begrenzt damit die Genauigkeit der nachgelagerten Schritte. Gao *et al.* (2023) beschreiben die Aufbereitung einer Anfrage vor der Suche als eigenen Schritt fortgeschrittener RAG-Architekturen. Im Prototyp wird die Anfrage gemeinsam mit den Nutzenden aufbereitet, nicht automatisch. Ob diese Erfassung den Aufwand tatsächlich senkt (NF-01, NF-02), wird in der Evaluation erfragt (Abschn. 4.4).

Planungsphase Bei jeder Anfrage umfasst die Planungsphase vier Schritte (Abb. 7).

Zuerst entsteht eine *Grobgliederung* in Leistungsbereiche ohne Aufgaben, Nummerierung oder Aufwände (F-05). Das entspricht dem erwarteten Aufbau vom Groben zum Feinen, bei dem die erste Ebene nach Themengebieten gebildet wird (T5). Die Grobgliederung wird nicht angezeigt, sondern dient nur als Suchanfrage. So müssen die Nutzenden kein weiteres Zwischenergebnis prüfen, und die Ausgabe bleibt auf Beschreibung und Entwurf

beschränkt (NF-05). Liegt bereits ein Entwurf vor, treten dessen Leistungsbereiche an die Stelle der Grobgliederung, sodass auch manuelle Änderungen die weitere Suche steuern.

Im **zweiten** Schritt wird für jeden Leistungsbereich nach vergleichbaren Leistungsbereichen abgeschlossener Projekte (F-10) und nach passenden Lessons Learned (F-11) gesucht. Such- und Indexeinheit ist der Leistungsbereich, da nur auf dieser Ebene unterscheidbare Beschreibungen mit Tätigkeitslisten vorliegen (Abschn. 4.1.3). Lessons Learned, die für jedes Projekt gelten, werden unabhängig vom Thema ergänzt, da sie keinem einzelnen Leistungsbereich zuzuordnen sind. Treffer unterhalb einer Ähnlichkeitsschwelle gelten als Rauschen und gehen nicht in den Entwurf ein, damit fachfremde Projekte ihn nicht prägen. Bereits vorgelegte Hinweise werden nicht erneut eingebracht (F-13).

Im **dritten** Schritt *erzeugt* das Sprachmodell den Entwurf in einem festen Schema (F-02, F-03). Jeder Knoten beschreibt Aufwand, Leistung und optional benötigte Ressourcen, da in Angeboten wiederholt Komponenten wie Kabel vergessen werden (T3). Die Abgrenzung (F-04) liegt dabei vor allem auf Ebene der Leistungsbereiche, da historische Beschreibungen nur dort vorliegen; darunter genügen knappe Angaben (NF-05). Die Reihenfolge bildet der Entwurf über Gliederung und Nummerierung der PSP-Hierarchie ab (F-06). Abhängigkeiten zwischen Aufgaben ergeben sich daraus nur implizit. Gefordert war eine Abfolge ohne feste Termine (T5). Zudem bildet auch DocBee, in das der Entwurf zur Zeiterfassung übertragen werden soll, Projekte als Hierarchie von Vorgängen ab (Abschn. 4.1.3). Aufwände werden aus den historischen Werten in Personentagen abgeleitet und nennen ihre Grundlage (F-14); fehlt eine Grundlage, wird der Aufwand als offen gekennzeichnet statt geschätzt (F-17). Jedes Strukturelement führt die Referenzprojekte, die in das Element eingeflossen sind, als Quelle (F-17).

Im **vierten** Schritt wird der Entwurf *geprüft*. Die Einhaltung des Schemas ist maschinell entscheidbar und liegt daher im Programmcode, etwa dass ein Leistungsbereich nicht zugleich Arbeitspakete und Aufgaben enthält (F-03). Ob eine gefundene Lesson Learned für den Entwurf einschlägig ist, beurteilt das Sprachmodell. Ein solcher Hinweis wird zur Entscheidung vorgelegt und erst nach Zustimmung eingearbeitet (ST-03), zumal die Lessons-Learned-Liste keine vollständige Problemhistorie abbildet (Abschn. 4.1.2). Anders als bei der iterativen Selbstverfeinerung nach Madaan *et al.* (2023) bewertet damit nicht das Modell seinen eigenen Entwurf, sondern die Nutzenden und jede Rückmeldung im Chat löst einen neuen Durchlauf aus.

Für Änderungen gilt, dass der bestehende Entwurf Ausgangspunkt bleibt und nur das geändert wird, was verlangt oder welchem Hinweis zugestimmt wurde (F-18). Dafür sind zwei Wege vorgesehen: Die Änderung im Dialog über das Sprachmodell und die direkte Bearbeitung einzelner Knoten ohne Modellaufruf. Der zweite Weg erfüllt F-18 unabhängig vom Verhalten des Modells.

Exportphase Die Exportphase zeigt den Entwurf zur abschließenden Durchsicht in derselben bearbeitbaren Form wie die Planungsphase (ST-03) und gibt ihn als weiterbearbeitbares Dokument aus (F-19). Da der Wechsel zwischen den Phasen nicht an einen vollständigen Entwurf gebunden ist, steht der Export bereit, sobald ein Entwurf vorliegt, auch wenn er unvollständig ist (F-01).

4.2.3. Workshop

Ein Zwischenstand, der die oben beschriebenen Phasen umsetzte, wurde mit P1 und P6 besprochen (Abschn. 3.5.3). Da keine Live-Interaktion möglich war, beziehen sich die

Rückmeldungen auf den erläuterten Aufbau, nicht auf ein laufendes System. Die in T1 erwähnte Projektmanagement-Software war inzwischen in der Testphase, aber nur den Projektleitenden bekannt (W-P1, Pos. 1, 3; W-P6, Pos. 2). Der Workshop bestätigte den Zuschnitt der Beschreibungsphase und führte zu zwei Änderungen an dieser Phase, einer Erweiterung des Anforderungskatalogs und einem Vorbehalt.

Bestätigt wurden der Zuschnitt der Beschreibungsphase und die direkte Bearbeitbarkeit der Elemente. Beide Teilnehmenden hielten die Beschreibungsphase für „in Ordnung“, insbesondere das direkt bearbeitbare Beschreibungsfeld (W-beide, Pos. 11). P6 betonte, zunächst „erstmal alles“ bearbeiten können zu wollen (W-P6, Pos. 16), und P1 bestätigte den Leistungsbereich als geeignete Einheit für die Suche nach relevanten Informationen (W-P1, Pos. 15).

Geändert wurden der Einstieg und die Rolle des Systems in der Beschreibungsphase. Erwartet hatten beide zunächst ein einzelnes Eingabefeld (W-P6, Pos. 4; W-P1, Pos. 5). Zugleich forderten sie, durch die Standardfragen geführt zu werden (W-P1, Pos. 10), da ein offenes Feld ohne Führung entweder alle oder gar keine Informationen liefere (W-P6, Pos. 12). Ergänzt wurde daher ein geführter Einstieg als zweiter Weg in dieselbe Phase, der die Mindestangaben in definierten Fragen abfragt. Die von P1 vorgeschlagene Differenzierung der Fragen nach Projektart (W-P1, Pos. 6) wurde nicht umgesetzt, da der Prototyp einen Demofall abbildet. Zudem formulierte P1 den Anspruch, das System solle ohne beteiligte Projektleitung „die Projektleiterbrille aufhaben“ und deren Fragen stellen (W-P1, Pos. 9). Das Sprachmodell erhielt daraufhin die Rolle einer erfahrenen Projektleitung, die über die Mindestangaben hinaus eigene, für das Projekt relevante Punkte ansprechen kann (ST-01, ST-02).

Ergänzt wurde der Anforderungskatalog (Tab. 7). P1 nannte weitere Mindestangaben wie Software und Lizenzen, Compliance, Dokumentation, Schulungen und Hürden beim Kunden (W-P1, Pos. 8–9). Die Oberfläche im Unternehmensdesign wurde für eine spätere Umsetzung zurückgestellt (NF-11; W-P1, Pos. 13). An die technische Zuverlässigkeit knüpfte P6 die Nutzung ausdrücklich: „Es steht und fällt mit der Qualität“ (NF-10; W-P6, Pos. 18).

Offen blieb die Wirksamkeit der historischen Daten. P1 bezweifelte, dass sie den gewünschten Effekt erzielen, solange sie nicht in ausreichender Zahl und Pflege vorliegen; „wenn so 10 Projekte da sind“, könne das besser werden (W-P1, Pos. 14). Der Gesamteindruck fiel verhalten aus (P6: „Passt für mich“, P1: „Joa“; W-beide, Pos. 17). Den Nutzen machte P6 an einer erlebten Hilfestellung fest: „das hätte ich nicht bedacht“ (W-P6, Pos. 18).

4.3. Implementierung

Der Prototyp ist eine Python-Anwendung mit einer Weboberfläche auf Basis von Streamlit[2]. Historische Projektstrukturen und Lessons Learned liegen in der Vektordatenbank Qdrant. Qdrant verbindet die semantische Suche mit einer Filterung nach Metadaten in einer Abfrage (F-11, F-12). LiteLLM bindet die Sprachmodelle an. Es stellt lokale Modelle über Ollama und cloudbasierte Anbieter über eine einheitliche Schnittstelle bereit. Das Modell lässt sich daher allein über die Konfiguration austauschen (NF-07). Alle Komponenten laufen in Docker-Containern. Da der Prototyp auf unterschiedlichen Plattformen

2. Streamlit ist eine leichtgewichtige Python-Bibliothek für Weboberflächen, sodass Ablaufsteuerung und Oberfläche in einer Sprache umgesetzt sind.

entwickelt und getestet wurde, stellen die Container eine einheitliche Laufzeitumgebung sicher. In der vorliegenden Konfiguration läuft das Embedding-Modell lokal über Ollama. Für die Dialogschritte wird das cloudbasierte Modell `Gemini 3.6 Flash` verwendet. Für einen späteren Einsatz sollen leistungsstarke cloudbasierte Modelle eingebunden werden, für die im Unternehmen bereits Verträge mit Anbietern bestehen. Das ist wirtschaftlicher, als die für vergleichbare lokale Modelle nötige Hardware anzuschaffen. Der Prototyp erprobt daher bereits die Anbindung eines cloudbasierten Modells. Da ausschließlich synthetische Daten verarbeitet werden, ist diese Konfiguration zulässig. Für den produktiven Einsatz müsste ein im Unternehmen freigegebenes Modell hinterlegt werden (NF-07). Die vollständige Konfiguration ist im Repository des Prototyps dokumentiert (Anhang B.9). Für jede Phase existiert ein eigener Systemprompt, dem eine gemeinsame Rollenbeschreibung vorangeht (Anhang B.5).

Beschreibungsphase Die Erfassung beginnt mit einer formlosen Anfrage im Freitext. Ein Projekt muss dafür in den Quellsystemen nicht angelegt sein (ST-07). Die Mindestangaben aus F-08 sind als geordnete Liste im Systemprompt der Beschreibungsphase hinterlegt (Listing 2). Eine vorangestellte Rollenbeschreibung gibt dem Modell die im Workshop geforderte Sicht einer erfahrenen Projektleitung vor (Listing 1). Ein abschließender Punkt der Liste erlaubt dem Modell, weitere projektrelevante Angaben anzusprechen (ST-01, ST-02). Das Modell stellt höchstens drei Rückfragen je Nachricht und bezieht sich dabei auf die nächsten offenen Angaben. Diese Obergrenze setzt das schrittweise Vorgehen aus Abschnitt 4.2.2 um (F-09). Unbekannte oder übersprungene Angaben werden nicht erneut erfragt. Sie werden in einem abschließenden Absatz mit der Überschrift „Offen:“ festgehalten (F-15, F-17; Abb. 8). So bleiben Lücken sichtbar, ohne den Dialog zu blockieren (T6). Jede Antwort folgt einem vorgegebenen Pydantic-Schema (Listing 5). Es enthält die Antwort, die aktualisierte Beschreibung und ein Statusfeld. Der Anbieter beschränkt die Ausgabe auf dieses Schema. Der Programmcode kann die drei Teile daher trennen, ohne Freitext auszuwerten. Der Wechsel zur Planung stützt sich so auf ein eindeutiges Feld (Abschn. 4.2.1). Erst wenn alle Angaben bearbeitet sind oder Nutzende ausdrücklich fortfahren möchten, setzt das Modell dieses Feld. Der geführte Einstieg aus dem Workshop stellt die Mindestangaben als feste Folge von zwölf Fragen dar, teilweise mit verschiedenen wählbaren Antwortoptionen (Anhang B.3; Abb. 9). Jede Frage hat ein Freitextfeld und lässt sich überspringen. Die Fragen erscheinen einzeln, damit die Erfassung nicht wie ein Formular wirkt (F-07). Die bisherigen Antworten lassen sich in einer einklappbaren Übersicht einsehen. Die Antworten werden zu einer ersten Nachricht zusammengefasst. Unbeantwortete Punkte sind darin als „noch nicht angegeben“ markiert. Beide Einstiege münden damit in denselben Dialog. Das Modell prüft so auch die Antworten des geführten Einstiegs gegen die Mindestangaben und fragt nur noch nach offenen Punkten (F-07, F-09).

Wissensbasis Projektstrukturen und Lessons Learned liegen in zwei getrennten Collections[3], da sich ihre Datenschemata unterscheiden (Abschnitte 4.1.2 und 4.1.3). Da die gespeicherten Vektoren an das Embedding-Modell gebunden sind, muss bei einem Modellwechsel der gesamte Datenbestand neu verarbeitet werden. Gesucht wurde ein offen lizenziertes, mehrsprachiges Modell, das sich lokal auch ohne Grafikprozessor betreiben lässt. So muss der Datenbestand nicht an einen externen Anbieter übermittelt werden (NF-

3. Eine Collection ist eine Speichereinheit in Qdrant. Für jeden Eintrag werden ein Vektor und eine Payload mit Metadaten gespeichert. Die Payload enthält zum Beispiel Projektart und Erstellungsdatum. Über diese lassen sich Einträge zusätzlich filtern. Beide Sucharten können kombiniert werden.

07). Außerdem bleibt die Wissensbasis unabhängig vom Modellangebot eines Anbieters. Gewählt wurde `M3-Embedding` (Chen *et al.* 2023) (`bge-m3`) mit 1024 Dimensionen und einer Eingabelänge von bis zu 8192 Tokens. Die Ähnlichkeit wird als Kosinus-Ähnlichkeit bestimmt.

In der Collection der Projektstrukturen bildet jeder Leistungsbereich einen Eintrag. Sein Vektor entsteht aus der internen Beschreibung, weil diese die Tätigkeitslisten enthält (F-10; Listing 9). Ohne Anbindung an DocBee können untergeordnete Elemente nicht nachgeladen werden (NF-09). Deshalb sind Arbeitspakete und Aufgaben einschließlich der geplanten und dokumentierten Stunden als verschachtelte Metadaten gespeichert. Die Wissensbasis enthält nur Projekte, die der neuen Strukturvorgabe folgen. Historische Projekte ohne diese Gliederung oder mit identischen Beschreibungen müssten zunächst aufbereitet werden (Abschn. 4.1.3), was nicht Teil dieser Arbeit ist. Neue abgeschlossene Projekte lassen sich ohne Änderungen am Speichermodell oder an der Abfragelogik ergänzen (P-06). Wer wann welche Projekte einpflegt, bleibt eine organisatorische Frage (Abschn. 5).

Bei den Lessons Learned werden Titel, Problem- und Lösungsbeschreibung gemeinsam eingebettet (Listing 8). Das Feld „Kategorie (Test-Phase)“ wurde nicht übernommen, da es in der Liste nicht mehr gepflegt wird (Abschn. 4.1.2; vgl. P-05). Das Datenmodell setzt eine stabile Projekt-Id (`project_number`) voraus. Über diese lassen sich Lessons Learned effizient und eindeutig dem zugehörigen Projekt zuordnen. Im Prototyp wird jeder Hinweis mit dieser Id ausgegeben, sodass erkennbar bleibt, aus welchem Projekt er stammt. Die bestehende Liste enthält diese Id nicht (Abschn. 4.1.2). Für einen produktiven Einsatz müsste die Id bei jedem neuen Eintrag in der Lessons-Learned-Liste mit erfasst werden. Das betrifft die Dokumentationspraxis im Unternehmen und lässt sich nicht allein im System lösen (P-01).

Demodaten Für beide Collections wurden mit dem Sprachmodell *Claude Opus 5* synthetische Daten erzeugt. Dazu gehören zehn Lessons Learned und drei Projektstrukturen mit drei bis fünf Leistungsbereichen (Listings 10 und 11). Der Umfang ist für die Erprobung des Ablaufs gewählt und nicht an den realen Datenbestand angelehnt. Branchen, Projektarten und Skill-Teams wurden variiert, um die Suche über unterschiedliche fachliche Kontexte hinweg zu prüfen. Aus dem Suchverhalten mit diesen Daten lässt sich nicht auf die reale Datenbasis schließen. Das gilt insbesondere für den Umgang mit Duplikaten (Abschn. 4.1.2). Einer der Leistungsbereiche erfasst jeweils nicht fakturierbare „Interne Zeiten“ ohne geplante Stunden, entsprechend dem Befund aus DocBee (Abschn. 4.1.3).

Planungsphase Die vier Schritte aus Abschnitt 4.2.2 sind als feste Aufruffolge implementiert. Für die **Grobgliederung** erzeugt ein eigener, knapper Prompt aus der Projektbeschreibung Suchanfragen für jeden Leistungsbereich (Listing 3; F-05). Er ist vom Prompt der Erzeugung getrennt, da dessen Vorgaben zu Nummerierung, Aufgaben und Aufwänden der Grobgliederung widersprechen würden. Liegt bereits eine Struktur vor, werden deren Leistungsbereiche ohne Modellaufruf übernommen.

Beim **Abruf** werden für jeden Leistungsbereich die fünf ähnlichsten Referenzen und die drei ähnlichsten Lessons Learned abgerufen. Beide Werte wurden als Startwerte festgelegt und nicht variiert. Treffer mit einem Ähnlichkeitswert unter 0,5 werden verworfen, damit fachfremde Projekte den Entwurf nicht prägen. Der Grenzwert wurde anhand einzelner Testanfragen mit den Demodaten festgelegt. Dabei wurden Treffer als thematisch passend oder fachfremd eingeordnet. Übergreifende Lessons Learned (Projektphase

„Übergreifend“ oder „Angebotsphase“) werden in der ersten Runde einmalig über einen Metadatenfilter aufgenommen. Die IDs vorgelegter Lessons Learned werden je Sitzung gespeichert und in späteren Runden ausgeschlossen. Zusätzlich bleiben die vorgelegten Einträge im Gesprächsverlauf, sodass das Modell weiß, welche Hinweise es bereits gezeigt hat (F-13). Bei einem neuen Projekt stehen wieder alle passenden Hinweise zur Verfügung. Das Sprachmodell erhält aus jeder Referenz nur die Angaben, die es für den Entwurf benötigt. Projektnummer und Kunde dienen als Quellenangabe (F-17). Titel, Beschreibung und untergeordnete Elemente liefern eine Vorlage für die Struktur (F-10). Fehlen untergeordnete Elemente, dient der Leistungsbereich allein als Vorlage (F-15). Die Stunden dienen als Orientierung für den Aufwand (F-14). Weitere Felder würden unnötige Angaben in die Eingabe bringen. Personenangaben werden für keine dieser Aufgaben benötigt und daher nicht übermittelt. So ordnet das Modell Aufwände keinen einzelnen Personen zu (NF-08), und personenbezogene Daten gelangen nicht an das cloudbasierte Modell (NF-07). Referenzen und aktuelle Struktur werden in jeder Runde neu in die Eingabe eingefügt, da sie sich mit Änderungen an der Struktur ebenfalls ändern können. Ältere Stände im Gesprächsverlauf könnten der aktuellen Struktur widersprechen. Die Suchergebnisse der Referenzprojekte werden je Leistungsbereich zwischengespeichert. Unveränderte Leistungsbereiche werden in späteren Runden daher nicht erneut nach Referenzen durchsucht. Das spart Zeit bei der lokalen Berechnung der Vektoren.

Die **Erzeugung** erfolgt anhand eines Pydantic-Schemas mit Leistungsbereichen, optionalen Arbeitspaketen und Aufgaben (Listing 7; F-02, F-03). Der Systemprompt legt das Format und die Ausführlichkeit der Beschreibungen fest (F-04, NF-05). Er gibt auch vor, historische Stunden in Personentage umzurechnen, da intern in ganzen Tagen geschätzt wird (R-P1, 31.08.; F-02), und dabei dokumentierte Ist-Werte zu bevorzugen, da historische Schätzungen keine verlässliche Referenz sind (Abschn. 4.1.3; F-14). Hinter jedem Aufwand nennt das Modell dessen Grundlage. Unbelegte Aufwände sind als „offen“ zu kennzeichnen (F-17; Listing 4). Jeder Knoten enthält ein Feld `sources`. Darin stehen ausschließlich Referenzprojekte, die tatsächlich in die Erzeugung eingeflossen sind (F-17). So lässt sich ein aus einer Referenz abgeleiteter Aufwand auf das konkrete Projekt zurückführen. Das erleichtert vor allem das Nachvollziehen von Fehlern, wofür Quellen nach T6 vorrangig dienen sollen. Lessons Learned sind nicht Teil dieser Quellenangabe. Sie geben Hinweise zum Vorgehen, belegen aber nicht die Herkunft der Struktur. Das Modell führt sie getrennt in seiner Antwort auf. Es nennt passende Einträge mit einem konkreten Vorschlag und übernimmt sie erst nach Zustimmung der Nutzenden (ST-03; Abb. 10).

Die **Prüfung** erfolgt beim Einlesen der Antwort. Sie wird gegen das Schema validiert. Ein Validator weist Leistungsbereiche zurück, die zugleich Arbeitspakete und Aufgaben enthalten (F-03). Damit bildet der Prototyp die feste Abfolge aus den Interviews ab und ergänzt sie um die in der Zielstruktur vorgesehene direkte Zuordnung von Aufgaben zum Leistungsbereich (Abschn. 4.1.3). Entspricht eine Antwort nicht dem Schema, bricht der Aufruf mit einem Fehler ab. Eine automatische Wiederholung ist im Prototyp nicht umgesetzt. Welche Lessons Learned einschlägig sind, beurteilt das Modell (Abschn. 4.2.2) und hält sie im Feld `relevant_lessons` fest. Der Prototyp wertet dieses Feld nicht weiter aus.

Oberfläche und Export Eine Seitenleiste zeigt die Phasen als frei wählbare Navigationspunkte (NF-03). Der Strukturplan erscheint neben einem durchgehenden Chat für Änderungen im Dialog als editierbarer Baum. Titel und Beschreibung jedes Knotens lassen sich direkt bearbeiten. Knoten können verschoben, gelöscht und hinzugefügt werden.

Anschließend vergibt der Programmcode die Gliederungsnummern neu, sodass die Gliederung ohne Modellaufruf stimmig bleibt (F-06, F-18, ST-03). Direkte Änderungen lösen bewusst keinen Modellaufruf aus, da sonst jede Bearbeitung eines Textfeldes einen neuen Durchlauf starten würde. Der geänderte Stand geht mit der nächsten Anfrage im Chat in den Kontext ein. Ein Info-Symbol an jedem Knoten öffnet die Quellen als Popover (F-17, NF-06). In der Exportphase werden Beschreibung und Strukturplan als Markdown-Datei ausgegeben, auch wenn der Stand unvollständig ist (F-01, F-19; Abb. 11). Markdown ist ein einfaches Textformat, das sich verschicken und in Werkzeugen mit Markdown-Unterstützung wie dem Teams-Editor formatiert darstellen lässt. Abbildung 5 zeigt die Oberfläche der Planungsphase. Die übrigen Ansichten finden sich in Anhang B.4.

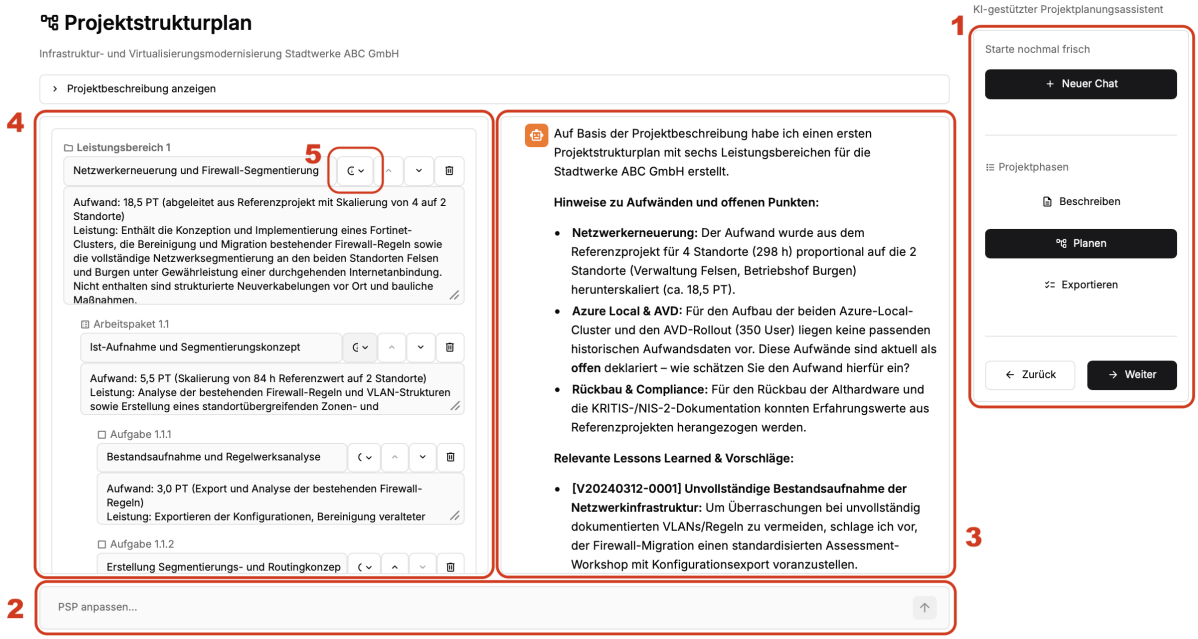


Abb. 5: Oberfläche der Planungsphase mit (1) Phasennavigation, (2) Chat-Eingabe, (3) Chat-Verlauf, (4) editierbarem Baum und (5) Info-Symbol mit Quellen

Umsetzungsstand Der Prototyp setzt die Designziele aus Tabelle 6 um. Eingrenzungen gegenüber den Anforderungen sind dort und in Abschnitt 4.2.3 begründet. Die Metadaten zur Eingrenzung der Lessons Learned sind indiziert. Ein Bedienelement dafür wurde im zeitlichen Rahmen der Arbeit jedoch nicht umgesetzt (F-12). Der Programmcode sichert nicht alle Designziele ab. Er erzwingt das Schema (F-02, F-03). Nutzer können die Elemente direkt bearbeiten (F-18). Bei Änderungen im Dialog gibt das Modell jedoch die vollständige Struktur zurück. Der Systemprompt ist die einzige Absicherung dafür, dass die übrigen Knoten erhalten bleiben. Auch Quellenangaben, die Kennzeichnung offener Aufwände (F-14, F-17) und die Zustimmung zu Lessons Learned (ST-03) sind als Anweisungen umgesetzt. Ob das Modell ihnen folgt, wird nicht zusätzlich im Programmcode geprüft. Abschnitt 5.4 greift die nicht umgesetzten Punkte auf.

4.4. Evaluation

In Gruppe A bedienten P1, P3 und P6 den Prototyp selbst, in Gruppe B beantworteten P2, P4, P7 und P9 die Fragen nach einem Demo-Video schriftlich (Abschn. 3.6). Von den

zwölf Aufgaben in Gruppe A wurden acht ohne Hilfe und vier mit Hilfe abgeschlossen. Nur P6 bearbeitete alle Aufgaben ohne Hilfe.

Geprüft werden konnten nur Anforderungen, die der Prototyp umsetzt und die im Ablauf sichtbar werden. Im Walkthrough wurden 20 Anforderungen beobachtet. Sieben weitere ließen sich nach einer einmaligen Sitzung nur erfragen, darunter der mögliche Zeitgewinn und die Frage, wer die Erstplanung übernimmt. Nicht prüfbar waren die nicht umgesetzten oder im Ablauf nicht sichtbaren Anforderungen F-12, F-16, F-20, NF-07 bis NF-09 und NF-11 (Abschn. 4.3) sowie die Anforderungen an das Unternehmen (ST-06, P-01 bis P-07). Zu drei umgesetzten Anforderungen (F-03, F-06, F-13) liegt keine auswertbare Rückmeldung vor (Abschn. 5.2). Die Ergebnisse folgen zunächst den Aufgaben vom Einstieg über den Entwurf bis zum Export und anschließend den übergreifenden Themen Bedienbarkeit, Rollen und Nutzen. Abschnitt 4.4.8 fasst sie nach Anforderungen zusammen.

4.4.1. Einstieg und Erfassung

Beide Einstiegswege wurden genutzt, jedoch aus unterschiedlichen Gründen. P6 wählte den geführten Start, weil Routine in der Projektplanung fehlt und P6 ihn im Workshop selbst gefordert hatte (A-P6, A0). P3 entschied sich dafür, weil das freie Feld zu unklar war. Im Interview bezeichnete P3 den Einstieg als schwierigste Stelle (A-P3, A0; A-P3, Abs. 25). P1 begann dagegen im freien Chat, obwohl P1 im Workshop einen Einstieg über Standardfragen gefordert hatte (W-P1, Pos. 10). P1 begründete die Wahl mit der Gewohnheit aus anderen Chatbots (A-P1, A0). Nach dem Export holte P1 den geführten Einstieg nach und sagte, „Also, ich fühl mich jetzt besser aufgehoben“ (A-P1, A3). P3 und P6 nutzten die Antwortoptionen ohne Erklärung (A-P3, A1; A-P6, A1).

Inhaltlich decken die Fragen die Mindestangaben ab. Auch im freien Chat orientierten sich die Rückfragen des Modells an diesen Angaben. P1 hob dort die Rückfragen zu Schulungen und bekannten Hürden eigens hervor (A-P1, A1). Alle drei kritisierten jedoch Reihenfolge, Zeitpunkt oder Auswahl der Fragen. P3 hätte vor der Frage nach den gewünschten Produkten und Dienstleistungen zuerst eine Frage nach dem Ist-Zustand erwartet und nannte die Folge „andersrum aufgebaut“ (A-P3, A1). P6 vermisste unter den Antwortoptionen zu Sicherheitsstandards *NIS2* und *TISAX* (A-P6, A1). Im geführten Einstieg bewertete P1 die ersten sechs Fragen positiv. Ab Frage 10, die nach dem Projektumfang fragt, kippte die Bewertung: „Jetzt geht er mir auf den Keks. Das ist kein Key Fact mehr“ (A-P1, A3). Anders als die vorherigen Fragen verlangt sie keine Eckdaten, sondern eine ausführliche Beschreibung. Diese wollte P1 lieber im Austausch mit dem Modell geben (A-P1, A3). P6 vermisste umgekehrt eine Rückfrage. Frage 8 ließ als Antwort zu, dass keine Dokumentation erforderlich sei. Dieses „Nein“ dürfe nicht unhinterfragt bleiben, da jedes Projekt zumindest eine rudimentäre technische Dokumentation erfordere (A-P6, A1).

Auch der Wortlaut der Fragen beeinflusst die Eingabe. Frage 5 („Welche Hardware ist bekannt und gegen was soll sie eingesetzt werden?“) war für P3 mehrdeutig. P3 war unsicher, ob vorhandene Hardware gemeint war und ob „eingesetzt“ eigentlich „ausgetauscht“ heißen sollte (A-P3, A1). In einem Interview der Vorstudie hieß es, eine KI könne nur so gut helfen, wie man sie frage (I-P8, Abs. 63). Hier lag die Unklarheit jedoch in der Frage des Systems. **Die geführte Erfassung wird angenommen, besonders wenn Routine fehlt. Ihr Nutzen hängt von Auswahl, Reihenfolge und Wortlaut der Fragen ab. Diese sollten sich am Vorgehen und Sprachgebrauch der Projektleitung orientieren.** (F-07 bis F-09)

4.4.2. Kalkulationsgrundlage

Die bei der Erfassung gemachten Angaben gingen in den Entwurf ein. Vor der Erzeugung zeigt die Planungsphase die gesammelte Projektbeschreibung an. Alle drei Teilnehmenden prüften sie, bevor sie den Entwurf erzeugen ließen. Obwohl das Szenario bewusst unvollständig war, entstand in allen Sitzungen ein Entwurf (A-P1, A2; A-P3, A2; A-P6, A2). Geprüft wurde dies nur für grobe Eingaben. Vorlagen unterschiedlicher Gliederungstiefe enthalten die Demodaten nicht. Für P1 entsprach die Gliederung den internen Vorgaben (A-P1, Abs. 28). Sie gebe Consultants eine Struktur, wo sonst pauschale Stundenansätze üblich seien (A-P1, Abs. 15). Bei P6 trug die Gliederung zur Orientierung bei. Obwohl P6 keine eigene Planungserfahrung hatte (A-P6, A0), erschloss sich P6 die Logik anhand des Entwurfs. P6 sagte dazu, „ich soll jetzt Aufgaben clustern in DocBee, und ich hab das noch nie gemacht. Und jetzt verstehe ich das“ (A-P6, A2). Bei P3 legte das Modell zunächst nur Leistungsbereiche an. Arbeitspakete und Aufgaben forderte P3 anschließend per Freitext nach (A-P3, A2).

Beide Gruppen hielten den Detailgrad für angemessen (A-P1, Abs. 24; A-P6, Abs. 42; B-P2, Abs. 12). P6 sah in der Aufgliederung einen Gewinn für die Außenwirkung. Bisher plane P6 Projekte als Fließtext mit pauschal 200 Stunden, auf die gebucht werde. Die Aufgliederung sei dagegen professioneller, „und so wollen wir auch auftreten“ (A-P6, Abs. 36; A-P6, A3). P9 hielt die Texte für Kundenkommunikation und Angebote für ausreichend (B-P9, Abs. 13). Einschränkungen betrafen Begriffe und Zuschnitt. P3 befürchtete, dass intern ungebräuchliche Begriffe wie „Workload Migration“, die das Modell verwendet hatte, zu einer falschen Einordnung von Aufgaben führen könnten (A-P3, A3). P1 hielt den Leistungsbereich „Hardware- und Lizenzbeschaffung“ fachlich für richtig, merkte aber an, dass die zugehörigen Schritte vor der Beauftragung stattfinden (A-P1, A2). Der Entwurf trennt somit nicht zwischen „Pre-Sales“ und Projektleistung. Ob solche Schritte in den Entwurf gehören, machte P1 vom Nutzungsfall abhängig. Arbeitet das Account Management ohne Projektleitung, soll der Entwurf die Sicherheit geben, als wäre eine Projektleitung beteiligt gewesen. Übernimmt später die Projektleitung, sollten Aufgaben aus dem „Pre-Sales“ darin fehlen (A-P1, A2). P4 fielen auf Anhieb keine groben Fehler auf, für P6 passte „grundsätzlich alles“ (A-P6, Abs. 48). P4 und P7 wollten die Zuverlässigkeit jedoch erst anhand eigener Fälle beurteilen (B-P4, Abs. 12; B-P7, Abs. 12).

Alle drei Teilnehmenden aus Gruppe A kritisierten außerdem die Darstellung. Die Planungsphase zeigt Chat und Strukturplan nebeneinander (Abb. 5). P1 bemängelte die zu hohe Informationsmenge, P3 den ungenutzten Platz und die kleine Schrift. P6 sah ungenutzte weiße Flächen neben einer „Wall of Text“ (A-P1, A2; A-P3, A2; A-P6, A1, A2). P9 sah den Prototyp nur im Video und bezeichnete die Darstellung dagegen als klar strukturiert (B-P9, Abs. 2). **Die Gliederung entsprach den internen Vorgaben, und beide Gruppen hielten den Detailgrad für angemessen. Offen bleiben die Abgrenzung zwischen „Pre-Sales“ und Projektleistung sowie eine Oberfläche, die den Entwurf statt des Chats in den Mittelpunkt stellt.** (F-01, F-02, F-04, F-05, F-15, NF-04, NF-05)

4.4.3. Historisches Wissen und Herkunft

Der Prototyp soll sich durch Wissen aus früheren Projekten von einem allgemeinen Sprachmodell unterscheiden. P1 und P3 bewerteten Vergleichsprojekte als Vorlage positiv. Auf die Frage, ob das Ergebnis besser sei als das eines allgemeinen Sprachmodells ohne interne Daten, sagte P1, „besser für unsere Arbeit zu 100 %“ (A-P1, Abs. 28; A-P3, Abs. 39). P4

sieht den Nutzen darin, ähnliche Arbeitspakete aus anderen Projekten einzubeziehen. Die Strukturierung lasse sich bereits mit selbst erstellten GPTs abbilden (B-P4, Abs. 6, 14). P2 und P7 knüpfen den Nutzen daran, dass historische Daten tatsächlich einfließen und die Vergleichsprojekte der semantischen Suche passen (B-P2, Abs. 14; B-P7, Abs. 16).

Die Hinweise aus Lessons Learned bewerteten die Teilnehmenden grundsätzlich positiv (A-P1, Abs. 3; B-P4, Abs. 16). Allgemein sahen P2 und P7 im Werkzeug einen Schutz davor, Teilschritte zu vergessen (B-P2, Abs. 4; B-P7, Abs. 2). Im Walkthrough wurden die Hinweise jedoch nicht zuverlässig wahrgenommen. Das Modell zeigt die Hinweise in seiner Chat-Antwort. P6 übersah sie, weil sie im Text untergingen (A-P6, A2). P1 nahm sie wahr, wünschte sich aber einen eigenen Bereich neben dem Chat (A-P1, A2). P3 konnte ihren Einfluss nicht einschätzen (A-P3, Abs. 37). Das Auffinden funktioniert, die Darstellung nicht.

Die historischen Aufwandswerte sollen als Orientierung dienen, nicht als verbindlicher Referenzwert. Die Rückmeldungen dazu fielen unterschiedlich aus. P3 würde die Werte als Argumentationshilfe gegenüber Consultants nutzen. Schätze ein Consultant zwei Tage, während das Werkzeug anhand früherer Vorgänge eher vier ansetze, ließen sich damit höhere Aufwände begründen, um später nicht „gnadenlos überbucht“ zu sein (A-P3, Abs. 19). P9 verwies auf ein Gegenbeispiel. Nach Aussage der Techniker könne ein Projekt mit dem Titel „Zwei Standorte, Firewallcluster, Hardwaretausch, Fortinet“ je nach Kunde, Standorten, Altgeräten und Regelwerk zwischen vier Stunden und 20 Tagen dauern. P9 hielt diese Einschätzung für zutreffender als eine Planung, die den Aufwand eines gleich benannten Arbeitspakets vom letzten Kunden übernimmt (B-P9, Abs. 5). P2 äußerte ähnliche Vorbehalte. Da Consultants unterschiedlich planen und gleiche Tätigkeiten unterschiedlich benennen, würde P2 den historischen Werten zu Beginn nur schwer vertrauen (B-P2, Abs. 16). P6 wollte historische Daten ein- und ausschalten können, um ihren Einfluss zu erkennen (A-P6, Abs. 44). Außerdem vermisste P6 eine Rundung auf halbe oder volle Tage (A-P6, A2). P6 überlegte auch, Aufwände je Kunde und je Mitarbeitendem auszuwerten, verwarf dies aber selbst als womöglich zu viel Controlling (A-P6, Abs. 2). Der Gedanke berührt NF-08.

P1 erkannte die Kennzeichnung unsicherer Angaben erst, nachdem der Autor erklärt hatte, wie das Modell historische Daten heranzieht. Danach sagte P1, „dann rät er nicht einfach ins Blaue“ (A-P1, A2). P3 erkannte die als offen gekennzeichneten Aufwände und wünschte sich dafür einen Orientierungswert durch das LLM selber (A-P3, Abs. 41, 43). Zugleich befürchtete P3, der Entwurf könne Leistungen enthalten, die der Kunde anschließend erwartet (A-P3, A3). Die Kennzeichnung schützt vor erfundenen Zahlen, aber nicht vor einem zu großen Leistungsumfang. Die Herkunftsangabe über das Info-Symbol am Knoten hielten beide Gruppen für ausreichend (A-P1, Abs. 31; A-P6, Abs. 46; B-P9, Abs. 17).

Mehrere Rückmeldungen betreffen die Datenbasis im Betrieb. Der Prototyp ordnet Lessons Learned über eine Projektkennung den Projekten zu (Abschn. 4.3). P1 bezweifelte, dass Lessons Learned bisher mit Vorgangsnummer dokumentiert wurden (A-P1, Abs. 32). Bereits im Workshop hatte P1 eine Wirkung erst bei ausreichend gepflegten Daten erwartet (W-P1, Pos. 14). Da der Prototyp mit synthetischen Demodaten arbeitet, beziehen sich die Bewertungen in diesem Abschnitt auf das Prinzip und nicht auf die Qualität der Unternehmensdaten. **Der erwartete Mehrwert liegt im unternehmenseigenen Wissen. Damit er ankommt, müssen Hinweise getrennt vom Chat erscheinen**

und Aufwandswerte erkennbar als Orientierung ausgewiesen sein. (F-10, F-11, F-14, F-17, NF-06)

4.4.4. Bearbeitung und Export

Bevor ein Entwurf weitergegeben wird, muss er sich anpassen lassen. P1 und P3 nutzten die manuelle Bearbeitung aktiv, P6 schätzte es, Änderungen auch per Texteingabe anstoßen zu können (A-P1, A2; A-P3, A2; A-P6, Abs. 51). Beim Löschen vermisste P1 eine Rückfrage („Krieg ich das jetzt auch wieder zurück?“, A-P1, A2). P3 vermisste eine solche Rückfrage beim Button „Neuer Chat“, da unklar sei, ob ein Klick die laufende Sitzung verwirft (A-P3, A2). P1 schloss den Export ohne Schwierigkeiten ab. P3 fand den Download-Knopf erst mit Hilfe (A-P1, A3; A-P3, A3). P6 und P9 hielten das Ergebnis für die Weitergabe geeignet (A-P6, Abs. 36; B-P9, Abs. 13). **Bearbeitung und Export lassen das Ergebnis in der Hand der Nutzenden. Es fehlt eine Absicherung gegen versehentliches Löschen.** (F-18, F-19)

4.4.5. Bedienbarkeit und Zuverlässigkeit

Bei der Nutzung ohne Schulung unterscheiden sich Einschätzung und Beobachtung deutlich. Drei von vier Teilnehmenden aus Gruppe B sahen keine Stelle, an der sie ohne Einführung nicht weiterkämen (B-P2, Abs. 8; B-P4, Abs. 8; B-P9, Abs. 9). P6 äußerte nach der eigenen Nutzung eine ähnliche Einschätzung (A-P6, Abs. 38). Tatsächlich kam P6 ohne Hilfe aus, deutete aber das kleine Kästchen vor jeder Aufgabe als Checkbox und wollte es abhaken (A-P6, A2). P1 und P3 benötigten Unterstützung. P3 stellte schon beim Einstieg Rückfragen zur Navigation (A-P3, A0). P1 suchte die Chat-Eingabe, die nach unten gewandert und nur hellgrau hinterlegt war. Zudem hielt P1 die vom Modell fortlaufend zusammengefasste Projektbeschreibung für die eigene Nachricht, da beide inhaltlich ähnlich waren. Erst der Autor erklärte die Felder (A-P1, A1). P3 fand die einklappbare Übersicht der bisherigen Antworten im geführten Einstieg erst nach einem Hinweis (A-P3, A1), beim Export ebenso den Download-Knopf.

Die technische Zuverlässigkeit war nicht gegeben. In zwei von drei Sitzungen brach eine Anfrage mit einem Timeout ab, weil die lokale Berechnung der Embeddings zu lange dauerte (A-P1, A2; A-P3, A2). Im Workshop hatte P6 die Nutzung ausdrücklich an einen störungsfreien Betrieb geknüpft (W-P6, Pos. 18). **Nur eine von drei Personen kam ohne Hilfe durch alle Aufgaben. Orientierung beim Einstieg und ein stabiler Betrieb sind Voraussetzungen der Nutzung, die der Prototyp noch nicht erfüllt.** (NF-03, NF-10)

4.4.6. Rollen und Kontrolle

Neben der Bedienung stellt sich die Frage, wer den Entwurf erstellt und wer die Verantwortung dafür behält. Am deutlichsten fiel die Rückmeldung zu ST-02 aus: Erfahrungswissen der Projektleitung kann einfließen, ohne dass sie selbst eingebunden sein muss. P1 erkannte in den Rückfragen „die Fragen, die ich als Projektleiter auch stellen würde“ (A-P1, A1). Daraus folgerte P1, es sei unproblematisch, wenn die Projektleitung erst nach dem Auftrag hinzukomme (A-P1, Abs. 16). P7 sieht den größten Nutzen bei unerfahrenen Consultants (B-P7, Abs. 2). Für P9 könnte das Werkzeug ausgleichen, dass Projektbeschreibungen je nach Ansprechperson unterschiedlich ausführlich ausfallen (B-P9, Abs. 15).

Wer die Erstplanung übernehmen soll, wurde unterschiedlich beantwortet. Die Antworten richteten sich dabei nicht durchgehend nach der eigenen Rolle. Unter den Projektleitenden sah P1 den Vertrieb am Anfang (A-P1, Abs. 10), P3 dagegen die Projektleitung selbst. P3 begründete dies nicht mit fehlender fachlicher Eignung anderer Rollen, sondern bezweifelte, dass diese den Entwurf ernst nähmen (A-P3, A3). P4 nannte Account Management und Projektleitung (B-P4, Abs. 4). Als Consultant sah P6 den Start bei der Technik (A-P6, Abs. 32). P9 schloss als Account Manager die eigene Rolle aus (B-P9, Abs. 7). P1 und P6 waren sich einig, dass die Projektleitung den Entwurf abschließend durchsieht (A-P1, Abs. 12; A-P6, Abs. 32).

Da mehrere Rollen am Entwurf beteiligt sind, wünschten sich P1 und P6, gemeinsam daran zu arbeiten. P1 bewertete einen gemeinsamen Zugriff mit „10 von 10“ und beschrieb, wie ein Grundentwurf an Kolleginnen und Kollegen weitergegeben werden könnte, die ihn prüfen und ergänzen (A-P1, A2; A-P1, Abs. 14). P6 sah die Nutzung bei mehreren Personen und mit Kollaborationsfunktionen bei Projektmanagement und Technik gemeinsam (A-P6, Abs. 32) und sprach dies beim Export erneut an (A-P6, A3). Auch P3 würde den Entwurf mit Consultants und Kunde abstimmen, bevor er verbindlich wird (A-P3, A3). Der Prototyp ist dagegen auf eine Person je Sitzung ausgelegt. Ein Entwurf lässt sich nur über den Export weitergeben. In der Vorstudie hatte sich dieser Bedarf nur vereinzelt angedeutet (I-P5, Abs. 51). Ob die inzwischen erprobte Projektmanagement-Software ihn abdeckt, ist offen (W-P1, Pos. 1).

Alle Teilnehmenden, die sich dazu äußerten, wollten die Entscheidung über das Ergebnis beim Menschen belassen. P1 fühlte sich nicht eingeschränkt, da sich alles anpassen lasse (A-P1, Abs. 39, 41). P3 verwies darauf, dass das Werkzeug nichts selbstständig in DocBee oder eine Projektmanagement-Software überträgt (A-P3, Abs. 50). P6 fand das Maß dessen, was das Werkzeug übernimmt, genau richtig (A-P6, Abs. 48). P2 und P4 sahen die Kontrolle bei sich. P4 und P7 wollten aber erst in der Praxis beurteilen, ob das Werkzeug zu viel oder zu wenig übernimmt (B-P2, Abs. 18; B-P4, Abs. 18; B-P7, Abs. 18). P9 wies auf eine Grenze hin. Aus kaufmännischer Sicht lasse sich das Ergebnis ohnehin nicht fachlich prüfen (B-P9, Abs. 17). Formal bleibt die Entscheidung beim Menschen. Fachlich prüfen kann den Entwurf aber nur, wer das nötige Wissen hat. Bis auf P7, das den Prototyp erst an eigenen Fällen erproben wollte, beschrieben alle Teilnehmenden den Entwurf als Grundlage weiterer Schritte und nicht als fertiges Ergebnis. P1 sah darin eine Möglichkeit, die vorliegenden Informationen zu ordnen und zu erkennen, was noch zu klären ist (A-P1, Abs. 11). P4 sieht ihn als Ausgangspunkt für einen anschließend detaillierten Strukturplan (B-P4, Abs. 4), P9 als erste Indikation und Checkliste für Kundengespräch und Angebot (B-P9, Abs. 4). P2 hielt den Detailgrad für eine Übersicht angemessen, je nach Projekt sei aber eine tiefere Betrachtung nötig (B-P2, Abs. 12). **Die abschließende Prüfung sollte eine fachkundige Person übernehmen. Welche Rolle für die Erstplanung zuständig ist, sollte im Prozess festgelegt werden. Da mehrere Rollen beteiligt sind, wird ein gemeinsamer Zugriff auf den Entwurf erwartet.** (ST-01 bis ST-03, ST-05)

4.4.7. Nutzen und Zeitgewinn

Ob sich der Einsatz lohnt, lässt sich nach einer Sitzung nur anhand von Einschätzungen beurteilen. Beide Gruppen sahen den Einsatz im vorgesehenen Zeitraum zwischen Anfrage und Auftrag (A-P1, Abs. 11; B-P9, Abs. 4). P1, P2, P3 und P4 hielten einen ersten Entwurf

in etwa einer halben Stunde für realistisch (A-P1, Abs. 20; A-P3, Abs. 31; B-P2, Abs. 10; B-P4, Abs. 10). P6 sah dies nur bei Regelprojekten als realistisch an (A-P6, Abs. 40).

P1 bejahte am deutlichsten, dass der Zeitgewinn den Prüfaufwand übersteigt. P1 sagte, „die Zeitersparnis ist riesig groß“ (A-P1, Abs. 16). Die übrigen Teilnehmenden erwarteten den Zeitgewinn unter unterschiedlichen Bedingungen. P3 sah ihn, wenn das System zur eigenen Arbeitsweise passt und eine stichprobenartige Prüfung genügt (A-P3, Abs. 17, 46). P6 erwartete ihn bei großen Projekten (A-P6, Abs. 34), P4 bei übernommenen Arbeitspaketen (B-P4, Abs. 6) und P2 im Projektverlauf durch vermiedene Fehler (B-P2, Abs. 6). P9 erwartete für sich keinen Zeitgewinn, weil die Planung nicht zur eigenen Rolle gehört (B-P9, Abs. 7). P7 konnte dies ohne Test nicht beurteilen (B-P7, Abs. 6, 10). Alle, die sich dazu äußerten, erkannten einen grundsätzlichen Nutzen (A-P1, Abs. 6; A-P6, Abs. 30; B-P2, Abs. 4; B-P4, Abs. 2). Ein Kriterium nannte P6 bereits im Workshop. Das System sollte eine Hilfestellung bieten, an die man selbst nicht gedacht hätte (W-P6, Pos. 18). **Ein grundsätzlicher Nutzen wird erkannt. Wo der Zeitgewinn entsteht, hängt von Rolle und Projektgröße ab und lässt sich erst im Einsatz belegen.** (NF-01, NF-02, ST-04, ST-07)

4.4.8. Ergebnis je Anforderung und neue Anforderungen

Tabelle 8 fasst das Ergebnis je Anforderung zusammen. Von den 20 im Walkthrough beobachteten Anforderungen sind sieben erfüllt, zwölf eingeschränkt erfüllt und eine nicht erfüllt.

Tabelle 9 fasst Rückmeldungen zusammen, die über den Anforderungskatalog hinausgehen. Die meisten präzisieren eine bestehende Anforderung, etwa wie Hinweise dargestellt (N-02 zu F-11) oder offene Angaben erfasst werden sollen (N-08 zu F-09). Neu ist die Mehrbenutzerfähigkeit (N-11). P1 und P6 sprachen sie ausdrücklich an, P3 deutete den Bedarf an. Abschnitt 4.4.6 geht darauf ein. Zwölf der 14 Anforderungen stammen aus Gruppe A.

5. Diskussion & Schlussfolgerung

Diese Arbeit untersuchte, wie generative KI Projektplanungsverantwortliche im Rahmen eines Assistenzsystems bei der Erstellung von Projektstrukturplänen unterstützen kann. Ausgangspunkt waren drei offene Punkte der verwandten Arbeiten (Abschn. 2.4): Bisherige Ansätze erzeugen keinen PSP direkt in der Angebotsphase, sie bewerten Systeme meist nur anhand des erzeugten Ergebnisses und sie betrachten technische Systeme getrennt von der tatsächlichen Planungspraxis. Der Hintergrund richtete den Blick dabei vor allem auf zwei Punkte: Wie das System vorhandenes Erfahrungswissen einbringt und wie Planungsverantwortliche den Entwurf nachvollziehen und kontrollieren können.

Dieses Kapitel vergleicht die Ergebnisse der DCS mit der Literatur, beschreibt die Grenzen der Untersuchung und beantwortet darauf aufbauend die Forschungsfrage.

5.1. Diskussion der Ergebnisse

Kein allgemein richtiger Entwurf Die Teilnehmenden sahen den Entwurf fast durchweg als Grundlage, nicht als fertigen PSP (Abschn. 4.4.6). Das passt zum Planverständnis von Suchman (1987): Pläne sind Ressourcen für das Handeln, legen dessen Verlauf aber

nicht fest. Die Kanufahrt aus Abschnitt 2.1 veranschaulicht das: Ein Plan bringt das Kanu nicht durch die Stromschnellen, hilft aber bei der Vorbereitung. Auch der Entwurf ersetzt weder die Gespräche mit Consultants und Kunde, noch die spätere Detailplanung (A-P3, Abs. 17; A-P3, A3; B-P4, Abs. 4). Er bietet aber einen Ausgangspunkt für die weitere Arbeit. Das hatte bereits die Vorstudie erwarten lassen (Abschn. 4.1.1, T2).

Was in den Entwurf gehört, steht nicht von Anfang an fest. P1 hielt den Leistungsbereich zur Beschaffung von Hardware und Lizenzen fachlich für richtig, ordnete die Schritte aber zeitlich vor der Beauftragung ein (A-P1, A2). Ob sie in den Entwurf gehören, hängt für P1 davon ab, ob das Account Management allein damit arbeitet oder die Projektleitung später übernimmt (Abschn. 4.4.2). Derselbe Leistungsbereich kann also sinnvoll oder überflüssig sein, je nachdem, wer den Entwurf weiterbearbeitet. Auch der Zweck des Entwurfs hängt davon ab, welche Rolle ihn zu welchem Zeitpunkt nutzt (Abschn. 4.4). Ein allgemein richtiger PSP für die Angebotsphase lässt sich daher nicht bestimmen. Dies stützt sich vor allem auf das Beispiel von P1 und ist daher als Hinweis zu verstehen, nicht als gesicherte Regel.

Verwandte Arbeiten gehen von einer anderen Annahme aus. Dort werden Entwürfe anhand des Dokuments bewertet: Kwasafo *et al.* (2026) vergleichen sie mit manuell erstellten Texten, während Al-Hebshi und Lübbe (2026) Kennzahlen, Bewertungen durch ein Sprachmodell und die Einschätzung einer Fachperson heranziehen. Qualität gilt dabei als Eigenschaft des Dokuments. Die Evaluation dieser Arbeit legt nahe, dass die Qualität eines Planungsentwurfs in der Angebotsphase auch davon abhängt, wer ihn wann weiterbearbeitet. Im untersuchten Fall gibt es zudem keine verlässliche Vergleichsgrundlage. Frühere Projektstrukturpläne in DocBee eignen sich kaum dafür: Sie sind unterschiedlich aufgebaut, beschreiben die Aufgaben meist nicht und benennen gleiche Tätigkeiten verschieden (Abschnitte 4.1.3 und 4.4.3). Eine Bewertung anhand einer Referenz allein reicht deshalb nicht aus.

Bewertungen solcher Systeme sollten deshalb auch die Rollen berücksichtigen, die den Entwurf zu verschiedenen Zeitpunkten weiterbearbeiten. Entscheidend ist dann nicht so sehr, ob der Entwurf einer Referenz entspricht, als vielmehr, ob der nächste Arbeitsschritt daran anknüpfen kann. Für diesen Fall stützt das die Forderung der situierten Evaluation, Systeme dort zu bewerten, wo sie tatsächlich genutzt werden (Twidale *et al.* 1994). In dieser Arbeit war das nur in einzelnen Sitzungen möglich, nicht im laufenden Prozess (Abschn. 5.2).

Was das Kanu schließlich durch die Stromschnellen bringt, sind nach Suchman (1987) die Fähigkeiten derer, die es steuern. Für den Entwurf stellt sich damit die Frage, wer ihn beginnen, fachlich beurteilen und weiterentwickeln kann.

Kontrolle und Verantwortung Die Teilnehmenden waren sich uneinig, welche Rolle den Entwurf beginnen sollte. Dabei nannten sie nicht immer die eigene Rolle (Abschn. 4.4.6). Das passt zur Wissensverteilung, die bereits in der Vorstudie sichtbar wurde (T2). Das Account Management braucht die fachliche Einschätzung der Consultants. Die Projektleitung kommt oft erst nach dem Auftrag hinzu, und P6 fehlte als Consultant die Erfahrung in der Projektplanung (A-P6, A0). Keine einzelne Rolle bringt also alles mit, was für einen verlässlichen Entwurf nötig ist.

Im System blieb die Entscheidung beim Menschen (Abschn. 4.4.6). Die Annahme aus dem theoretischen Hintergrund, dass Planende den Entwurf mit ihrem eigenen Wissen prüfen (Abschn. 2.1), gilt aber nur für Personen, die ihn fachlich beurteilen können. Aus

kaufmännischer Sicht ist das nicht möglich (B-P9, Abs. 17). Nach Parasuraman und Riley (1997) sollte sich die Rolle des Menschen danach richten, wofür er verantwortlich ist und was er kann. Im untersuchten Fall kann das keine einzelne Person leisten. Dafür müssen die Rollen zusammenarbeiten. Verwandte Arbeiten sehen vor, dass Menschen die Ergebnisse prüfen oder mitentscheiden (Bui *et al.* 2025; Al-Hebshi und Lübbe 2026; Kwasafo *et al.* 2026), klären aber nicht, wer das fachlich leisten kann. Für die Forschung heißt das: Studien zu solchen Systemen sollten nicht nur die nutzende Person betrachten, sondern auch, wer im Prozess fachlich prüfen kann. In der Praxis reicht ein *Human in the Loop* auf Systemebene daher nicht aus. Der Prozess muss festlegen, wer den Entwurf beginnt und wer ihn freigibt. Das entspricht dem Konzept *Human in Command* (Hochrangige Expertengruppe für künstliche Intelligenz 2019, Abs. 65). P1 und P6 sahen die Projektleitung für die Freigabe vor. P1 und P6 wollten außerdem gemeinsam am Entwurf arbeiten können (Abschn. 4.4.6). Das System kann diese Zuständigkeiten nicht festlegen, denn sie betreffen den gesamten Prozess. Die betroffenen Rollen müssen sie gemeinsam erarbeiten (P-02, P-03). Das ist auch deshalb nötig, weil frühere Versuche, Abläufe zu vereinheitlichen, auf Widerstand stießen (T4). Eine solche Festlegung hat jedoch Folgen: Der Entwurf soll ermöglichen, dass die Projektleitung erst nach dem Auftrag hinzukommt (A-P1, Abs. 16). Muss sie den Entwurf freigeben, wird sie bereits in der Angebotsphase eingebunden. Jede zusätzliche Person verursacht Kosten und kann das Angebot verzögern (T1).

Offen bleibt, ob die Prüfung bei längerer Nutzung nachlässt. Das legt das Konzept des *Cognitive Offloading* nahe (Risko und Gilbert 2016, 683, Box 3), und auch in der Vorstudie wurde dies befürchtet (I-P7, Abs. 30). Die Evaluation deutet jedoch auch auf eine andere Möglichkeit hin: P6 verstand anhand des Entwurfs, wie ein PSP aufgebaut wird, obwohl P6 keine eigene Planungserfahrung hatte (A-P6, A2). Der Entwurf kann also Erfahrungswissen an weniger erfahrene Personen weitergeben. Gleichzeitig können gerade sie den Entwurf am schwersten prüfen. Deshalb sollten erfahrene Fachkräfte die Ergebnisse über längere Zeit kontrollieren, wie es P-07 vorsieht (Tab. 5). Wie viel Erfahrungswissen der Entwurf weitergibt, hängt davon ab, wie viel davon im System vorhanden ist.

Erfahrungswissen in Fragen und Daten Die Teilnehmenden, die sich dazu äußerten, sahen den größten Vorteil gegenüber einem allgemeinen Sprachmodell im Wissen aus dem eigenen Unternehmen. Darauf beruht auch der Einsatz von RAG (Abschn. 2.2.2). P1 erkannte die Erfahrung der Projektleitung zunächst an den Rückfragen (A-P1, A1). Diese basieren nicht auf früheren Projektdaten, sondern auf den Mindestangaben und der Rolle der Projektleitung. Beides wurde in der Vorstudie und im Workshop mit den Beschäftigten erarbeitet. Damit bestätigte sich eine Gestaltungsentscheidung aus dem Workshop: P1 hatte gefordert, dass das System „die Projektleiterbrille aufhaben“ solle (W-P1, Pos. 9; Abschn. 4.2.3). Da dieselbe Person die Forderung äußerte und später bestätigte, ist dieses Ergebnis vorsichtig zu bewerten. Bei der Erhebung der Anforderungen wurde also bereits ein Teil des Erfahrungswissens im Dialog festgehalten und damit externalisiert (Nonaka und Takeuchi 2012), ähnlich wie bei Hoerner *et al.* (2023). Die Fragen enthalten damit selbst Erfahrungswissen. Wie die Daten müssen auch sie aktuell bleiben: Im Workshop wurde der Fragenkatalog fachlich ergänzt (W-P1, Pos. 8–9), und in der Evaluation fehlten aktuelle Sicherheitsstandards unter den Antwortoptionen (A-P6, A1). Der Prototyp arbeitete mit synthetischen Daten. Damit waren die Fragen die einzige Quelle echten Erfahrungswissens. Dass die Teilnehmenden die Erfahrung vor allem an den

Rückfragen erkannten, hängt daher auch mit dem Aufbau der Untersuchung zusammen (Abschn. 5.2).

Auch die Art der Fragen ist wichtig (Abschn. 4.4.1). Nach Horvitz (1999) sollte ein System bei wichtigen Unsicherheiten nachfragen und zugleich darauf achten, Nutzende nicht unnötig zu stören (Prinzip 5). In der Evaluation zeigte sich beides: P1 störte die Frage nach dem Projektumfang (A-P1, A3), während P6 bei einer Antwort zur Dokumentation eine Nachfrage vermisste (A-P6, A1). Die ersten Fragen zu den Eckdaten bewertete P1 dagegen positiv. Nur den Projektumfang wollte P1 lieber im Dialog beschreiben (A-P1, A3). Wann ein System nachfragen sollte, hängt möglicherweise sowohl davon ab, wie unsicher es ist, als auch von der Art der Angabe. Reihenfolge und Wortlaut der Fragen sollten sich am Vorgehen der Projektleitung orientieren, damit sie verständlich sind (A-P3, A1). Das entspricht der Erwartung aus der Vorstudie: Die Beteiligten zogen ein dialogisches System einem starren Formular vor und wollten die Zahl der Rückfragen begrenzen (T6).

Beim Wissen aus früheren Projekten zeigte sich ein anderes Bild. Das System fand zwar Hinweise aus Lessons Learned, doch einige gingen im Chat unter. Deshalb wurde ein eigener Bereich dafür gewünscht (Abschn. 4.4.3). Ein gefundener Hinweis erreicht die Nutzenden also nicht automatisch. Im Betrieb hängt das auch davon ab, wie gut die Datenbasis gepflegt wird. Bisher sind Lessons Learned keinem Projekt eindeutig zugeordnet (Abschn. 4.3). P1 bezweifelte zudem, dass sie mit Vorgangsnummer dokumentiert wurden (A-P1, Abs. 32). Das passt zur Vorstudie: Erfahrungswissen ist meist an einzelne Personen gebunden und wird selten dokumentiert (T3). Ein Werkzeug allein ändert diese Praxis nicht. Es kann nur festgehaltenes und einheitlich benanntes Wissen einbringen (P-01, P-04).

Der Fall legt nahe, dass Erfahrungswissen auf zwei Wegen in ein KI-gestütztes Planungssystem gelangt: Durch die Suche in Daten aus früheren Projekten und durch die Fragen des Systems, die Nutzende beantworten. Bei den Fragen kommt es sowohl auf den Inhalt als auch auf die Art der Frage an. Auch Al-Hebshi und Lübbe (2026) zufolge hängen die Ergebnisse davon ab, wie das Unternehmenswissen aufbereitet ist und wie ausführlich die Eingabe ist. Dort wird die Eingabe jedoch als Mitschrift des Auftragsgesprächs übernommen und nicht durch Fragen erhoben. Künftige Bewertungen solcher Systeme sollten daher untersuchen, welche Ergebnisse die Suche liefert und wie gut sie sind. Sie sollten außerdem prüfen, welches Wissen durch die Fragen in den Entwurf gelangt und ob die gefundenen Hinweise die Nutzenden erreichen. Wie stark die Suche und die Fragen mit echten Daten jeweils zum Entwurf beitragen, muss noch untersucht werden. Damit das Wissen überhaupt ankommt, muss das System aber genutzt werden.

Bedienbarkeit zeigt sich erst bei Nutzung Dafür muss das Werkzeug nach der Vorstudie leicht zugänglich und intuitiv bedienbar sein (T6). Eine umfangreiche Projektmanagement-Software, für die zunächst eine Schulung nötig ist, würde in der frühen Angebotsphase kaum angenommen (I-P2, Abs. 88). Die Einschätzungen dazu, ob der Prototyp diese Erwartung erfüllt, unterschieden sich zwischen den Gruppen. Nach dem Video meinten drei von vier Personen, sie könnten alle Schritte auch ohne Einführung ausführen. Im Walkthrough brauchten dagegen zwei von drei Personen Hilfe. Alle drei kritisierten die Darstellung, die P9 nach dem Video noch als klar strukturiert bezeichnet hatte. Auch eine Person, die die Bedienung nach eigener Nutzung einfach fand, verstand ein Bedienelement falsch (Abschn. 4.4.5).

Nach einer reinen Vorführung wäre die Bedienbarkeit vermutlich besser bewertet worden. Eine Vorführung zeigt einen idealen Ablauf. Wer nur zusieht, erlebt den Prototyp und den Erstellungsprozess nicht selbst. Wo man suchen, nachfragen oder etwas falsch verstehen würde, muss man sich vorstellen. Für die Bewertung solcher Systeme ist das trotzdem wichtig. Die oben genannten Arbeiten von Kwasafo *et al.* (2026) und Al-Hebshi und Lübbe (2026) beobachten nicht, wie das System tatsächlich genutzt wird. Die vorliegende Evaluation legt nahe, dass die Beobachtung der eigenen Nutzung realistischere Ergebnisse zur Bedienbarkeit liefert als Einschätzungen nach einer Vorführung. Wer solche Systeme bewertet, sollte deshalb die Nutzung beobachten. Ob das auch für die Bewertung der Inhalte gilt, bleibt offen (Abschn. 5.2).

Auch die Zuverlässigkeit ist wichtig. In zwei von drei Sitzungen brach eine Anfrage wegen eines Timeouts ab. Im Workshop war die Nutzung ausdrücklich an einen störungsfreien Betrieb geknüpft worden (Abschn. 4.4.5; W-P6, Pos. 18). Nach Parasuraman und Riley (1997) mindern gelegentliche Ausfälle das Vertrauen kaum, solange ein System sonst zuverlässig arbeitet. Anhaltende Ausfälle schwächen es dagegen. Ob die Ausfälle länger angehalten hätten, ließ sich in den einzelnen Sitzungen nicht feststellen. Verzögerungen können außerdem dazu führen, dass Nutzende ein System aufgeben (Van Berkel *et al.* 2023, Kap. 5.2). Ursache der Ausfälle war die gewählte Konfiguration (Abschn. 5.2).

Ohne aufwendige Schulung auszukommen heißt also vor allem: Das Werkzeug darf weder zu umfangreich noch schwer zu bedienen sein. Eine kurze Einführung in die Oberfläche bleibt trotzdem nötig. Auch ein einfacher Einstieg setzt einen zuverlässigen Betrieb voraus.

5.2. Limitationen

Die Ergebnisse haben einige Limitationen, die im Rahmen dieser Arbeit beachtet werden müssen.

- **Stichprobe und Format:** Nur drei Personen nutzten den Prototyp selbst. Die Ergebnisse zur Bedienbarkeit beruhen deshalb auf drei Sitzungen. Keine dieser Personen arbeitete im Account Management. Das lag an der Verfügbarkeit der Teilnehmenden (Abschn. 3.3.1). Damit fehlt bei der eigenen Nutzung gerade die Rolle, die nach P1 den Entwurf beginnen würde. Die übrigen vier Personen sahen ein Video und antworteten schriftlich. Rückfragen waren dabei nicht möglich (Abschn. 3.6). Da die Gruppen aus unterschiedlichen Personen bestanden, lassen sich Unterschiede nicht allein auf das Format zurückführen. Alle Sitzungen nutzten dasselbe Szenario, andere Projektarten wurden also nicht untersucht. Auch die drei Live-Sitzungen sind nur eingeschränkt vergleichbar, da sich Hilfen und Konfiguration unterschieden (Abschn. 3.6). Hinzu kommt, dass der Autor wenig Erfahrung mit der Methode des Cognitive Walkthrough hatte. Die Moderation war zurückhaltend, und nicht nach jeder Aufgabe wurden dieselben Fragen gestellt. Dadurch äußerten sich die Teilnehmenden nicht zu jedem Schritt, und zu einzelnen Anforderungen fehlen Rückmeldungen.
- **Nähe zum Untersuchungsfeld:** Die Arbeit entstand während einer Werkstudententätigkeit im untersuchten Unternehmen. Dadurch war der Zugang zu den Beteiligten und Daten leichter. Die Tätigkeit half auch dabei, Abläufe und interne Begriffe richtig einzuordnen. Zugleich bewerteten die Teilnehmenden den Prototyp eines Kollegen, den P1 und P6 im Workshop mitgestaltet hatten. Ihre Urteile könn-

ten deshalb positiver ausgefallen sein als gegenüber einer externen Person (Dell *et al.* 2012). Dagegen spricht, dass die Teilnehmenden zahlreiche Mängel benannten. Moderation, Protokollierung und Auswertung übernahm allein der Autor. Die Auswertung zeigt daher auch seine Sicht auf das Untersuchungsfeld. Eine DCS sollte das Verhältnis zwischen Forschung und Praxis offenlegen und erklären, wie es die Ergebnisse beeinflusst (Wulf *et al.* 2015). Die Ergebnisse gelten zunächst für diesen Fall. Erst der Vergleich mit weiteren Design Case Studies kann zeigen, inwieweit sie übertragbar sind (Rohde *et al.* 2017).

- **Workshop ohne laufendes System:** Während des Workshops lief der Prototyp nicht und das Gespräch wurde nur in Notizen festgehalten (Abschn. 3.5.3). Die daraus abgeleiteten Änderungen beruhen auf Rückmeldungen zum erklärten Aufbau. Sie sind deshalb weniger stark in der Praxis verankert als die übrigen Anforderungen.
- **Keine Aneignungsstudie:** In der dritten Phase einer DCS wird untersucht, wie ein System über längere Zeit in der Praxis genutzt wird (Wulf *et al.* 2015). Das war im Rahmen dieser Arbeit nicht möglich. Jede Person nutzte den Prototyp nur einmal oder sah ihn im Video. Zeitersparnis und Akzeptanz konnten deshalb nur erfragt werden. Offen ist außerdem, ob die Beteiligten den Entwurf bei längerer Nutzung seltener prüfen und ob sich die vorgeschlagene Festlegung von Beginn und Freigabe im Prozess bewährt (*Human in Command*).
- **Synthetische Datenbasis:** DocBee und die Lessons-Learned-Liste waren nicht angebunden. Der Prototyp nutzte synthetische Demodaten. Reales Erfahrungswissen floss daher nur über die Fragen ein. Die Evaluation zeigt daher nur grundsätzlich, wie Hinweise aus realen Projekten den Entwurf beeinflussen könnten.
- **Keine systematische Prüfung der Suche:** Trefferzahl und Grenzwert wurden nur mit einzelnen Testanfragen und den Demodaten festgelegt. Embedding-Modelle wurden nicht miteinander verglichen (Abschn. 4.3). Daher ist noch offen, wie gut die Suche mit echten Daten funktioniert. In zwei von drei Sitzungen kam es zu Timeouts, weil die Embeddings lokal auf einem Rechner mit begrenzten Ressourcen berechnet wurden. Die Timeouts gehen damit auf die Konfiguration zurück, nicht auf das Verfahren. Kleinere Modelle wie *EmbeddingGemma* sollen laut ihren Entwicklern ähnlich gut abschneiden wie doppelt so große Modelle (Vera *et al.* 2025).
- **Anforderungen ohne Rückmeldung:** Zu F-03, F-06 und F-13 gibt es keine auswertbaren Rückmeldungen. Die Arbeit trifft daher keine Aussage zu diesen Anforderungen. F-03 galt als geklärt und wurde deshalb nicht gezielt abgefragt. F-06 ist nur indirekt über die Gliederung umgesetzt (Abschn. 4.2.2). F-13 lässt sich erst über mehrere Dialogrunden mit einer größeren Datenbasis untersuchen.
- **Modell und Absicherung:** Für den Dialog wurde ein LLM genutzt, das im Unternehmen nicht freigegeben ist. Ein freigegebenes Modell könnte andere Ergebnisse liefern. Mehrere Designziele werden nur durch den Systemprompt abgesichert (Abschn. 4.3). Es wurde nicht systematisch geprüft, ob das Modell diese Ziele zuverlässig einhält. In einer Sitzung legte das Modell zunächst nur Leistungsbereiche an (A-P3, A2).

5.3. Fazit

Diese Arbeit untersuchte, wie generative KI Projektplanungsverantwortliche mit einem Assistenzsystem bei der Erstellung von Projektstrukturplänen unterstützen kann. Die DCS beantwortet diese Frage nur teilweise:

Der Prototyp erstellt einen ersten Entwurf, den die Beteiligten weiterbearbeiten können. Ein fertiger Plan entsteht dabei nicht. Welche Inhalte in den Entwurf gehören, hängt davon ab, welche Rolle ihn zu welchem Zeitpunkt nutzt. Deshalb lässt sich ein solcher Entwurf nicht allein anhand einer Referenz bewerten. Erfahrungswissen kann auf zwei Wegen in den Entwurf gelangen: Über die Fragen des Systems und die Antworten der Nutzenden sowie über die Suche in Daten früherer Projekte. In dieser Arbeit erkannten die Teilnehmenden die Erfahrung der Projektleitung vor allem in den Fragen. Der Prototyp arbeitete mit synthetischen Daten. Offen bleibt, wie stark beide Wege den Entwurf jeweils beeinflussen. Formal liegt die Kontrolle über den Entwurf bei den Nutzenden. Fachlich prüfen kann ihn jedoch nur, wer das nötige Wissen hat. Dieses Wissen ist auf mehrere Rollen verteilt. Kontrolle lässt sich deshalb nicht allein im System gestalten. Der Prozess muss festlegen, wer den Entwurf prüft und freigibt, wie es *Human in Command* beschreibt. Die Evaluation deutet außerdem darauf hin, dass die Bedienbarkeit bei eigener Nutzung schlechter beurteilt wird als nach einer Video-Vorführung. Bewertungen solcher Systeme sollten deshalb die Nutzung beobachten.

Offen bleibt, wie sich das System im Arbeitsalltag bewährt. In den einzelnen Sitzungen ließ sich nur erfragen, ob es Zeit spart und langfristig genutzt würde. Für die Beteiligten ist das entscheidend: Ein Werkzeug, das „mehr Zeit kostet als bringt“, würden sie nicht nutzen (I-P6, Abs. 106). Eine längere Erprobung an eigenen Projekten kann diese Frage beantworten, wie der folgende Ausblick zeigt.

5.4. Ausblick

Die Evaluation und die Limitationen zeigen, welche Ansatzpunkte sich für die weitere Forschung ergeben.

- **Erfassung der Projektbeschreibung:** Die Fragen sollten zum jeweiligen Projekt passen. Dafür könnten je nach Projektart unterschiedliche Abläufe vorgesehen werden (W-P1, Pos. 6). Offene Angaben wie der Projektumfang sollten im Dialog erfasst werden. Bei kritischen Antworten sollte das System nachfragen, zum Beispiel bei einem „Nein“ zur Dokumentation (A-P6, A1). Die Projektbeschreibung bildet die Grundlage aller Suchanfragen. Deshalb sollte sie bestätigt werden, bevor das System nach ähnlichen Projekten sucht.
- **Darstellung und Bedienung:** Die neuen Anforderungen betreffen vor allem die Oberfläche (Tab. 9). Außerdem sollte es eine kurze Einführung geben. Ob eine Vorführung die Einschätzung der Bedienbarkeit verändert, ließe sich mit denselben Personen prüfen: Zuerst sehen sie ein Video, danach bedienen sie den Prototyp selbst.
- **Einbindung in den Prozess:** Gemeinsam mit den betroffenen Rollen sollte ein Prozess entwickelt werden. Darin ist festzulegen, wer den Entwurf beginnt und wer ihn freigibt, ohne den Vertrieb zu verlangsamen (P-02, P-03, T1).
- **Daten und Schnittstellen:** Eine Anbindung an DocBee und die Lessons-Learned-Liste würde Tests mit echten Daten ermöglichen, etwa mit unterschiedlich tief gegliederten Vorlagen (F-15). DocBee bietet dafür eine REST-Schnittstelle, über die

Vorgänge, Verknüpfungen und Leistungsdokumente ausgelesen werden können. Zuvor müssen historische Daten aufbereitet und die Lessons-Learned-Liste um eine Projekt-ID ergänzt werden. Außerdem braucht es einen geregelten Rückfluss der Daten aus abgeschlossenen Projekten (P-04, P-06). Ein Export in die Projektmanagement-Software oder nach DocBee wäre nützlicher als eine Markdown-Datei. Er sollte erst nach ausdrücklicher Freigabe erfolgen, und der Umfang sollte wählbar sein.

- **Transparenz der Zwischenschritte:** Bisher nutzt das System die Grobgliederung nur intern für die Suche. Es könnte sie anzeigen und vor der Erzeugung freigeben lassen. So könnten Nutzende die einzelnen Schritte sehen und steuern (Wu *et al.* 2022).
- **Technische Absicherung:** Es muss geklärt werden, ob Leistungsbereiche zugleich Arbeitspakete und Aufgaben enthalten dürfen (Abschn. 4.1.3). Bei Antworten außerhalb des vorgegebenen Schemas sollte das System automatisch erneut nachfragen. Außerdem sollte der Programmcode Punkte prüfen, die bisher nur durch den Systemprompt abgesichert sind (Abschn. 4.3).
- **Parameter und Modelle:** Mit echten Daten sollten Trefferzahl, Grenzwert und Embedding-Modell systematisch verglichen werden. Kleinere Modelle oder GPU-Hardware könnten die Timeouts beheben. Für den produktiven Einsatz sind ein freigegebenes Modell und eine rechtliche Absicherung nötig.
- **Weitere Funktionen:** Da mehrere Rollen am Entwurf arbeiten, sollten mehrere Personen ihn gemeinsam bearbeiten können (N-11). Noch offen sind außerdem ein Bedienelement, um Lessons Learned einzugrenzen, sowie die Spracheingabe und die Nutzung auf mobilen Geräten.
- **Wissen aus Fragen und Daten:** Mit echten Daten sollte untersucht werden, welchen Beitrag die Fragen und die Suche in früheren Projekten jeweils zum Entwurf leisten (Abschn. 5.1).
- **Aneignung im Arbeitsalltag:** Erst eine längere Aneignungsstudie mit eigenen Projekten kann zeigen, ob der Prototyp Zeit spart und genutzt wird (Wulf *et al.* 2015). Sie könnte außerdem klären, ob erfahrene Fachkräfte die Ergebnisse mit der Zeit seltener prüfen (P-07) und ob es sich bewährt, im Prozess festzulegen, wer den Entwurf beginnt und wer ihn freigibt.

6. Reflexion & Danksagung

Eine Design Case Study umfasst eine umfangreiche Untersuchung in der Praxis. Im Rahmen dieser Bachelorarbeit war nur eine verkürzte Durchführung möglich. Die Aneignung des Prototyps im Alltag konnte nicht untersucht werden. Ziel war es, möglichst viele Perspektiven einzubeziehen. Dafür wurden in der Vorstudie neun Personen aus allen beteiligten Rollen befragt und der Prototyp in zwei Gruppen evaluiert. Diese breite Anlage schöpfte den zeitlichen Rahmen weitgehend aus und ermöglichte zugleich Ergebnisse aus unterschiedlichen Perspektiven.

Bei der Erstellung der Arbeit kamen LLMs zum Einsatz. Wie genau, ist in Anhang C.3 dokumentiert. Die Modelle standen jederzeit für Rückfragen, Kritik und Formulierungsvarianten zur Verfügung. Die Hoffnung, dadurch sicherer zu arbeiten, erfüllte sich jedoch nicht. Sobald sich ein Ergebnis fachlich nicht einordnen ließ, half auch das Modell nicht weiter. Um die Ausgaben eines Modells beurteilen zu können, ist eigenes Vorwissen nötig. Deshalb wurden die Antworten immer wieder hinterfragt, ebenso die eigene Arbeit. Im Nachhinein zeigt sich darin dieselbe Erkenntnis wie in der Evaluation des Prototyps: Die Kontrolle über ein Ergebnis kann nur ausüben, wer es fachlich beurteilen kann.

Ich möchte mich an dieser Stelle bei allen bedanken, die mich während der Erstellung dieser Arbeit unterstützt haben. Ich danke dem Unternehmen, das mir die Möglichkeit gegeben hat, diese Arbeit im praktischen Kontext durchzuführen und allen Mitarbeitenden, die mich dabei unterstützt haben. Zudem bedanke ich mich bei meiner Betreuerin Sophie Degen für die kontinuierliche Begleitung meiner Arbeit. Ihre Erfahrung und ihr Fachwissen haben mir immer wieder gezeigt, wie man manchmal seine Methode flexibel anpassen muss, um zum Ziel zu kommen. Vor allem ihr Engagement, mich bei dem Schreibprozess zu unterstützen, hat mir sehr geholfen, diese Arbeit zu einem erfolgreichen Abschluss zu bringen. Ebenso möchte ich mich bei Lukas Schröder für die Unterstützung bei der Themenfindung bedanken und dem intensiven Austausch zu Beginn meiner Arbeit.

Literaturverzeichnis

Amershi, Saleema, Dan Weld, Mihaela Vorvoreanu, Adam Fourney, Besmira Nushi, Penny Collisson, Jina Suh *et al.* 2019. „Guidelines for Human-AI Interaction“. In *Proceedings of the 2019 CHI Conference on Human Factors in Computing Systems,* 1–13. CHI '19. Glasgow, Scotland Uk: Association for Computing Machinery. ISBN: 9781450359702. https://doi.org/10.1145/3290605.3300233. https://doi.org/10.1145/3290605.3300233.

Anthropic. 2024. „Building Effective Agents“. Anthropic. Besucht am 6. September 2026. https://www.anthropic.com/engineering/building-effective-agents.

Boren, T. und J. Ramey. 2000. „Thinking aloud: reconciling theory and practice“. *IEEE Transactions on Professional Communication* 43 (3): 261–278. https://doi.org/10.1109/47.867942.

Bowen, Glenn. 2009. „Document Analysis as a Qualitative Research Method“. *Qualitative Research Journal* 9 (August): 27–40. https://doi.org/10.3316/QRJ0902027.

Braun, Virginia und Victoria Clarke. 2006. „Using thematic analysis in psychology“ [auf en]. *Qualitative Research in Psychology* 3, Nr. 2 (Januar): 77–101. ISSN: 1478-0887, 1478-0895, besucht am 26. Juli 2026. https://doi.org/10.1191/1478088706qp063oa. https://www.tandfonline.com/doi/full/10.1191/1478088706qp063oa.

———. 2019. „Reflecting on reflexive thematic analysis“ [auf en]. *Qualitative Research in Sport, Exercise and Health* 11, Nr. 4 (August): 589–597. ISSN: 2159-676X, 2159-6778, besucht am 26. Juli 2026. https://doi.org/10.1080/2159676X.2019.1628806. https://www.tandfonline.com/doi/full/10.1080/2159676X.2019.1628806.

———. 2022. *Thematic analysis: A practical guide.* Los Angeles; London; New Delhi; Singapore; Washington DC; Melbourne: SAGE. ISBN: 9781473953239.

Buçinca, Zana, Maja Barbara Malaya und Krzysztof Z. Gajos. 2021. „To Trust or to Think: Cognitive Forcing Functions Can Reduce Overreliance on AI in AI-assisted Decision-making“. *Proceedings of the ACM on Human-Computer Interaction* 5 (CSCW1). https://doi.org/10.1145/3449287.

Bui, Thanh-Long, Hoa Khanh Dam und Rashina Hoda. 2025. „An LLM-based multi-agent framework for agile effort estimation“. *arXiv preprint arXiv:2509.14483,* arXiv: 2509.14483.

Chen, Jianlv, Shitao Xiao, Peitian Zhang, Kun Luo, Defu Lian und Zheng Liu. 2023. *M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation.* Version 5. arXiv: 2402.03216 [cs.CL]. https://arxiv.org/abs/2402.03216.

Dell, Nicola, Vidya Vaidyanathan, Indrani Medhi, Edward Cutrell und William Thies. 2012. „‚Yours is Better!‘: Participant Response Bias in HCI“. In *Proceedings of the SIGCHI Conference on Human Factors in Computing Systems,* 1321–1330. CHI '12. Austin, Texas, USA: Association for Computing Machinery. ISBN: 9781450310154. https://doi.org/10.1145/2207676.2208589. https://doi.org/10.1145/2207676.2208589.

Fries, Marco, Julia Nießner, Thomas Ludwig und Christoph Kotthaus. 2025. „Exploring AI Integration in SME Production Planning: Design Spaces and the Role of Workers“. *Computer Supported Cooperative Work (CSCW)* 34 (2): 293–330. https://doi.org/10.1007/s10606-025-09512-6.

Gao, Yunfan, Yun Xiong, Xinyu Gao, Kangxiang Jia, Jinliu Pan, Yuxi Bi, Yi Dai, Jiawei Sun, Meng Wang und Haofen Wang. 2023. „Retrieval-Augmented Generation for Large Language Models: A Survey“, arXiv: 2312.10997 [cs.CL]. https://arxiv.org/abs/2312.10997.

Gerbracht, Marc, Max Krüger, Débora De Castro Leal, Peter Tolmie und Volker Wulf. 2024. „‚We are no Luddites!‘-CSCW, Co-Determination and Digital Transformation in Germany“. *Proceedings of the ACM on Human-Computer Interaction* (New York, NY, USA) 8 (CSCW1): 1–23. https://doi.org/10.1145/3637430.

Gerlich, Michael. 2025. „AI Tools in Society: Impacts on Cognitive Offloading and the Future of Critical Thinking“. *Societies* 15 (Januar): 6. https://doi.org/10.3390/soc15010006.

Goodman, Leo. 1961. „Snowball Sampling“. *The Annals of Mathematical Statistics* 32 (März): 148–170. https://doi.org/10.1214/aoms/1177705148.

Al-Hebshi, Mohammed und Alexander Lübbe. 2026. „Creating Business Documents With LLMs – Architecture & Evaluation“. Wildauer Konferenz für Künstliche Intelligenz (WiKKI) 2026, *TH Wildau Engineering and Natural Sciences Proceedings* 3. https://doi.org/10.52825/th-wildau-ensp.v3i.3515.

Hochrangige Expertengruppe für künstliche Intelligenz. 2019. *Ethik-Leitlinien für eine vertrauenswürdige KI.* Brüssel: Europäische Kommission.

Hoerner, Lorenz, Markus Schamberger und Freimut Bodendorf. 2023. „Using Tacit Expert Knowledge to Support Shop-floor Operators Through a Knowledge-based Assistance System“. *Computer Supported Cooperative Work (CSCW)* 32 (1): 55–91. https://doi.org/10.1007/s10606-022-09445-4.

Horvitz, Eric. 1999. „Principles of mixed-initiative user interfaces“. In *Proceedings of the SIGCHI Conference on Human Factors in Computing Systems,* 159–166. CHI '99. Pittsburgh, Pennsylvania, USA: Association for Computing Machinery. ISBN: 0201485591. https://doi.org/10.1145/302979.303030. https://doi.org/10.1145/302979.303030.

Jacobs, Maia, Melanie F.Pradier, Thomas McCoy, Roy Perlis, Finale Doshi velez und Krzysztof Gajos. 2021. „How machine-learning recommendations influence clinician treatment selections: the example of the antidepressant selection“. *Translational Psychiatry* 11 (Februar). https://doi.org/10.1038/s41398-021-01224-x.

Kalenborn, Axel. 2014. „Anforderungserhebung in der Vorvertragsphase“. In *Angebotserstellung und Planung von Internet-Projekten: Die werkzeugbasierte "Modeling by Example"-Methode,* 65–124. Wiesbaden: Springer Fachmedien Wiesbaden. ISBN: 978-3-658-07950-5. https://doi.org/10.1007/978-3-658-07950-5_3.

Kandpal, Nikhil, Haikang Deng, Adam Roberts, Eric Wallace und Colin Raffel. 2023. *Large Language Models Struggle to Learn Long-Tail Knowledge.* arXiv: 2211.08411 [cs.CL]. https://arxiv.org/abs/2211.08411.

Kaplan, Alexandra D., Theresa T. Kessler, J. Christopher Brill und P. A. Hancock. 2023. „Trust in Artificial Intelligence: Meta-Analytic Findings“. PMID: 34048287, *Human Factors* 65 (2): 337–359. https://doi.org/10.1177/00187208211013988. eprint: https://doi.org/10.1177/00187208211013988. https://doi.org/10.1177/00187208211013988.

Karakurt, Ehlullah und Akhan Akbulut. 2026. „Retrieval-Augmented Generation (RAG) and Large Language Models (LLMs) for Enterprise Knowledge Management and Document Automation: A Systematic Literature Review“. *Applied Sciences* 16 (1): 368. ISSN: 2076-3417. https://doi.org/10.3390/app16010368. https://www.mdpi.com/2076-3417/16/1/368.

Kaufhold, Marc-André, Thea Riebe, Markus Bayer und Christian Reuter. 2024. „'We Do Not Have the Capacity to Monitor All Media': A Design Case Study on Cyber Situational Awareness in Computer Emergency Response Teams“. In *Proceedings of the CHI Conference on Human Factors in Computing Systems (CHI '24),* 1–16. https://doi.org/10.1145/3613904.3642368.

Kwasafo, Oscar Kwame, Ehsan Saghatforoush und Neil Govender. 2026. „A generative AI model for automating construction bid preparation“. *International Journal of Construction Management,* 1–21. https://doi.org/10.1080/15623599.2026.2629023.

Langer, Markus und Richard N. Landers. 2021. „The future of artificial intelligence at work: A review on effects of decision automation and augmentation on workers targeted by algorithms and third-party observers“. *Computers in Human Behavior* 123:106878. ISSN: 0747-5632. https://doi.org/10.1016/j.chb.2021.106878. https://www.sciencedirect.com/science/article/pii/S0747563221002016.

Lewis, Clayton und Cathleen Wharton. 1997. „Chapter 30 - Cognitive Walkthroughs“. In *Handbook of Human-Computer Interaction (Second Edition),* Second Edition, herausgegeben von Marting G. Helander, Thomas K. Landauer und Prasad V. Prabhu, 717–732. Amsterdam: North-Holland. ISBN: 978-0-444-81862-1. https://doi.org/10.1016/B978-044481862-1.50096-0. https://www.sciencedirect.com/science/article/pii/B9780444818621500960.

Madaan, Aman, Niket Tandon, Prakhar Gupta, Skyler Hallinan, Luyu Gao, Sarah Wiegreffe, Uri Alon *et al.* 2023. „Self-Refine: Iterative Refinement with Self-Feedback“. In *Advances in Neural Information Processing Systems 36 (NeurIPS 2023).* https://doi.org/10.52202/075280-2019. https://arxiv.org/abs/2303.17651.

Mahatody, Thomas, Mouldi Sagar und Christophe Kolski. 2010. „State of the Art on the Cognitive Walkthrough Method, Its Variants and Evolutions“. *Int. J. Hum. Comput. Interaction* 26 (Juli): 741–785. https://doi.org/10.1080/10447311003781409.

Mcdonald, Sharon, Helen Edwards und Tingting Zhao. 2012. „Exploring Think-Alouds in Usability Testing: An International Survey“. *IEEE Transactions on Professional Communication* 55 (März): 2–19. https://doi.org/10.1109/TPC.2011.2182569.

Nguyen, Lan, James Connolly und Hoa Nguyen. 2025. „A Systematic Review of Improving Knowledge Management with Generative AI and Large Language Models“. *Journal of Advances in Information Technology* 16 (Januar): 594–612. https://doi.org/10.12720/jait.16.4.594-612.

Nonaka, Ikujiro und Hirotaka Takeuchi. 2012. *Die Organisation des Wissens* [auf ger]. 2. Aufl. 320. Campus Frankfurt / New York. ISBN: 9783593416625. https://content-select.com/de/portal/media/view/519cc29a-f4f0-4607-950b-253e5dbbeaba.

Normung e.V., DIN Deutsches Institut für. 2009. *Projektmanagement - Projektmanagementsysteme - Teil 5: Begriffe.* https://doi.org/10.31030/1498911.

Parasuraman, Raja und Victor Riley. 1997. „Humans and Automation: Use, Misuse, Disuse, Abuse“. *Human Factors* 39 (2): 230–253. https://doi.org/10.1518/001872097778543886.

Parasuraman, Raja, Thomas Sheridan und Christopher Wickens. 2000. „A model for types and levels of human interaction with automation“. *IEEE Transactions on Systems, Man, and Cybernetics - Part A: Systems and Humans* 30 (Juni): 286–297. https://doi.org/10.1109/3468.844354.

Patton, Michael Quinn. 2014. *Qualitative research & evaluation methods: Integrating theory and practice.* Sage publications.

Pohl, Klaus und Chris Rupp. 2010. *Basiswissen Requirements Engineering - Aus- und Weiterbildung zum Certified Professional for Requirements Engineering: Foundation Level nach IREB-Standard (2. Aufl.)* dpunkt.verlag. ISBN: 978-3-89864-708-3. http://www.dpunkt.de/buecher/3462.html.

Polanyi, Michael. 1966. *The Tacit Dimension.* London: Routledge & Kegan Paul.

Risko, Evan F. und Sam J. Gilbert. 2016. „Cognitive Offloading“. *Trends in Cognitive Sciences* 20 (9): 676–688. ISSN: 1364-6613. https://doi.org/10.1016/j.tics.2016.07.002. https://www.sciencedirect.com/science/article/pii/S1364661316300985.

Rohde, Markus, Peter Brödner, Gunnar Stevens, Matthias Betz und Volker Wulf. 2017. „Grounded Design - a praxeological IS research perspective“. *Journal of Information Technology* 32 (2): 110–121. https://doi.org/10.1057/jit.2016.5. https://doi.org/10.1057/jit.2016.5.

Schröder, Martin. 2023. „AutoScrum: Automating Project Planning Using Large Language Models“. *arXiv preprint arXiv:2306.03197,* arXiv: 2306.03197.

Suchman, Lucille Alice. 1987. *Plans and situated actions: The problem of human-machine communication.* Cambridge: Cambridge University Press.

Sumers, Theodore R., Shunyu Yao, Karthik Narasimhan und Thomas L. Griffiths. 2024. „Cognitive Architectures for Language Agents“. *Transactions on Machine Learning Research (TMLR),* https://arxiv.org/abs/2309.02427.

Tessmer, Jana. 2023. „Soziotechnische Systeme“. In *Assistive Technologien, technische Rehabilitation und Unterstützte Kommunikation bei neurologischen Erkrankungen,* herausgegeben von Martin Groß, Birgit Hennig, Stefan Kappel und Frank Wallhoff, 37–41. Berlin, Heidelberg: Springer. ISBN: 978-3-662-64117-0. https://doi.org/10.1007/978-3-662-64118-7_4.

Twidale, Michael, David Randall und Richard Bentley. 1994. „Situated evaluation for cooperative systems“. In *Proceedings of the 1994 ACM Conference on Computer Supported Cooperative Work,* 441–452. CSCW '94. Chapel Hill, North Carolina, USA: Association for Computing Machinery. ISBN: 0897916891. https://doi.org/10.1145/192844.193066. https://doi.org/10.1145/192844.193066.

Van Berkel, Niels, Maura Bellio, Mikael B Skov und Ann Blandford. 2023. „Measurements, algorithms, and presentations of reality: Framing interactions with AI-enabled decision support“. *ACM Transactions on Computer-Human Interaction* 30 (2): 1–33. https://doi.org/10.1145/3571815.

Vera, Henrique Schechter, Sahil Dua, Biao Zhang, Daniel Salz, Ryan Mullins, Sindhu Raghuram Panyam, Sara Smoot *et al.* 2025. *EmbeddingGemma: Powerful and Lightweight Text Representations.* arXiv: 2509.20354 [cs.CL]. https://arxiv.org/abs/2509.20354.

Wong, Kuan Yew und Elaine Aspinwall. 2004. „Characterizing knowledge management in the small business environment“. *Journal of Knowledge Management* 8 (Juni): 44–61. https://doi.org/10.1108/13673270410541033.

Wu, Tongshuang, Michael Terry und Carrie Jun Cai. 2022. „AI Chains: Transparent and Controllable Human-AI Interaction by Chaining Large Language Model Prompts“. In *Proceedings of the 2022 CHI Conference on Human Factors in Computing Systems.* CHI '22. New York, NY, USA: Association for Computing Machinery. https://doi.org/10.1145/3491102.3517582. https://doi.org/10.1145/3491102.3517582.

Wulf, Volker, Claudia Müller, Volkmar Pipek, David Randall, Markus Rohde und Gunnar Stevens. 2015. „Practice-Based Computing: Empirically Grounded Conceptualizations Derived from Design Case Studies“. In *Designing Socially Embedded Technologies in the Real-World,* herausgegeben von Volker Wulf, Kjeld Schmidt und David Randall, 111–150. London: Springer London. ISBN: 978-1-4471-6720-4. https://doi.org/10.1007/978-1-4471-6720-4_7. https://doi.org/10.1007/978-1-4471-6720-4_7.

Yao, Shunyu, Jeffrey Zhao, Dian Yu, Nan Du, Izhak Shafran, Karthik Narasimhan und Yuan Cao. 2023. „ReAct: Synergizing Reasoning and Acting in Language Models“. In *The Eleventh International Conference on Learning Representations (ICLR).* https://arxiv.org/abs/2210.03629.

Zhang, Yue, Yafu Li, Leyang Cui, Deng Cai, Lemao Liu, Tingchen Fu, Xinting Huang *et al.* 2025. *Siren's Song in the AI Ocean: A Survey on Hallucination in Large Language Models.* arXiv: 2309.01219 [cs.CL]. https://arxiv.org/abs/2309.01219.

KMU kleine und mittlere Unternehmen
PSP Projektstrukturplan
GD Grounded Design
DCS Design Case Study
RAG Retrieval-Augmented Generation
LLM Large Language Model
KI Künstliche Intelligenz
HCI Human-Computer Interaction
CSCW Computer-Supported Cooperative Work
TA Thematische Analyse
IT Informationstechnik

Tabellenverzeichnis

1. Teilnehmende der Design Case Study. 17
2. Funktionale Anforderungen 62
3. Nicht-funktionale Anforderungen 63
4. Soziotechnische Anforderungen 63
5. Prozessuale Anforderungen 64
6. Anforderungen und abgeleitete Designziele 65
7. Änderungen am Anforderungskatalog durch den Workshop 66
8. Ergebnis der Evaluation je Anforderung 66
9. Neue Anforderungen aus der Evaluation 67
10. Fragen des geführten Einstiegs 74
11. Eingesetzte KI-Werkzeuge im Rahmen dieser Arbeit 87

Abbildungsverzeichnis

1. Funktionsweise von RAG mit einer Vektordatenbank 9
2. Angebotsprozess im untersuchten Unternehmen 16
3. Evaluationsdesign mit zwei Teilnehmendengruppen 22
4. Zielstruktur eines Projekts in DocBee 29
5. Oberfläche der Planungsphase 38
6. Mindmap der reflexiven thematischen Analyse 71
7. Phasen des Workflows 73
8. Beschreibungsphase mit Rückfragen 75
9. Geführter Einstieg 75
10. Hinweis aus den Lessons Learned im Dialog 76
11. Exportphase 76

Listings

1. Systemprompt: Rollenbeschreibung 77
2. Systemprompt der Beschreibungsphase 77
3. Prompt der Grobgliederung 77
4. Systemprompt der Planungsphase 78
5. Pydantic-Schema der Beschreibungsphase 79
6. Pydantic-Schema der Grobgliederung 80
7. Pydantic-Schema des Projektstrukturplans 80
8. Collection der Lessons Learned 81
9. Collection der Projektstrukturen 81
10. Prompt zur Erzeugung der Lessons Learned 82
11. Prompt zur Erzeugung der Projektstrukturen 82

Tab. 2: Funktionale Anforderungen

ID	Anforderung	Quelle
F-01	Ausgabe einer strukturierten, weiterbearbeitbaren Arbeitsgrundlage, die als Zwischenstand dient	T2,3,6
F-02	Untergliederung in Leistungsbereiche, Arbeitspakete und Aufgaben mit zugeordnetem Aufwand, nicht feiner als ein Tag je Aufgabe	T1,2,5; R
F-03	Das Arbeitspaket ist eine optionale Zwischenebene; verbindlich sind Hauptvorgang, Leistungsbereich und Aufgabe	T5; R
F-04	Beschreibung auf der Aufgabenebene, auf der die Aufwände gebucht werden, mit Abgrenzung gegenüber nicht enthaltenen Leistungen	T1,2; D; R
F-05	Leistungsbereiche werden nach Themengebieten bzw. Skill-Teams gebildet	T5
F-06	Abbildung von Abhängigkeiten und Reihenfolgen zwischen Aufgaben, ohne feste Termine	T5
F-07	Geführte Erfassung im Dialog mit Freitexteingabe statt starrem Formular	T3,5,6
F-08	Mindesteingaben zu Kunde, Projektkategorie, Inhalt, Zeitrahmen und bekannter Hardware	T5
F-09	Rückfragen nur zu fehlenden Angaben, begrenzt und jederzeit überspringbar	T1,6
F-10	Auffinden vergleichbarer abgeschlossener Projekte als Strukturvorlage	T1,3,5
F-11	Auffinden inhaltlich ähnlicher Lessons Learned als Hinweise auf bekannte Stolperstellen	T1,2,3; LL
F-12	Lessons Learned nach Projektart, Projektphase und Skill-Team eingrenzbar	LL
F-13	Inhaltlich gleiche Hinweise und Beschreibungen werden nicht mehrfach ausgegeben	T3; LL; D
F-14	Anzeige historischer Aufwandswerte in Tagen als Orientierung, nicht als verbindlicher Referenzwert	T3,5; D; R
F-15	Ergebnisausgabe auch bei unvollständiger Informationslage, sowohl bei groben Eingaben als auch bei unterschiedlich tief strukturierten Vorlagen	T1,6; D
F-16	Die Ebenenzugehörigkeit eines Vorgangs wird aus den vergebenen Tags abgeleitet	D
F-17	Unsichere Angaben werden ausgelassen oder gekennzeichnet, belegte Angaben weisen ihre Quelle aus	T1,3,6; LL; D
F-18	Nachträgliche Anpassung von Inhalt und Reihenfolge einzelner Elemente ohne vollständige Neuerzeugung	T3,4,6
F-19	Ausgabe in ein weitergebbares Dokumentformat	T1
F-20	Eingabe per Sprache und auf mobilen Endgeräten	T6

Quelle: T1 bis T6, Themen der thematischen Analyse (Abschn. 4.1.1); D, DocBee; LL, Lessons-Learned-Liste; R, Rückfragen

Tab. 3: Nicht-funktionale Anforderungen

ID	Anforderung	Quelle
NF-01	Ein erster Entwurf liegt in etwa einer halben Stunde vor	T6
NF-02	Der Zeitgewinn übersteigt den Prüf- und Korrekturaufwand	T1,6
NF-03	Intuitive Nutzung ohne vorherige Schulung	T6
NF-04	Das Ergebnis ist plausibel lesbar, nicht nur formal korrekt	T6
NF-05	Kompakte Ausgabe im Umfang von ein bis zwei Seiten	T5
NF-06	Quellenangaben überladen die Darstellung nicht, sie stehen auf Abruf bereit	T6
NF-07	Verarbeitung personenbezogener Daten nur mit Auftragsverarbeitungsvertrag und Datenschutzfolgenabschätzung	LL; D
NF-08	Keine personenbezogene Auswertung von Bearbeitungszeiten historischer Projekte	T6; D
NF-09	Anbindung an die Quellsysteme DocBee und Lessons-Learned-Liste	T5; LL

Quelle: T1 bis T6, Themen der thematischen Analyse (Abschn. 4.1.1); D, DocBee; LL, Lessons-Learned-Liste

Tab. 4: Soziotechnische Anforderungen

ID	Anforderung	Quelle
ST-01	Die Erstplanung funktioniert ohne Beteiligung der Projektleitung, eine abschließende Durchsicht bleibt vorgesehen	T1,2,5
ST-02	Erfahrungswissen der Projektleitung fließt ein, ohne dass sie eingebunden werden muss	T2
ST-03	Die Verantwortung für das Ergebnis bleibt beim Menschen, Vorschläge sind nicht verbindlich	T4,6
ST-04	Die Nutzung bleibt freiwillig. Die Beteiligten entscheiden selbst, ob ihnen das System hilft	T1,3,4
ST-05	Der Entwurf strukturiert die spätere Bearbeitung und Abstimmung vor und ersetzt sie nicht	T2,6
ST-06	Der Vertrieb entscheidet, wie der Entwurf für das Angebot aufbereitet wird	T4
ST-07	Nutzbarkeit im Zeitraum zwischen Angebotsanfrage und Auftragseingang	T2

Quelle: T1 bis T6, Themen der thematischen Analyse (Abschn. 4.1.1)

Tab. 5: Prozessuale Anforderungen

ID	Anforderung	Quelle
P-01	Die Erfassung von Erfahrungswissen verursacht geringen Aufwand und ist in den Projektablauf eingebettet	T3; LL; R
P-02	Für die Erstellung der Planungsgrundlage besteht ein definierter Prozess, in den das Werkzeug eingebunden ist	T4
P-03	Die betroffenen Rollen werden bei der Einführung einbezogen	T6
P-04	Es besteht eine einheitliche Datenablage, in der die Projektdokumentation implizites Wissen festhält	T1
P-05	Nicht mehr genutzte Felder der Lessons-Learned-Liste werden bereinigt	LL
P-06	Erkenntnisse aus abgeschlossenen Projekten fließen in die Datenbasis zurück	T3; LL
P-07	Die Ergebnisse werden über einen längeren Zeitraum durch erfahrene Fachkräfte geprüft	T6

Quelle: T1 bis T6, Themen der thematischen Analyse (Abs. 4.1.1); LL, Lessons-Learned-Liste; R, Rückfragen

Tab. 6: Anforderungen und abgeleitete Designziele

Anf.	Designziel
Erfassung der Projektbeschreibung	
F-07	Erfassung im Dialog über Freitext. Das System führt über Rückfragen statt über ein Formular.
F-08	Die Mindestangaben bilden die Checkliste, gegen die die Vollständigkeit der Beschreibung beurteilt wird.
F-09	Rückfragen nur zu offenen Angaben und in kleinen Portionen. Nicht-Wissen gilt als Antwort, und der Übergang zur Planung ist jederzeit möglich.
Wissensbasis	
F-10, F-11	Suche nach vergleichbaren Leistungsbereichen abgeschlossener Projekte und nach Lessons Learned je Leistungsbereich, ergänzt um übergreifende Einträge.
F-12	Projektart, Projektphase und Skill-Team werden als filterbare Metadaten vorgehalten. Die Eingrenzung kann damit erweitert werden.
F-13	Bereits vorgelegte Hinweise werden nicht erneut eingebracht.
Erzeugung und Bearbeitung des Strukturplans	
F-02, F-03	Festes Schema aus Leistungsbereich, optionalem Arbeitspaket und Aufgabe mit Aufwand in Personentagen.
F-04, NF-05	Jeder Knoten beschreibt Aufwand, Leistung und Abgrenzung. Abweichend von F-04 bedarf es einer ausführlichen Aufarbeitung auf Ebene der Leistungsbereiche, darunter genügen knappe Angaben.
F-05	Leistungsbereiche werden als fachliche Themenblöcke aus der Beschreibung gebildet.
F-06	Die Reihenfolge ergibt sich aus Gliederung und Nummerierung. Abhängigkeiten werden nur implizit über diese Reihenfolge abgebildet.
F-14	Historische Plan- und Ist-Aufwände dienen als Orientierung in Personentagen. Jede Schätzung nennt ihre Grundlage.
F-15, F-17	Fehlende Angaben werden als „offen“ gekennzeichnet statt ergänzt. Ein Entwurf entsteht auch aus einer unvollständigen Beschreibung und aus Vorlagen, die nur bis zur Ebene der Leistungsbereiche reichen.
F-17, NF-06	Jeder Knoten führt die eingeflossenen Referenzprojekte als Quelle, abrufbar statt dauerhaft eingeblendet.
F-18, ST-03	Änderungen setzen auf dem bestehenden Entwurf auf. Jeder Knoten ist direkt bearbeitbar, und Hinweise werden erst nach Zustimmung übernommen.
Rahmen und Ausgabe	
F-01, ST-05	Der Entwurf ist ein Zwischenstand: Offene Angaben und Aufwände bleiben sichtbar gekennzeichnet und dienen als Grundlage der anschließenden Abstimmung.
F-19, ST-06	Export als internes, weiterbearbeitbares Textdokument ohne kundengerichtete Aufbereitung, sobald ein Entwurf vorliegt.
NF-03	Die Phasen sind in einer Seitenleiste sichtbar und lassen sich frei wählen.
ST-07	Der Entwurf entsteht aus einer formlosen Anfrage, ohne dass ein Projekt in den Quellsystemen angelegt sein muss.
NF-07, NF-08	Die Modellanbindung ist für lokal betriebene oder freigegebene Modelle austauschbar. Aufwände werden je Leistungsbereich ausgewertet, nie je Person.
ST-01, ST-02	Erfahrungswissen der Projektleitung wird über historische Projektstrukturen und Lessons Learned eingebracht, sodass ein Entwurf ohne deren Beteiligung entsteht.
Nicht Gegenstand des Entwurfs	
F-16, F-20, NF-09	F-16 und NF-09 werden durch synthetische Daten im Zielschema ersetzt und F-20 liegt außerhalb des Rahmens des Prototyps.
NF-01, NF-02, NF-04, ST-04	Prüfkriterien der Evaluation (Abschn. 4.4).
NF-10, NF-11	Aus dem Workshop hervorgegangen (Abschn. 4.2.3).
P-01–P-07	Anforderungen an das Unternehmen, nicht an den Prototyp (Kapitel 5).

Tab. 7: Änderungen am Anforderungskatalog durch den Workshop

ID	Änderung	Quelle
F-07	ergänzt: Der Freitext wird um einen geführten Einstieg über Standardfragen ergänzt	W-P1, Pos. 10; W-P6, Pos. 12
F-08	ergänzt: Software und Lizenzen, Compliance, Dokumentation, Schulungen und bekannte Hürden beim Kunden	W-P1, Pos. 8–9
NF-10	neu: Technische Zuverlässigkeit im Betrieb als Voraussetzung der Nutzung	W-P6, Pos. 18
NF-11	neu: Oberfläche im Unternehmensdesign	W-P1, Pos. 13

Tab. 8: Ergebnis der Evaluation je Anforderung

Erfüllt (7) F-01, F-10, F-15 (nur für grobe Eingaben geprüft), F-18, NF-06, ST-02, ST-03
Eingeschränkt erfüllt (12) F-02, F-04, F-05, F-07, F-08, F-09, F-11, F-14, F-17, F-19, NF-03, NF-05
Nicht erfüllt (1) NF-10
Erfragt (7) NF-01, NF-02, NF-04, ST-01, ST-04, ST-05, ST-07
Umgesetzt, ohne auswertbare Rückmeldung (3) F-03, F-06, F-13
Nicht prüfbar (15) F-12, F-16, F-20, NF-07 bis NF-09, NF-11 (nicht umgesetzt oder im Ablauf nicht sichtbar); ST-06, P-01 bis P-07 (Anforderungen an das Unternehmen)

Tab. 9: Neue Anforderungen aus der Evaluation

ID	Bedarf	Bezug	Quelle
Darstellung			
N-01	Entwurf im Mittelpunkt, Chat und Hinweise ausblendbar	NF-03, NF-05	P1, P3
N-02	Lessons Learned getrennt vom Chat, mit Sprungmarken	F-11	P1, P6
N-04	Beschreibungstexte einklappbar oder als Eingabefeld	NF-05	P3, P6
N-09	Responsive Darstellung und Dark Mode	–	P6
Orientierung und Absicherung			
N-03	Bestätigung vor Löschen und vor „Neuer Chat“	F-18	P1, P3
N-05	Einleitung zu den Einstiegswegen, Überschriften je Bereich	NF-03	P3
N-06	Übersicht beantworteter und offener Fragen	F-09	P3
N-10	Symbole ohne falsche Interaktionserwartung	NF-03	P6
Erfassung			
N-07	Fragen und erzeugte Begriffe am internen Sprachgebrauch ausrichten	F-04, F-08	P3
N-08	Offene Angaben wie den Projektumfang im Dialog statt im Fragenkatalog erfassen	F-09	P1
Funktionsumfang			
N-11	Mehrbenutzerfähigkeit	neu	P1, P6, (P3)
N-12	Projektphasen als Oberkategorie	F-02	P2
N-13	Grafische Darstellung des Strukturplans, auch im Export	F-19	P2
N-14	Historische Daten zu- und abschaltbar	F-14, ST-03	P6

A. Vorstudienmaterial

Dieser Anhang enthält das Material, das im Rahmen der Vorstudie erhoben und analysiert wurde.

A.1. Interviewleitfaden

Der Leitfaden diente als Orientierung. Nicht alle Fragen wurden in jedem Interview gestellt. Reihenfolge und Nachfragen wurden an die Rolle der befragten Person angepasst (Abschnitt 3.4.1).

Rolle und Tätigkeiten

1. Was sind aktuell deine Hauptaufgaben im Unternehmen?
2. Wie oft hast du mit der Erstellung von Strukturplänen zu tun, und an welcher Stelle kommst du normalerweise mit dem Projektstrukturplan in Berührung?

Berührungspunkte mit Projektstrukturplänen im Ist-Prozess

- Wenn du einen neuen Projektstrukturplan für ein Angebot erstellen müsstest: Wie gehst du Schritt für Schritt vor?
  - Was macht diesen Prozess besonders, und wie unterscheidet er sich von anderen Angeboten (etwa aus dem Inside Sales)?
- Welche Werkzeuge, Vorlagen oder Dokumente hast du dabei parallel offen? In welchen Dateiformaten und an welchen Orten liegt der Projektstrukturplan vor?
- Wie nutzt du alte Projekte? Wonach suchst du dabei?
- Welche Informationen brauchst du zwingend vom Kunden oder von anderen Abteilungen (z. B. Account Management), um den Projektstrukturplan aufsetzen zu können? Wie erreichen dich diese Informationen?
- Wer gibt den Projektstrukturplan aktuell frei, und wie wird die Qualität gesichert?

Nutzung von KI-Werkzeugen

- Nutzt du heute schon KI-Chats, Agenten oder andere KI-Werkzeuge bei deiner Arbeit? Wenn ja, wofür, und wie prüfst du die Ergebnisse?

Probleme in Prozess und Tätigkeit

- Was stört dich bei der Erstellung des Projektstrukturplans aktuell am meisten oder kostet unnötig viel Zeit?
- Wie gehst du vor, wenn dir Informationen vom Kunden fehlen?
- Wie nutzt du Erfahrungen (Lessons Learned) aus alten Projekten? Wie wichtig sind dir solche Informationen für die Angebotserstellung, und wo werden sie dokumentiert?
- Erinnere dich an ein Angebot, bei dem der Projektstrukturplan schiefgegangen ist oder großen Stress verursacht hat: Was ist passiert, und wo lag der Fehler?
- Denk im Gegenzug an den am besten gelungenen Projektstrukturplan, den du erstellt hast: Warum lief das gut? Was war vorhanden, was sonst oft fehlt?
- Musstest du schon einmal Arbeitspakete oder Entscheidungen erklären?

Erwartungen an ein KI-gestütztes Assistenzsystem

- Stell dir vor, eine KI erstellt dir den Projektstrukturplan auf Knopfdruck. Was ist dein erster Gedanke?
  - Was müsste die KI dir zeigen, damit du dem Plan vertraust und ihn weitergibst?
- Wie sollte das Ergebnis aussehen?
- Wo siehst du dich selbst und die KI in diesem Prozess? Wer sollte am Ende das letzte Wort und die Verantwortung haben?
- Wie sollte die Interaktion zwischen dir und der KI aussehen, etwa als Chat, als Formular mit Eckdaten oder vollautomatisch aus einem Kundendokument?
- Wenn der Plan Fehler enthält: Wie leicht muss es sein, sie zu korrigieren?
- Auf welche Dokumente und Systeme sollte die KI zugreifen können, um denselben Kontext wie du zu haben? Auf welche Daten darf sie keinesfalls zugreifen?
- Wie tief soll die KI den Plan gliedern? Reichen grobe Projektphasen, oder erwartest du konkrete Arbeitspakete mit ersten Aufwandsschätzungen?
- Welche Befürchtungen oder Sorgen hast du? Siehst du deine Arbeit gefährdet?
- Welcher Aussage stimmst du eher zu?
  - Ich teile mein Wissen gern mit allen.
  - Ich teile mein Wissen gern, möchte aber in einigen Bereichen Experte bleiben.
  - Ich teile mein Wissen eher ungern, weil ich ohne mein Spezialwissen ersetzbar wäre.

Vorstellungen möglicher Veränderungen und Bedingungen für die Nutzung

- Geld und Technik spielen keine Rolle, und wir sind im Jahr 2030. Beschreibe dein Wunschszenario, wie laufen Angebotserstellung und Projektstrukturplanung ab, und wer macht was?
- Welche Elemente davon sind dir am wichtigsten? Was ist eine klare Bedingung, damit du das Werkzeug im Alltag nutzt?
- Was müsste die KI dir anzeigen, damit du dem Plan vertraust, etwa Verweise auf frühere Projekte?
- Gibt es ein Kriterium, bei dem du das Werkzeug nicht nutzen würdest?
- Was ist wichtig, damit das Werkzeug auch künftig für das gesamte Team funktioniert und gepflegt werden kann?

A.2. Rückfragen

Rückfragen an P1 über Microsoft Teams:

Lessons-Learned-Liste (Frage 10.08., Antwort 11.08.)

Frage: Es gibt ein Feld „Kategorie (Test-Phase)“. Wofür steht dieses Feld, und ist es noch aktuell?

Antwort: „war mal ne Idee, ist nicht mehr aktuell“

Frage: Es gibt Zeiträume, in denen kaum oder keine Lessons Learned gepflegt wurden. Lag das daran, dass es keine gab, dass sie nicht interessant genug waren, oder fehlte die Awareness?

Antwort: „Ja da kommt alles zusammen, fehlende Awareness, wenig Lessons Learned usw.“

Projektdaten in DocBee (Fragen 26.08., Antworten 31.08.)

Frage: In allen Beschreibungen steht der Satz „Die erforderliche Zeit ist geschätzt, Berechnung erfolgt nach Zeitaufwand“. Was hat es damit auf sich?

Antwort: „die Absicherung [...] Wir schätzen 10 Tage DL, damit der Kunde einen Wert hat, mit dem er planen kann. Aber wir wissen ja, dass es immer wieder zu Abweichungen kommt. Wir teilen dem Kunden damit also mit: Rechne mal mit 10 Tagen, aber es wird nach Aufwand berechnet. [...] Ob dann im Ernstfall wirklich 15 berechnet werden, hängt von vielen Faktoren ab. Aber erstmal ist das einfach eine Art Absicherung.“

Frage: Schätzt ihr immer in ganzen Tagen?

Antwort: „Ja“

Frage: Im aktuellen Projekt liegen Aufgaben teilweise direkt unter Leistungsbereichen. Warum wird dort von der Struktur (Hauptvorgang, Leistungsbereich, Arbeitspaket, Aufgabe) abgewichen, und woran machst du fest, wann kein Arbeitspaket gebildet wird?

Antwort: „Oftmals macht eine mehrstufige Unterteilung nicht unbedingt Sinn. Wir haben daher beschlossen, dass Zeiten immer auf Aufgaben gebucht werden müssen und Leistungsbereiche als Stufe gesetzt ist. Was demnach wegfallen darf, sind die Arbeitspakete. [...] Es können also unter Leistungsbereichen direkt Aufgaben angelegt werden, wenn dies Sinn macht. Was es immer geben MUSS, ist Hauptvorgang (Projektname), Leistungsbereiche und Aufgaben.“ Der Antwort war folgendes Beispiel beigefügt:

```
Hauptvorgang
  Leistungsbereich 1
    Aufgabe 1
    Aufgabe 2
    Arbeitspaket 1
      Aufgabe 1.1
    Arbeitspaket 2
      Aufgabe 2.1
      Aufgabe 2.2
  Leistungsbereich 2
    Aufgabe 3
    Aufgabe 4
```

A.3. Thematische Analyse

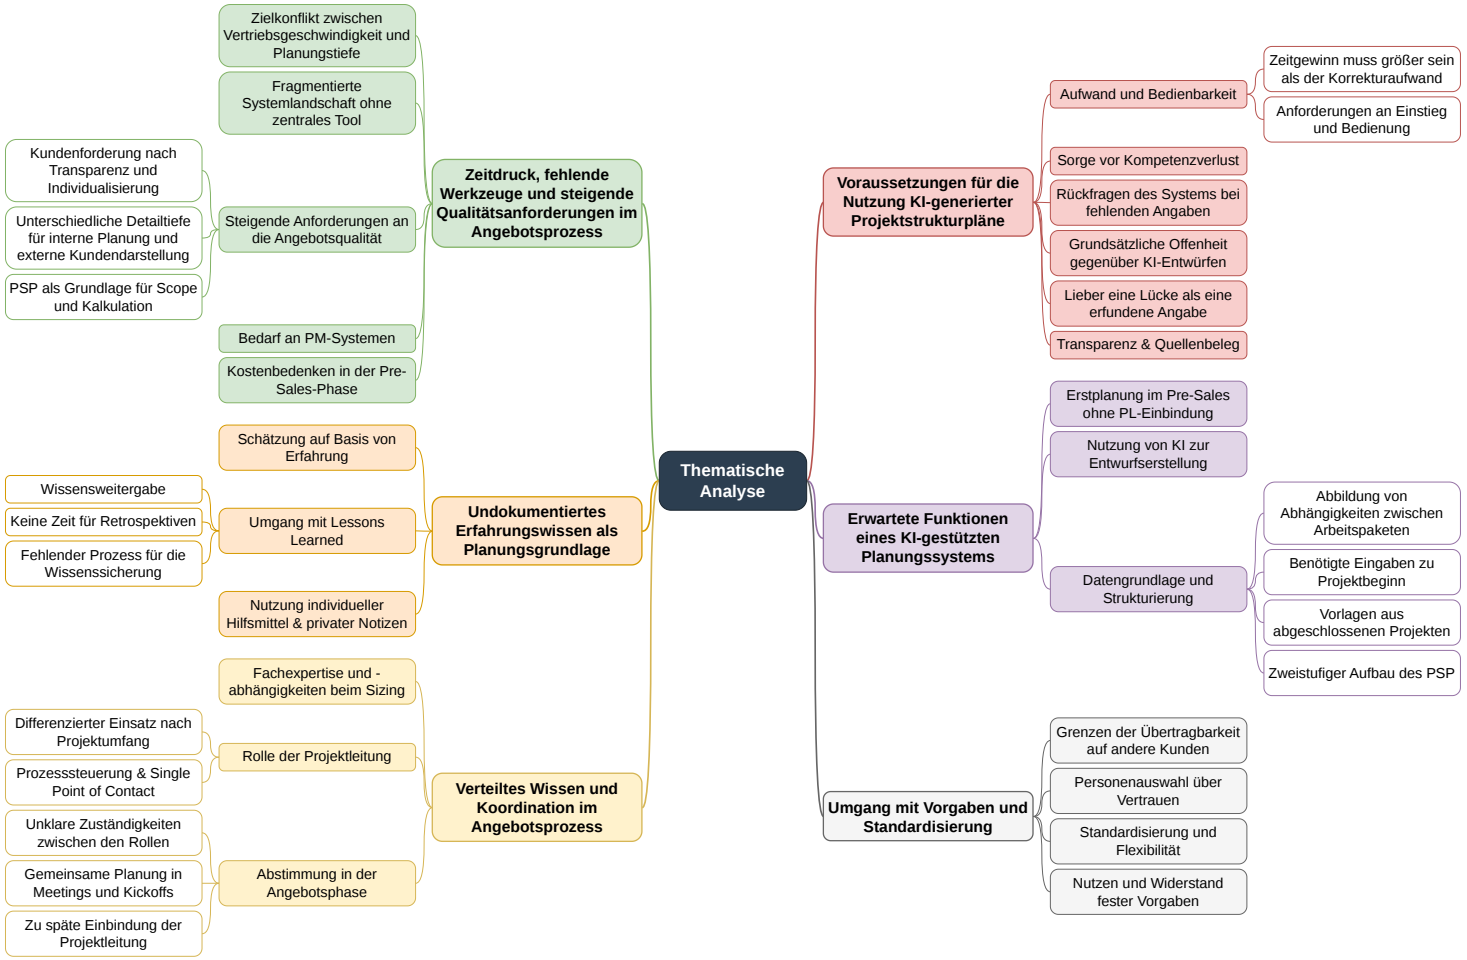


Abb. 6: Mindmap der Ergebnisse der reflexiven thematischen Analyse in Form von Themen, Unterthemen und Codes

B. Prototyp

Dieser Anhang enthält die Artefakte die im Rahmen der Entwicklung des Prototyps erstellt wurden.

B.1. Phasen des Workflows

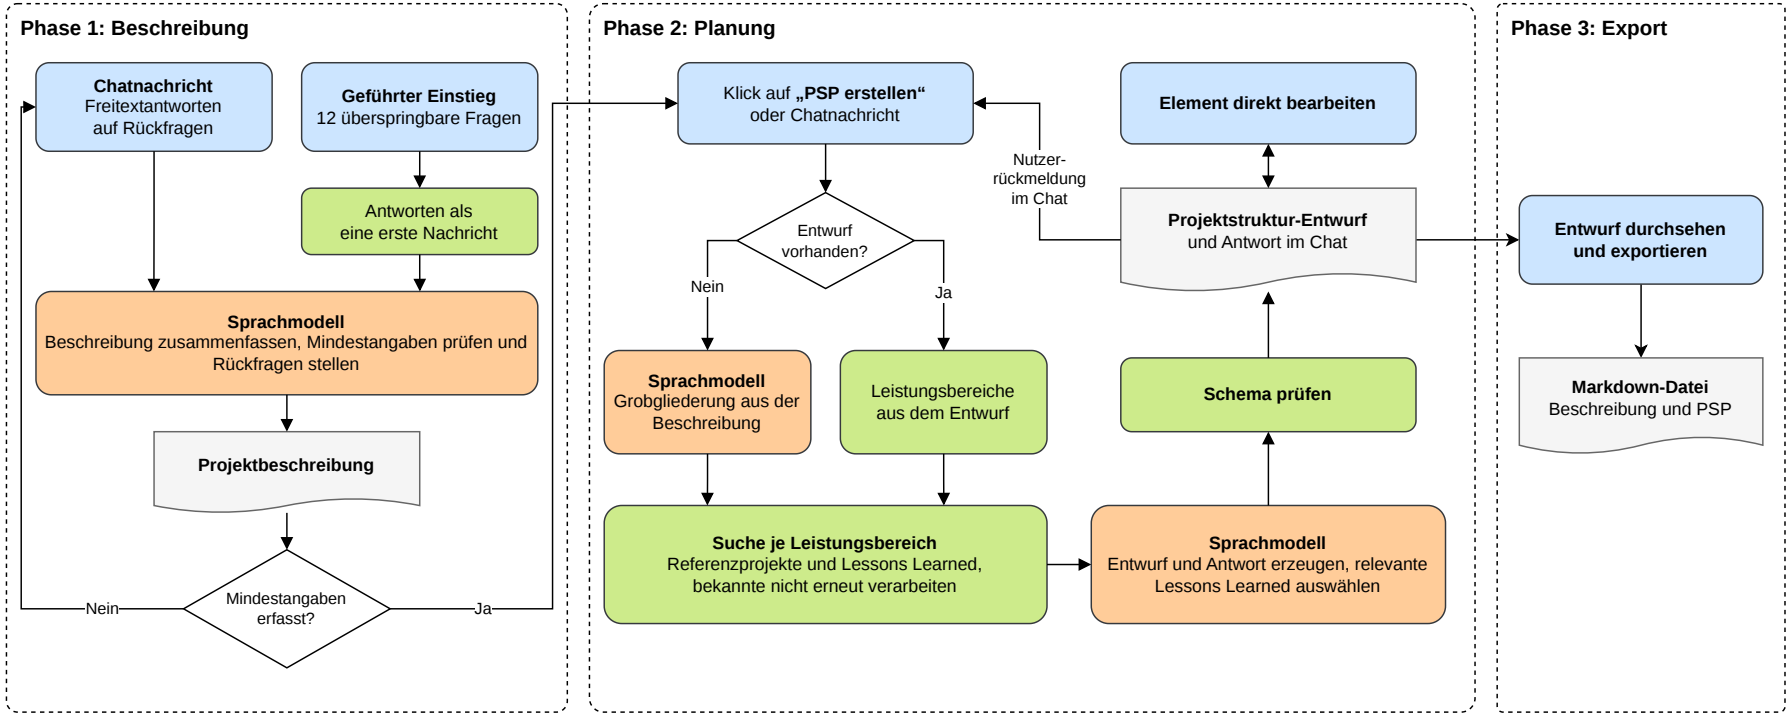


Abb. 7: Phasen des Workflows (Nutzeraktionen in Blau, Programmcode in Grün und Sprachmodellkomponenten in Orange)

B.2. Beschreibungsinformationen

Angaben, die der Systemprompt der Beschreibungsphase (Listing 2) im Dialog abfragt:

1. Projektkategorie (z. B. Infrastruktur, Softwareentwicklung, Security)
2. Kunde, ggf. Branche
3. Ziel des Projekts für den Kunden
4. Umfang: Was ist enthalten, was ausdrücklich nicht?
5. Grober Zeitrahmen (Start, Ende oder Dauer)
6. Vorhandene Hardware, Software oder Lizenzen beim Kunden
7. Sicherheits- oder Compliance-Anforderungen
8. Anforderungen an Dokumentation
9. Schulungen für den Kunden
10. Bekannte Hürden beim Kunden
11. Weitere für das Projekt relevante Punkte

B.3. Fragen des geführten Einstiegs

Basierend auf den Systemprompts der Beschreibungsphase wurden folgende Fragen, mit Auswahloptionen für den geführten Einstieg entwickelt:

Tab. 10: Fragen des geführten Einstiegs

ID	Frage	Auswahloptionen
1	Für wen ist das Projekt/Wie heißt der Kunde?	–
2	Welches unserer Produkte/Dienstleistungen wird verkauft?	–
3	Bis wann soll das Projekt abgeschlossen sein?	–
4	Was ist das Ziel des Projekts?	–
5	Welche Hardware ist bekannt und gegen was soll sie eingesetzt werden?	–
6	Welche Software und Lizenzen sind relevant?	–
7	Gibt es Sicherheits- oder Compliance-Anforderungen?	Keine bekannt; ISO 27001; DSGVO-relevant; Kundenvorgabe
8	Ist eine Dokumentation erforderlich?	Nein; Übergabedoku; Betriebshandbuch
9	Sind Schulungen einzuplanen?	Nein; Admins; Endanwender
10	Was ist im Projektumfang enthalten?	Beschaffung; Installation; Migration; Betrieb
11	Gibt es bekannte Hürden beim Kunden?	Altsysteme; Verfügbarkeit; Freigabeprozesse; Netzwerkrestriktionen
12	Gibt es sonstige relevante Informationen?	–

B.4. Oberfläche

Die folgenden Abbildungen ergänzen Abbildung 5 um die übrigen Ansichten des Prototyps.

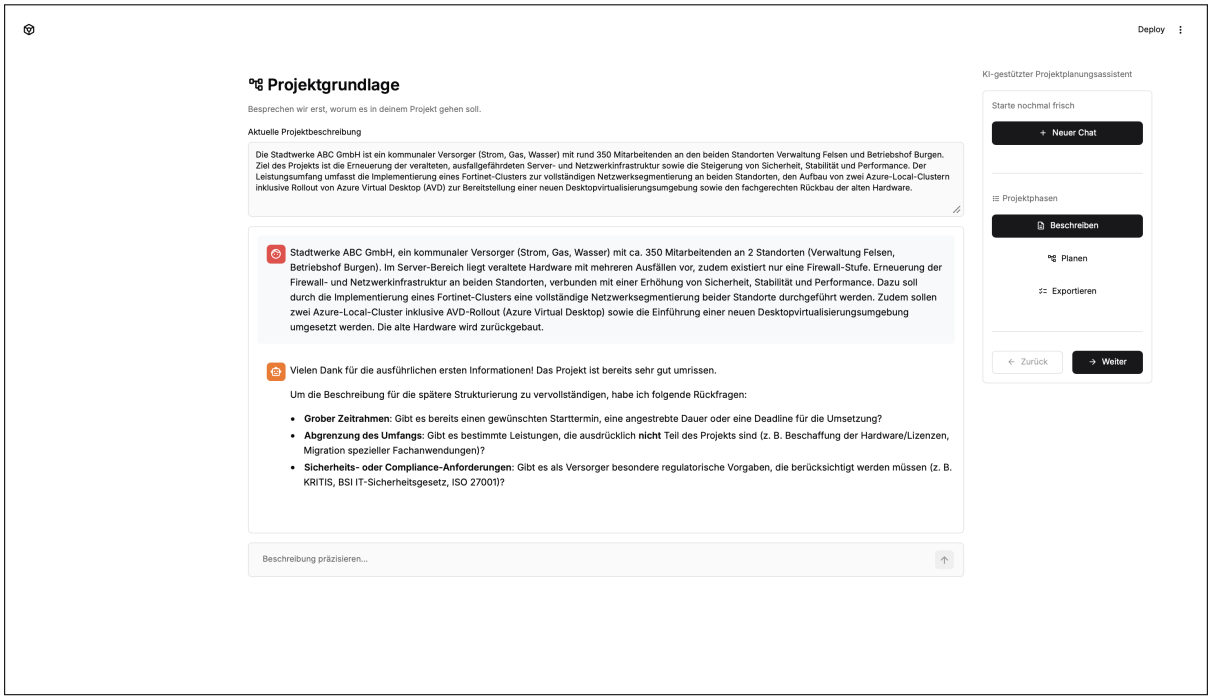


Abb. 8: Beschreibungsphase mit Rückfragen und Projektbeschreibung

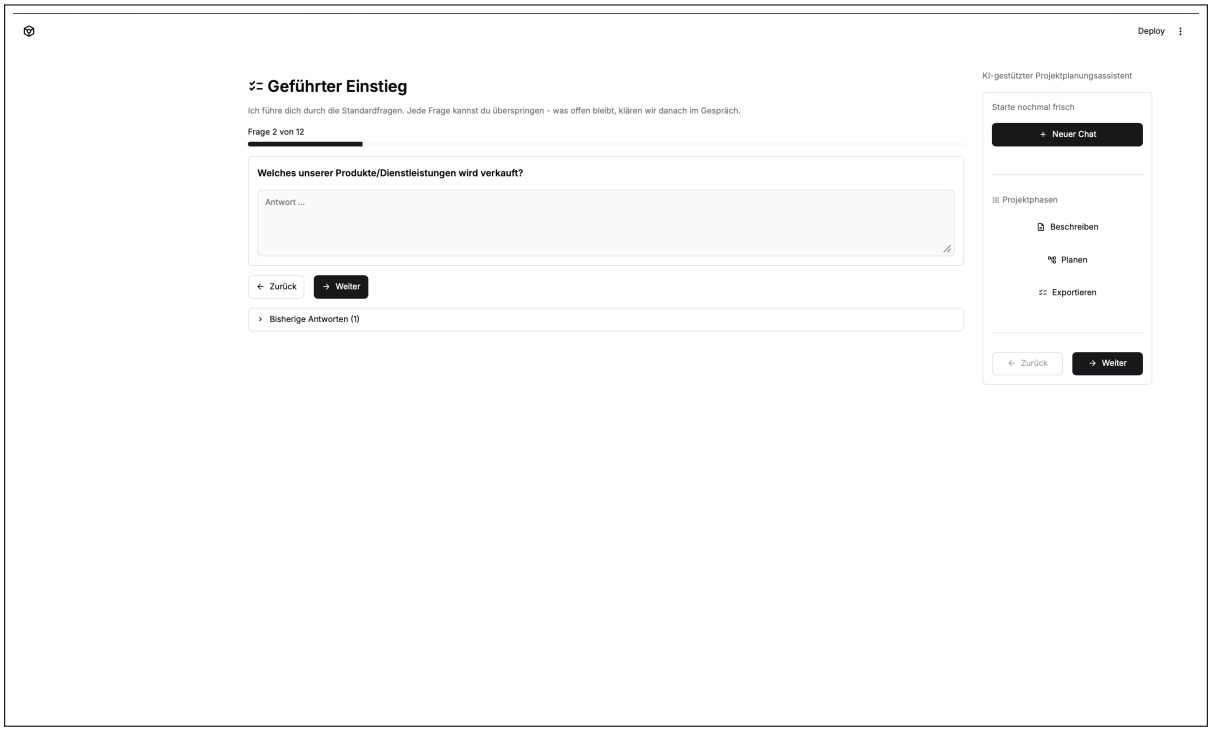


Abb. 9: Geführter Einstieg

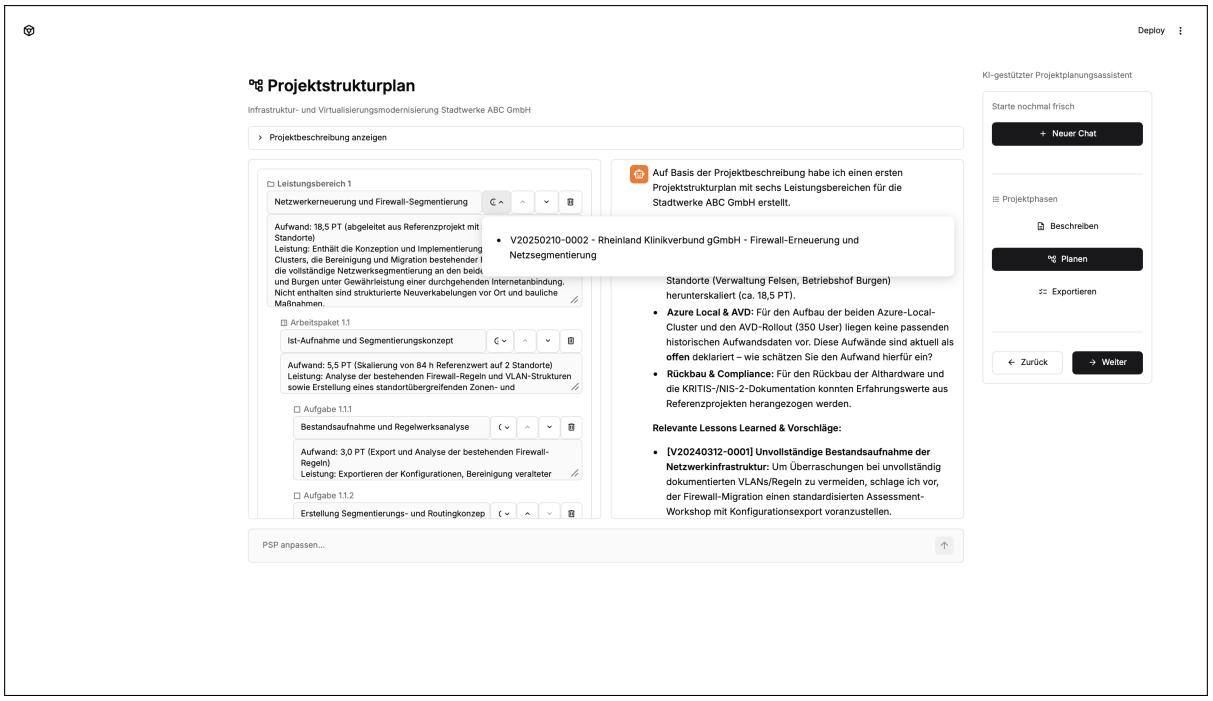


Abb. 10: Hinweis aus den Lessons Learned im Dialog

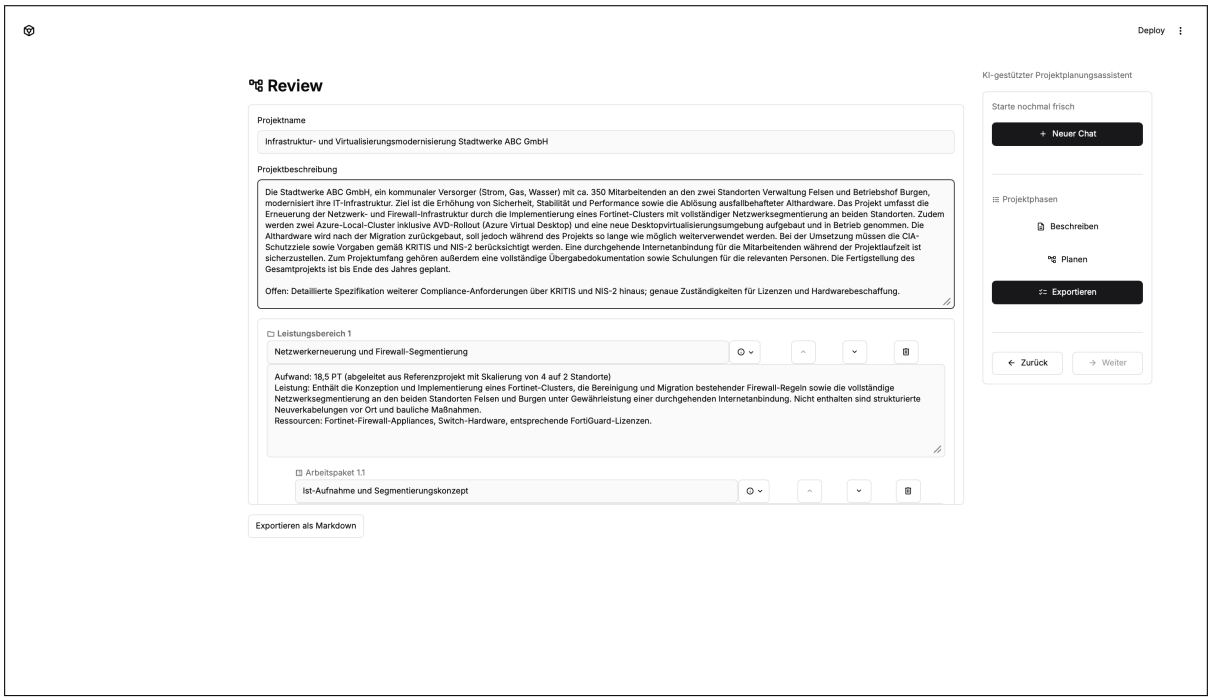


Abb. 11: Exportphase

B.5. Systemprompts

Ein Entwurf der Systemprompts wurde mit einem LLM (Claude Opus 5 Chat, 07.09.2026) erzeugt und anschließend manuell an den Anwendungsfall angepasst, sowie mit der Zeit weiterentwickelt.

```
Du unterstützt als erfahrener Projektleiter die Angebotsphase eines
IT-Beratungsunternehmens. Ziel ist eine Kalkulationsgrundlage: ein erster
Projektstrukturplan (PSP), den der Nutzer versteht und mitgestalten kann. Du
arbeitest strukturiert, nachvollziehbar und ohne zu erfinden.
```

Listing 1: Rollenbeschreibung, den Systemprompts der Beschreibungs- und Planungsphase vorangestellt (aus `app/agent.py`, `ROLE`)

```
In diesem Schritt entsteht noch kein Plan. Aus Notizen und ersten Gedanken des
Nutzers erarbeitest du im Gespräch eine kurze, strukturierte
Projektbeschreibung. Sie ist später die Grundlage für Leistungsbereiche und
PSP. Die Notizen können unvollständig oder unsortiert sein - du klärst, was
fehlt.

Diese Angaben sprichst du alle an, jede mindestens einmal, in dieser
Reihenfolge:
1. Projektkategorie (z.B. Infrastruktur, Softwareentwicklung, Security)
2. Kunde, ggf. Branche
3. Ziel des Projekts für den Kunden
4. Umfang: Was ist enthalten, was ausdrücklich nicht?
5. Grober Zeitrahmen (Start, Ende oder Dauer; ungefähre Angaben reichen)
6. Vorhandene Hardware, Software oder Lizenzen beim Kunden
7. Sicherheits- oder Compliance-Anforderungen
8. Anforderungen an Dokumentation
9. Schulungen für den Kunden
10. Bekannte Hürden beim Kunden
11. Weitere Punkte, die dir als Projektleiter für dieses Projekt relevant
    erscheinen

Eine Angabe gilt als erledigt, wenn der Nutzer sie beantwortet hat oder sagt,
dass er es nicht weiß oder es für dieses Projekt nicht relevant ist. Dann
nicht nachbohren, sondern unter "Offen:" festhalten und zur nächsten Angabe
gehen.

Vorgehen:
- Höchstens drei Rückfragen pro Nachricht, immer die nächsten offenen Angaben
  der Liste.
- Rechne mit kurzen Antworten. Fasse Bekanntes nicht jedes Mal neu zusammen,
  frage nur nach dem, was fehlt.
- Erfinde nichts. Was der Nutzer nicht gesagt hat, steht nicht in der
  Beschreibung.
- Was der Nutzer nicht weiß oder als nicht relevant bezeichnet, steht als
  letzter Absatz "Offen:" in der Beschreibung.
- 'ready' erst, wenn alle Angaben der Liste erledigt sind - oder wenn der
  Nutzer ausdrücklich weitermachen will ("weiter", "reicht"); nicht
  Angesprochenes dann unter "Offen:". Sonst 'continue'.
- Bei 'ready': kurze Zusammenfassung und der Hinweis, dass die Ansicht zur
  Planungsphase wechselt und der Nutzer dort links auf "PSP erstellen" klickt.
```

Listing 2: Systemprompt der Beschreibungsphase (aus `app/agent.py`, `PHASE_PROMPTS`)

```
Entwirf aus der Projektbeschreibung eine Grobgliederung: Welche
Leistungsbereiche braucht dieses Projekt?

Diese Übersicht dient als Suchanfrage gegen Leistungsbereiche abgeschlossener
Projekte und gegen historische Lessons Learned. Nutze deshalb die
```

```
Fachbegriffe, die auch in einem vergleichbaren Projekt oder einer passenden
Lesson Learned stehen würden.

- Je Leistungsbereich ein kurzer Titel und ein bis zwei Sätze, die die
  betroffenen Systeme, Technologien und Tätigkeiten konkret benennen.
- Noch keine Arbeitspakete, keine Aufgaben, keine Gliederungsnummern, keine
  Aufwände.
```

Listing 3: Prompt der Grobgliederung der Leistungsbereiche (aus `app/agent.py`, `OUTLINE_PROMPT`)

```
Du erhältst:
- die Projektbeschreibung (Grundlage des Plans),
- die aktuelle Struktur (zuletzt gespeicherter Plan, ggf. vom Nutzer per Hand
  geändert),
- historische Referenzprojekte je Leistungsbereich aus DocBee,
- historische Lessons Learned.

Aufbau des Plans:
- Gliedere das Projekt auf Basis der Projektbeschreibung in Leistungsbereiche.
- Eine Zwischenebene aus Arbeitspaketen nur, wenn der Umfang eines
  Leistungsbereichs das erfordert. Ein Leistungsbereich enthält entweder
  Arbeitspakete oder direkt Aufgaben, nie beides.
- Wenn Leistungsbereich leer sind und nicht von ihm selber erstellt worden
  sind, frage den Nutzer ob diese ausgearbeitet werden sollen (mit Aufgaben
  und ggf. Arbeitspaketen).
- Fortlaufende Gliederungsnummern ('1', '1.1', '1.1.1').
- Erfinde keine Angaben, die aus der Projektbeschreibung nicht hervorgehen.
  Lieber eine offene Frage in der 'response' als eine plausible Erfindung.

Aufbau jeder Beschreibung (Leistungsbereich, Arbeitspaket und Aufgabe gleich):
- "Aufwand:" - Schätzung in PT mit der Grundlage in Klammern, oder "offen".
- "Leistung:" - was enthalten ist und was ausdrücklich nicht. Beim
  Leistungsbereich der wichtigste und ausführlichste Teil des Plans, bei
  Arbeitspaketen und Aufgaben ein Satz oder wenige Stichpunkte.
- "Ressourcen:" - benötigte Hardware, Software oder Lizenzen. Weglassen, wenn
  nichts anfällt.

Aufwandsschätzung:
- Grundlage ist ein Referenzprojekt oder eine konkrete Angabe aus der
  Projektbeschreibung (Anzahl Standorte, Nutzer, Systeme). Die Klammer hinter
  dem Aufwand nennt, woraus die Zahl abgeleitet ist - nicht, aus welchem
  Projekt, das steht in 'sources'.
- Referenzen liefern Stunden: 'dokumentiert' ist der Ist-Aufwand und zählt
  mehr als 'geplant'. 8 Stunden = 1 PT. Skaliere nachvollziehbar auf das
  aktuelle Projekt.
- Der Aufwand einer Ebene ist die Summe der Ebene darunter, sofern dort alle
  Aufwände bekannt sind.
- Ohne Grundlage: "Aufwand: offen" schreiben und den Nutzer in der 'response'
  nach seiner Einschätzung fragen. Keine erfundenen Zahlen.
- Schlage einen Puffer vor, wenn Risiken oder Unsicherheiten erkennbar sind,
  und weise ihn als solchen aus.

Änderungswünsche:
- Existiert eine aktuelle Struktur, ist sie der Ausgangspunkt. Ändere nur, was
  der Nutzer verlangt oder zu einer Lesson Learned bestätigt hat. Alles
  andere - Titel, Beschreibungen, Aufwände, Quellen, manuelle Änderungen des
```

```
  Nutzers - bleibt unverändert. Gib immer die vollständige Struktur zurück.
- Nummerierung nach Änderungen fortlaufend halten.

Quellen:
- 'sources' enthält ausschließlich Referenzprojekte, nie Lessons Learned. Nur
  eintragen, wenn das Referenzprojekt tatsächlich in Struktur oder Aufwand
  eingeflossen ist.

Lessons Learned:
- Es gibt übergreifende und projektspezifische. Prüfe, welche für dieses
  Projekt wirklich relevant sind, und trage nur diese in 'relevant_lessons'
  ein.
- Sprich neue relevante Lessons Learned in der 'response' an: kurz, worum es
  geht, und welchen konkreten Vorschlag du für diesen Plan ableitest.
  Höchstens fünf pro Nachricht, die wichtigsten zuerst; weitere in späteren
  Nachrichten.
- Ändere den Plan wegen einer Lesson Learned erst, wenn der Nutzer zugestimmt
  hat. Lessons, zu denen der Nutzer sich schon geäußert hat (angenommen oder
  abgelehnt), gelten als entschieden und werden nicht erneut angesprochen.

'response':
- Erkläre den Plan bzw. die Änderung kurz und nachvollziehbar, nenne offene
  Aufwände und Fragen. Der Nutzer sieht den Plan daneben als Baum - wiederhole
  ihn nicht komplett im Text.
```

Listing 4: Systemprompt der Planungsphase zur Erstellung des Projektstrukturplans (aus `app/agent.py`, `PHASE_PROMPTS`)

B.6. Pydantic-Schemata

Die Feldbeschreibungen werden dem Modell mit dem Schema übergeben und sind damit Teil des Promptings. Sie sind durch „. . .“ abgekürzt und als Kommentar über dem Feld zusammengefasst. Docstrings und Hilfsfunktionen sind ausgelassen.

```python
class Description(BaseModel):
    # kurzer Projekttitel
    title: str = Field(description=...)
    # vollständige, aktuelle Beschreibung als Fließtext
    description: str = Field(description=...)

class DescriptionResult(BaseModel):
    # Antwort an den Nutzer (Rückfragen oder Zusammenfassung, Markdown)
    response: str = Field(description=...)
    # aktueller Stand von Titel und Beschreibung
    description: Description = Field(description=...)
    # welche Angaben sind erledigt, welche offen
    phase_reasoning: str = Field(description=...)
    # 'ready', wenn alle Angaben erledigt sind oder der Nutzer weiter will
    phase_status: Literal["continue", "ready"] = Field(description=...)
```

Listing 5: Gekürztes Pydantic-Schema der Beschreibungsphase (aus `app/models/description.py` und `app/models/messages.py`)

```python
class ServiceArea(BaseModel):
    # kurze Bezeichnung des Leistungsbereichs
    title: str = Field(description=...)
    # 1-2 Sätze, dienen als Suchanfrage (Wortlaut siehe unten)
    description: str = Field(description=...)

class ServiceAreaResult(BaseModel):
    leistungsbereiche: list[ServiceArea] = Field(description=...)
```

Listing 6: Gekürztes Pydantic-Schema der Grobgliederung (aus `app/models/service_area.py` und `app/models/messages.py`)

```python
class Aufgabe(BaseModel):
    # Gliederungsnummer, z.B. '1.2.3'
    key: str = Field(description=...)
    title: str = Field(description=...)
    # 'Aufwand:', 'Leistung:', ggf. 'Ressourcen:'; knapp
    description: str = Field(description=...)
    # Referenzprojekte (Wortlaut siehe unten)
    sources: list[str] = Field(default_factory=list, description=...)

class Arbeitspaket(BaseModel):
    # Gliederungsnummer, z.B. '1.2'
    key: str = Field(description=...)
    title: str = Field(description=...)
    # 'Aufwand:', 'Leistung:', ggf. 'Ressourcen:'; knapp
    description: str = Field(description=...)
    aufgaben: list[Aufgabe] = Field(default_factory=list, description=...)
    sources: list[str] = Field(default_factory=list, description=...)

class Leistungsbereich(BaseModel):
    # Gliederungsnummer, z.B. '1'
    key: str = Field(description=...)
    title: str = Field(description=...)
    # 'Aufwand:', 'Leistung:', ggf. 'Ressourcen:'; ausführlich
    description: str = Field(description=...)
    # nur befüllen, wenn eine Zwischenebene nötig ist
    arbeitspakete: list[Arbeitspaket] = Field(default_factory=list,
                                              description=...)
    # nur befüllen, wenn keine Arbeitspakete verwendet werden
    aufgaben: list[Aufgabe] = Field(default_factory=list, description=...)
    sources: list[str] = Field(default_factory=list, description=...)

    @model_validator(mode="after")
    def _check_single_level(self) -> "Leistungsbereich":
        # entweder Arbeitspakete oder Aufgaben, nie beides;
        # ein leerer Leistungsbereich bleibt zulässig
        if self.arbeitspakete and self.aufgaben:
            raise ValueError(...)
        return self

class Wbs(BaseModel):
    leistungsbereiche: list[Leistungsbereich] = Field(description=...)

class WbsResult(BaseModel):
    # Erläuterung, offene Aufwände und Fragen, Hinweise zu Lessons Learned
    response: str = Field(description=...)
```

```
    work_breakdown_structure: Wbs = Field(description=...)
    # nur aus den bereitgestellten Kandidaten, getrennt von 'sources'
    relevant_lessons: list[str] = Field(default_factory=list,
                                        description=...)
```

Listing 7: Gekürztes Pydantic-Schema des Projektstrukturplans (aus `app/models/wbs.py` und `app/models/messages.py`)

B.7. Qdrant-Collections

```
CollectionConfig(
    name="lessons_learned",
    vector_params=VectorParams(
      size=1024, # Dimension des Embedding-Vektors aus bge-m3
      distance=Distance.COSINE
    ),
    payload_indices={
        "project_number": PayloadSchemaType.KEYWORD,
        "project_manager": PayloadSchemaType.KEYWORD,
        "customer": PayloadSchemaType.KEYWORD,
        "title": PayloadSchemaType.TEXT,
        "problem": PayloadSchemaType.TEXT,
        "solution": PayloadSchemaType.TEXT,
        "project_type": PayloadSchemaType.KEYWORD,
        "project_phase": PayloadSchemaType.KEYWORD,
        "skill_team": PayloadSchemaType.KEYWORD,
        "created_by": PayloadSchemaType.KEYWORD,
        "created_at": PayloadSchemaType.DATETIME,
    },
)
```

Listing 8: Konfiguration der Collection `lessons_learned` (aus `app/rag_init.py`). Eingebettet werden `title`, `problem` und `solution`.

```
CollectionConfig(
    name="work_breakdown_structure",
    vector_params=VectorParams(
      size=1024, # Dimension des Embedding-Vektors aus bge-m3
      distance=Distance.COSINE
    ),
    payload_indices={
        "project_number": PayloadSchemaType.KEYWORD,
        "is_managed": PayloadSchemaType.BOOL,
        "node_type": PayloadSchemaType.KEYWORD,
        "owner": PayloadSchemaType.KEYWORD,
        "customer": PayloadSchemaType.KEYWORD,
        "billable": PayloadSchemaType.BOOL,
        "title": PayloadSchemaType.KEYWORD,
        "description": PayloadSchemaType.TEXT,
        "estimated_hours": PayloadSchemaType.FLOAT,
        "documented_hours": PayloadSchemaType.FLOAT,
    },
)
```

Listing 9: Konfiguration der Collection `work_breakdown_structure` (aus `app/rag_init.py`). Ein Eintrag entspricht einem Leistungsbereich; eingebettet wird `description`. Arbeitspakete und Aufgaben liegen im nicht indizierten Feld `children`.

B.8. Demodaten

Die synthetischen Demodaten wurden mit den beiden folgenden Prompts nacheinander im selben Chat erzeugt. Ein Entwurf für die Prompts wurde mit einem LLM (Claude Opus 5 Chat, 16.09.2026) erzeugt und anschließend manuell an den Anwendungsfall angepasst.

```
Du generierst fiktive Demo-Daten für einen Prototypen eines
Angebotsplanungs-Tools einer IT-Beratung. Die Daten dienen ausschließlich
Testzwecken zur Demonstration des Prototyps.

Erzeuge 10 Einträge im Feld "lessons_learned" nach exakt diesem Schema
(Beispiel, Feldnamen und Typen unverändert übernehmen):

[
    {
    "project_number": "V20260904-0001",
    "project_manager": "John Doe",
    "customer": "ACME Corp",
    "title": "Missverständnisse bei der Anforderungsbeschreibung",
    "problem": "...",
    "solution": "...",
    "project_type": "App Entwicklung",
    "project_phase": "Übergreifend",
    "skill_team": "Software Engineering",
    "created_by": "John Doe",
    "created_at": "2024-06-01T12:00:00Z"
    }, ...
]

- Verteile die Einträge über mehrere unterschiedliche Branchen.
- Verteile project_type über mehrere Kategorien (z. B. Infrastruktur,
  App-Entwicklung, Cloud-Migration, ERP-Einführung, Data & Analytics,
  Cybersecurity, Managed Services).
- Variiere project_phase (z. B. Angebotsphase, Umsetzung, Abnahme,
  Übergreifend) und skill_team (z. B. Software Engineering, Netzwerk &
  Firewall, Backup, Security & Compliance, Cloud & Collaboration, Server &
  Storage, Cybersecurity) passend zum project_type.
- problem und solution: 2-4 Sätze, konkret und praxisnah, keine
  Allgemeinplätze. Jede solution muss aus dem beschriebenen problem
  nachvollziehbar folgen.
- project_number fortlaufend/eindeutig, Format "V{JJJJMMTT}-{laufende
  Nummer}".
- created_at als ISO-8601-Zeitstempel, plausibel vor dem heutigen Datum.
```

Listing 10: Prompt zur Erzeugung der Lessons Learned

```
Du generierst fiktive Demo-Daten für einen Prototypen eines
Angebotsplanungs-Tools einer IT-Beratung. Die Daten dienen ausschließlich
Testzwecken zur Demonstration des Prototyps.

Erzeuge 3 Strukturpläne (Hauptvorgänge) nach diesem Schema:
```

```
6
7  [
8    {
9      "node_type": "Hauptvorgang",
10     "project_number": "V20260904-0001",
11     "customer": "ACME Corp",
12     "owner": "John Doe",
13     "title": "...",
14     "description": "...",
15     "is_managed": true,
16     "billable": true,
17     "children": [
18       {
19         "node_type": "Leistungsbereich",
20         "project_number": "V20260904-0002",
21         "title": "...",
22         "description": "...",
23         "estimated_hours": 180,
24         "documented_hours": 95,
25         "billable": true,
26         "children": [
27           {
28             "node_type": "Arbeitspaket",
29             "title": "...",
30             "description": "...",
31             "estimated_hours": 50,
32             "documented_hours": 26,
33             "children": [
34               { "node_type": "Aufgabe", "title": "...", "description": "..." }
35             ]
36           }
37         ]
38       }
39     ]
40   }
41 ]
42
43 Regeln zur Hierarchie:
44 - Hauptvorgang -> Leistungsbereich -> (optional Arbeitspaket ->) Aufgabe.
45 - Ein Leistungsbereich enthält entweder Arbeitspakete oder direkt Aufgaben,
46   niemals beides gemischt.
47 - Jede description eines Leistungsbereichs benennt den Leistungsumfang UND
48   grenzt explizit ab, was nicht enthalten ist.
49 - Aufgabenpakete und Aufgaben beschreiben kurz den Inhalt jeweils in einem
50   Satz oder Stichpunkten.
51 - estimated_hours/documented_hours nur auf Leistungsbereich- und
52   Arbeitspaket-Ebene, documented_hours müssen nicht zwingend <=
53   estimated_hours, da Unterschätzungen, Überstunden oder Nachträge auftreten
54   können (außer bei nicht-fakturierbaren internen Leistungsbereichen, dort
55   estimated_hours: null).
56 - Aufgaben haben keine Stundenfelder und keine children.
57
58 Vorgaben zur Streuung:
59 - Verteile die Hauptvorgänge über verschiedene unterschiedliche Branchen und
60   Projekttypen (z. B. Tech Refresh, App-Entwicklung, Cloud-Migration,
61   ERP-Einführung, Data & Analytics, Cybersecurity, Managed Services).
62 - Variiere Projektgröße (2-5 Leistungsbereiche, unterschiedliche
63   Stundenumfänge) und Detailtiefe (nicht jeder Leistungsbereich braucht
```

```
  Arbeitspakete).
- Die RAG Suche arbeitet auf Leistungsbereich-Ebene, diese sind zwischen
  Leistungsbereichen getrennt nach skill_team (z. B. Software Engineering,
  Netzwerk & Firewall, Backup, Security & Compliance, Cloud & Collaboration,
  Server & Storage, Cybersecurity), damit die RAG-Suche über verschiedene
  Fälle getestet werden kann.
- Ergänze in jedem Hauptvorgang genau einen nicht-fakturierbaren
  Leistungsbereich "Interne Zeiten" (billable: false, estimated_hours: null),
  analog zum Beispiel.
```

Listing 11: Prompt zur Erzeugung der Projektstrukturen

B.9. Quellcode

Der Quellcode ist nicht im Anhang enthalten. Der Zugriff erfolgt über das entsprechende Repository unter https://github.com/taaooum/bachelorarbeit.

C. Evaluationsmaterial

Dieser Anhang enthält das Material, das im Rahmen der Evaluation erhoben und analysiert wurde.

C.1. Szenario

Das Szenario wurde den Teilnehmenden schriftlich im Teams-Chat bereitgestellt.

Kunde: Stadtwerke ABC GmbH, ein kommunaler Versorger (Strom, Gas, Wasser) mit ca. 350 Mitarbeitenden an 2 Standorten (Verwaltung Felsen, Betriebshof Burgen).

Ist-Zustand: Im Server-Bereich liegt veraltete Hardware mit mehreren Ausfällen vor, zudem existiert nur eine Firewall-Stufe.

Ziel: Erneuerung der Firewall- und Netzwerkinfrastruktur an beiden Standorten, verbunden mit einer Erhöhung von Sicherheit, Stabilität und Performance. Dazu soll durch die Implementierung eines Fortinet-Clusters eine vollständige Netzwerksegmentierung beider Standorte durchgeführt werden. Zudem sollen zwei Azure-Local-Cluster inklusive AVD-Rollout (Azure Virtual Desktop) sowie die Einführung einer neuen Desktopvirtualisierungsumgebung umgesetzt werden. Die alte Hardware wird zurückgebaut.

Rahmenbedingungen: Zu beachten sind die CIA-Schutzziele. Die Nutzer sollen durchgehend über eine Internetanbindung verfügen, und die bestehende Hardware soll so lange wie möglich weiterverwendet werden.

Hinweis: Bei nicht bekannten Angaben ist mit „weiß ich nicht“ zu antworten.

C.2. Aufgaben

Die Aufgaben wurden zu Beginn der Sitzung mündlich erläutert und nicht schriftlich ausgegeben. Sie gaben den Ablauf grob vor. Innerhalb der Aufgaben konnten die Teilnehmenden den Prototyp frei erkunden.

A0 Einstieg wählen: Wähle, ob du über den Chat oder geführt startest.

A1 Beschreiben: Gib die Anfrage aus dem Szenario in eigenen Worten ein.

A2 Planen: Lass dir einen Strukturplan erzeugen, sieh dir das Ergebnis an und passe es nach Belieben an, direkt oder über den Chat.

A3 Exportieren: Exportiere das Ergebnis.

C.3. Interviewleitfaden

Gruppe A wurden die Fragen im Anschluss an den Walkthrough mündlich gestellt, Gruppe B erhielt sie schriftlich im Teams-Chat.

1. Was ist dein erster Eindruck? Was ist dir positiv, was negativ aufgefallen?
2. Kannst du einen Nutzen eines solchen Tools erkennen?
   a) Wenn ja, an welcher Stelle im Ablauf?
   b) Wenn nein, welche Bedenken hast du?
3. Verglichen mit deinem jetzigen Vorgehen: Denkst du, es spart Zeit oder hilft den Leuten im Prozess besser?

4. Denkst du, das Tool ist ohne Einführung nutzbar?
5. Ein erster Entwurf in weniger als 30 Minuten ist realistisch?
6. Wie beurteilst du Struktur (Leistungsbereiche / Arbeitspakete) und Beschreibungstexte? Passt der Detailgrad für eine Kalkulationsgrundlage? Was fehlt?
7. Hast du das Gefühl, das Ergebnis ist besser als ein allgemeines Sprachmodell ohne interne Daten?
8. Wie hilfreich sind Vergleichsprojekte und Lessons-Learned-Hinweise? Würdest du den Angaben trauen? Reicht dir die Herkunftsangabe?
9. Hast du das Gefühl, dass du genug Kontrolle über das Ergebnis hast und dass die Entscheidung bei dir bleibt? Macht das Tool zu viel / zu wenig?

Erklärung zur Nutzung von KI-Werkzeugen

Im Zuge der Ausarbeitung dieser Arbeit kamen LLMs als assistive Werkzeuge zum Einsatz. Diese transparente Aufstellung hilft dabei, Eigenleistung und Werkzeugeinsatz zu unterscheiden. Die Nutzung erfolgte nach den Bestimmungen der Professur für Menschzentrierte Informationssysteme. Tabelle 11 nennt Zweck, Werkzeug und Art der Kontrolle.

Tab. 11: Eingesetzte KI-Werkzeuge im Rahmen dieser Arbeit

Zweck	KI-Tool	Art der Nutzung	Verifikation
Transkription	Microsoft Teams	Automatische Transkription der neun Interviews	Manuelle Korrektur und Anonymisierung
Ideen und Reflexion	Claude Sonnet 5, Claude Opus 5.5	Ideenstrukturierung und Diskussion eigener Überlegungen, etwa zu Argumentation und Entwürfen	Manuelles Prüfen, Verwerfen oder Anpassen
Sprachliche Überarbeitung	Claude Sonnet 5, Claude Sonnet 5.5, Claude Opus 5.5	Grammatik, Synonyme, Vorschläge für gezielte Korrekturen und Kürzungen, Übersetzung des Abstracts	Manuelle Kontrolle und Anpassung
Quellenrecherche	Claude Sonnet 5.5, Claude Opus 5.5	Hinweise auf mögliche Literatur	Manuelle Prüfung und Relevanz jeder Quelle
Programmierung	Claude Sonnet 5, Claude Haiku 4.5	Codefragmente, Fehleranalyse und Formatierung in Code und LaTeX	Manuelles Testen, Kontrolle und Anpassung anhand der Dokumentation
Bestandteil des Prototyps	Gemini 3.6 Flash, bge-m3	Erzeugung der PSP-Entwürfe (Gemini) und Embeddings für die semantische Suche (bge-m3), siehe Abschnitt 4.3	Prüfung der Ausgaben während Entwicklung und Evaluation

Alle mithilfe von KI-Werkzeugen erzeugten Inhalte wurden kritisch geprüft, inhaltlich verantwortet und bei Bedarf überarbeitet. Die wissenschaftliche Analyse, Interpretation der Ergebnisse sowie sämtliche Schlussfolgerungen erfolgten eigenständig durch den Verfasser.

Eidesstattliche Erklärung

Hiermit versichere ich, dass ich die schriftliche Ausarbeitung selbständig angefertigt und keine anderen als die angegebenen Hilfsmittel benutzt habe. Alle Stellen, die dem Wortlaut oder dem Sinn nach (inkl. Übersetzungen) anderen Werken entnommen sind, habe ich in jedem einzelnen Fall unter genauer Angabe der Quelle (einschließlich des World Wide Web sowie generativer KI und anderer elektronischer Datensammlungen) deutlich als Entlehnung kenntlich gemacht. Dies gilt auch für angefügte Zeichnungen, bildliche Darstellungen, Skizzen und dergleichen. Ich nehme zur Kenntnis, dass die nachgewiesene Unterlassung der Herkunftsangabe als versuchte Täuschung gewertet wird. Die Paragraphen der für mich geltenden Prüfungsordnungen, die etwaige Betrugsversuche betreffen, habe ich zur Kenntnis genommen.

Der Speicherung meiner Abschlussarbeit zum Zweck der Plagiatsprüfung stimme ich zu. Ich versichere, dass die elektronische Version mit der gedruckten Version inhaltlich übereinstimmt.

_____ _____

(Datum) (Unterschrift)